Hướng dẫn tải bài tập

- Trước khi làm bài tập chương, ta truy cập vào đường link Github sau để tải các bài tập trong chương đó: https://github.com/hhohho/Learn-Data-Mining-through-Excel-2.
- Sau khi truy cập vào đường link ta sẽ thấy có 14 folder đại diện cho từng chương và bài tập của chương đó, bây giờ bấm vào folder có tên "chapter2", trong folder sẽ chứa 6 file excel (3 file bài tập, 3 file đáp án của bài tập đó). Sau đó ta bấm vào từng file và tải "Download raw file" ở dưới icon "History".

Hiểu biết

1. Lý thuyết

Hồi quy tuyến tính (Linear Regression) là một mô hình dự đoán được sử dụng để xây dựng một mô hình tuyến tính nhằm đưa ra dự đoán trên dữ liệu mới.

a) Mô hình tuyến tính

Mô hình tuyến tính giả định mối quan hệ giữa biến mục tiêu (biến phụ thuộc, y) và biến thuộc tính (biến độc lập, x) là tuyến tính.

Trường hợp **một Biến Độc lập** (Simple Linear Regression):

$$y = mx + b$$

- Trong đó: m là hệ số góc (slope), và b là hệ số chặn (y-intercept).

Trường hợp **nhiều Biến Độc lập** (Multiple Linear Regression):

$$y = m_1x_1 + m_2x_2 + \ldots + m_nx_n + b$$

b) Phương pháp bình phương tối thiểu (Least Square Method)

Excel sử dụng LSM để tìm ra các hệ số m_i và b tối ưu. Phương pháp này hoạt động bằng cách tối thiểu hóa tổng bình phương các sai số (E) giữa giá trị thực tế (y_i) và giá trị dự đoán.

Công thức tính tổng bình phương sai số (E):

$$E = \sum_{i=1}^{n} (y_i - (mx_i + b))^2$$

Làm theo từng bước trong file pdf hướng dẫn thì ta có được các bước làm của từng file sau đây:

2. Thực hành

8125800015

- File Chapter2-1a: Trường hợp một biến độc lập

Bước 1. Ta tính tổng của cột A (Temperature) và của cột B (Ice Cream Sale (dollar in thousand)) bằng công thức: **=SUM(A:A)**; **=SUM(B:B)**. Sau đó thực hiện phép toán tổng của các tích cho cột A và B với công thức **=SUMPRODUCT(A:A, B:B)**. Sau đó, ta tìm tổng của bình phương các số có trong cột A bằng công thức **=SUMPRODUCT(A:A, A:A)**

Bước 2. Tìm số lượng dòng có trong cột A: **=COUNT(A:A)**, thực hiện phép tính m bằng công thức **=(D7*D5-D3*D4)/(D7*D6-D3^2)** và n bằng công thức **=(D6*D4-D3*D5)/(D7*D6-D3^2**)

Bước 3. Sau khi có được giá trị của m và b ta có thể nhập vào công thức dự đoán như sau **=D$8*C12+D$9** ở ô D12, kéo xuống tới D14 để autofill.

Công thức m (Hệ số góc):

$$m = \frac{n\sum_{i=1}^{n} x_i y_i - (\sum_{i=1}^{n} x_i)(\sum_{i=1}^{n} y_i)}{n(\sum_{i=1}^{n} x_i^2) - (\sum_{i=1}^{n} x_i)^2}$$

Công thức b (Hệ số chặn):

$$b = \frac{(\sum_{i=1}^{n} x_i^2)(\sum_{i=1}^{n} y_i) - (\sum_{i=1}^{n} x_i)(\sum_{i=1}^{n} x_i y_i)}{n(\sum_{i=1}^{n} x_i^2) - (\sum_{i=1}^{n} x_i)^2}$$

Tuy nhiên có một cách khác để có được giá trị của m và b, đầu tiên xóa hết cột C và D nãy giờ làm được đi, sau đó dùng công thức **=SLOPE(B:B; A:A)** để có giá trị của m và **=INTERCEPT(B:B; A:A)** để có được giá trị của b. Có thêm một cách đó là dùng Tools dành cho Data Analysis.

Cuối cùng vẽ hình, vào Insert chọn biểu đồ Scatter (tô hết cột A và B trước khi chọn), thêm Trendline, chỉnh sửa sao cho đẹp mắt. Như vậy ta đã có được một biểu đồ dự đoán đẹp mắt.

- File Chapter2-2a: Trường hợp nhiều biến độc lập

Bước 1. Ta dùng 3 biến độc lập sau để dự đoán được cột Ice Cream Sale (dollar in thousand): Temperature, Tourists, Sunny Days. Nhập lần lượt cho ô A11 tới A14 là “Sunny Days”, “Tourists”, “Temperature”, “Y-intercept”. Sau đó ta sử dụng hàm **LINEST** và **INDEX** để tìm được hệ số cho ô A11 bằng **=@INDEX(LINEST(D$2:D$9;A$2:C$9;TRUE;TRUE);1;B11)**, sau đó autofill tới A14 để có được kết quả sau:

Sunny Days: 5.95647

Tourists: -0.0013

31258015

Temperature: 3.97541

Y-intercept: −295.47

Ta có được phương trình của mô hình:

$$y = 3.97541x_1 - 0.0013x_2 + 5.95647x_3 - 295.47$$

Bước 2. Bây giờ ta sẽ xem dự đoán của mô hình mới tốt và chất lượng như thế nào, ta nhập tên cho ô E1 là "Predicted" và F2 là "Error". Cột Predicted, ô E2 ta nhập **=A2*C$13+B2*C$12+C2*C$11+C$14** sau đó autofill tới E9, cột Error ô F2 ta nhập **=POWER(D2-E2;2)** rồi autofill tới F9.

Bước 3. Nhập tên cho ô D11 là "Sum of Errors" và công thức ở ô kế nó **=SUM(F2:F9)**.

Đánh giá: Tổng sai số tìm được là 14.327347. Các hệ số tìm được từ LINEST đảm bảo giá trị sai số này là nhỏ nhất (tối thiểu).

- File Chapter2-HW: Trường hợp nhiều biến độc lập

Bước 1. Sử dụng 9 cột (ngoại trừ Year) để dự đoán cho cột phụ thuộc (Number of First Year Enrollment). Ta sử dụng hàm **LINEST** để xây dựng mô hình và tìm được hệ số tương ứng cho từng cột. Sử dụng công thức cho cột "Num high school graduates" **=@INDEX(LINEST($K37:$K46;$B37:$J46);1;B35)** sau đó autofill ngang cho tới cột phụ thuộc để có được các hệ số như sau

Biến độc lập (x_i)	**Hệ số (m_i)**
Num high school graduates (x_1)	0.00802262
USA Economics (x_2)	12.76836133
comparable tuition fee (x_3)	−3.09130912
financial scholarship (x_4)	−3.42695489
financial aid available (x_5)	−1.04293590
number of open house visitors (x_6)	0.02891171
media advertisement investment (x_7)	−0.00352006

Biến độc lập (x_i)	**Hệ số (m_i)**
admission activities (x_8)	1.39494704
SAT cutoff (x_9)	0.03316125
Y-intercept (b)	−67.05839260

Bước 2. Ta áp dụng các hệ số trên vào phương trình hồi quy tuyến tính đa biến

$$y = \sum m_i x_i + b$$

cùng với đó là dữ liệu từ "NEW YEAR" để có được kết quả dự đoán là **220** sinh viên năm nhất đăng ký.

END

3123580015