Hướng dẫn tải bài tập

- Trước khi làm bài tập chương, ta truy cập vào đường link Github sau để tải các bài tập trong chương đó: https://github.com/hhohho/Learn-Data-Mining-through-Excel-2.
- Sau khi truy cập vào đường link ta sẽ thấy có 14 folder đại diện cho từng chương và bài tập của chương đó, bây giờ bấm vào folder có tên "chapter6", trong folder sẽ chứa 8 file excel (4 file bài tập, 4 file đáp án của bài tập đó). Sau đó ta bấm vào từng file và tải "Download raw file" ở dưới icon "History".

Hiểu biết

1. Lý thuyết

Hồi quy Logistic (Logistic Regression) là một mô hình thống kê dùng để ước tính xác suất xảy ra của một sự kiện (thường là kết quả nhị phân như Có/Không, Sống sót/Tử vong, Mắc bệnh/Không mắc bệnh). Đây là một trường hợp đặc biệt của hồi quy tuyến tính khi biến mục tiêu (y) là biến phân loại.

a) Hàm Logistic (Sigmoid) và xác suất

Mô hình này không dự đoán trực tiếp giá trị y, mà dự đoán xác suất $P(Y = 1)$ nằm trong khoảng [0,1] bằng cách sử dụng **Hàm Sigmoid (Logistic Function)**:

$$P(Y = 1) = \frac{1}{1 + e^{-Z}}$$

Trong đó, Z là biến tuyến tính (Linear Combination) của các biến độc lập (x_i) và hệ số (m_i) tương ứng, tương tự như trong hồi quy tuyến tính:

$$Z = m_1x_1 + m_2x_2 + \ldots + m_nx_n + b$$

b) Phương pháp tìm hệ số tối ưu

Trong Hồi quy Logistic, không thể dùng phương pháp LSM như Hồi quy Tuyến tính. Thay vào đó, ta tìm các hệ số m_i và b tối ưu bằng cách sử dụng công cụ **Solver** trong Excel để:

- **Tối đa hóa Log-Likelihood (Hợp lý Log)**: Là tổng Log của Xác suất (Likelihood) được dự đoán cho từng điểm dữ liệu.
- **Tối thiểu hóa Log-Loss (Sai số Log)**: Là tổng của sai số Log (Cross-Entropy Loss) của mô hình.

Hai phương pháp này cho kết quả các hệ số tương đồng nhau.

3125300015

Làm theo từng bước trong file pdf hướng dẫn thì ta có được các bước làm của từng file sau đây:

2. Thực hành

- File Chapter6-1a: Tìm hệ số bằng tối đa hóa Log-Likelihood

Bước 1. Dùng 5 biến về gen (Gene1 - Gene5) để dự đoán khả năng cho cột 5-year survival, với giá trị $y = 1$ là Sống sót và $y = 0$ là Tử vong. Ở ô B3 và B4 ta nhập công thức **=@INDEX(LINEST($G$6:$G$92;$B$6:$F$92);1;B1)** rồi autofill với G3 và G4, nhập 2 ô này với mục đích là so sánh phương pháp bình thường với phương pháp Solver.

Bước 2. Nhập "m1x1+m2x2+…+b" cho ô H5, sau đó ở ô H6 ta nhập **=$G$4+SUMPRODUCT($B$4:$F$4;B6:F6)** rồi autofill tới H92, nhập "P(1)" cho ô I5 (đại diện cho xác suất sống được trong 5 năm dựa trên dữ liệu của cột H), ở ô I6 ta nhập **=1/(1+EXP(0-H6))** rồi autofill tới I92.

Bước 3. Nhập "Outcome" cho ô J5 và công thức **=IF(I6>0.5,1,0)** cho ô J6, autofill tới J92.

Nhập "Difference" cho ô K5 và công thức **=IF(G6=J6,0,1)** cho ô K6, autofill tới K92.

Nhập "total Diff =" cho ô J2, công thức **=SUM(K6:K92)** cho ô K2.

Nhập "Likelihood" cho ô L5, công thức **=IF(G6=1,I6,1-I6)** cho ô L6 rồi autofill tới L92.

Nhập "Ln(likelihood)" cho ô M5, công thức **=IF(L6=0, -1000000, LN(L6))** cho ô M6 rồi autofill tới M92

Bước 4. Nhập "To-Maximize" cho ô L1, công thức **=SUM(M6:M92)** cho ô M1, ta sẽ dùng Solver với ô này. Sau khi thực hiện Solver xong ta sẽ thấy được kết quả ở ô M1 đã thay đổi và ô K2 đã chuyển thành 12 cùng với đó là các giá trị từ B4 đến G4 cũng đã thay đổi.

Kết quả: Solver sẽ tìm ra các hệ số tối ưu để đạt được giá trị Log-Likelihood lớn nhất (-28.721089).

- File Chapter6-2a: tương tự như file Chapter6-1a, tìm hệ số bằng tối thiểu hóa Log-Loss

Bước 1. Ta tìm hệ số bằng phương pháp tối thiểu hóa Log-Loss, đầu tiên ta sẽ đi tính Log Loss cá nhân do nó là giá trị cần được tối thiểu hóa. Công thức:

$$Log\ Loss = -\left(y_{thực} \ln\left(P(1)\right) + (1 - y_{thực}) \ln\left(1 - P(1)\right)\right)$$

Hàm Excel (Dùng cho một hàng dữ liệu, kết hợp IF):

$$Cell\ Log\ Loss = IF(y_{thực} = 1, -LN(P(1)), -LN(1 - P(1)))$$

Bước 2. Thực hiện các thao tác y như file Chapter6-1a.

Bước 3. Bây giờ ta sẽ đi tối thiểu hóa tổng Log Loss bằng Solver
Kết quả: Solver sẽ tìm ra các hệ số tối ưu để đạt được giá trị Log Loss nhỏ nhất (28.721089). Do tổng Log Loss chính là giá trị âm của tổng Log-Likelihood, nên hai phương pháp cho ra cùng một bộ hệ số tối ưu.

- File Chapter6-HW-1: Hồi quy Logistic đa biến
Bước 1. Sử dụng 13 biến độc lập (M_1 đến M_{13}) để dự đoán (kết quả nhị phân 0 hoặc 1). Ta có các hệ số của mô hình sau khi dùng phương pháp tối đa hóa Log-Likelihood và sử dụng Solver để tìm các hệ số tối ưu của chúng:

Biến độc lập (M_i)	**Hệ số (m_i)**
M_1	-0.00122820
M_2	0.14569183
M_3	0.08276323
M_4	0.00213617
M_5	0.00035489
M_6	-0.09823829
M_7	0.03265770
M_8	-0.00262619
M_9	0.13475306
M_{10}	0.03242804
M_{11}	0.06103458
M_{12}	0.14319872
M_{13}	0.06062366
Hệ số chặn (b)	-0.38603111

Bước 2. Tiếp theo ta sẽ dự đoán và phân loại, dùng SUMPRODUCT để tính tổng tích của 13 biến độc lập và 13 hệ số tương ứng, sau đó cộng với b để tính biến tuyến tính và xác suất P(1):

$$Z = \sum_{i=1}^{13} m_i\, x_i + b$$

Áp dụng Hàm Sigmoid:

$$P(1) = \frac{1}{1 + e^{-Z}}$$

Sau đó ta phân loại (Outcome) bằng hàm IF để đưa ra kết quả dự đoán

$$Dự\ đoán\ = IF(P(1) \geq 0.5,1,0)$$

- File Chapter6-HW-2: Hồi quy Logistic và kiểm tra chéo

Bước 1. File này có cùng dữ liệu với Chapter6-HW-1, nhưng ta sẽ tập trung việc đánh giá mô hình bằng kỹ thuật kiểm tra chéo (Cross-validation) (là quá trình đánh giá hiệu suất mô hình trên một tập dữ liệu độc lập (Validation Set) để kiểm tra khả năng tổng quát hóa và phát hiện quá khớp (overfitting).

Bước 2. Các hệ số được tìm thấy thông qua việc tối ưu hóa trên tập huấn luyện:

Các hệ số được tìm thấy thông qua việc tối ưu hóa trên tập huấn luyện:

Biến độc lập (M_i)	**Hệ số (m_i)**
M_1	-0.00105376
M_2	0.11219145
M_3	0.10326992
M_4	0.00239557
M_5	0.00011178
M_6	-0.06789021
M_7	0.02156732
M_8	-0.00264759
M_9	0.12454064
M_{10}	0.03178865
M_{11}	0.08693642
M_{12}	0.15681922
M_{13}	0.05253964
Hệ số chặn (b)	-0.41230696

Bước 3. Bây giờ ta sẽ đánh giá hiệu suất dựa trên tập kiểm tra chéo. Áp dụng hệ số vừa tìm được vào tập kiểm tra chéo (Validation Set) để tính Log-Loss và Log-Likelihood, cũng như số lượng dự đoán sai. Để có được kết quả sau:

- Tổng Log-Loss Tối thiểu trên tập kiểm tra: 70.41722913
- Tổng Log-Likelihood Tối đa trên tập kiểm tra: -70.41722913
- Sai khác Cross-validation (Cross-validation Diff): 16 (Đây là số lượng dự đoán sai trên tập kiểm tra chéo, cho thấy mô hình dự đoán đúng trên số lượng mẫu còn lại).

END

21250015