Clustering

Nội dung

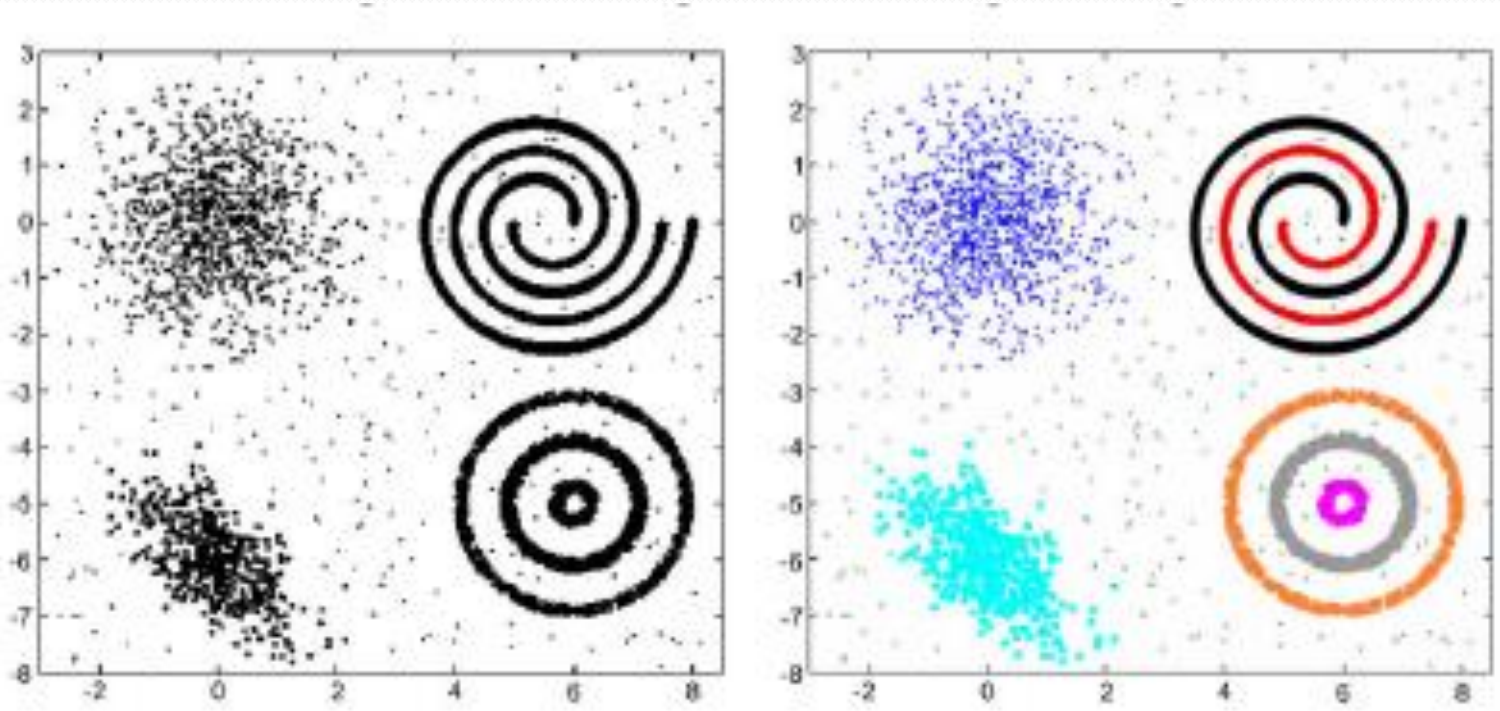
- Giới thiệu: Clustering
- Phân loại
- Thuật toán Kmeans
- Hierarchical Clustering
- Density-Based Clustering
- Bài tập

Clustering

- **Học không giám sát (Unsupervised learning)**
- Tập học (training data) bao gồm các quan sát, mà mỗi quan sát *không có thông tin về label hoặc giá trị đầu ra mong muốn*.
- Mục đích là tìm ra (học) các cụm, các cấu trúc, các quan hệ tồn tại ẩn trong tập dữ liệu hiện có.

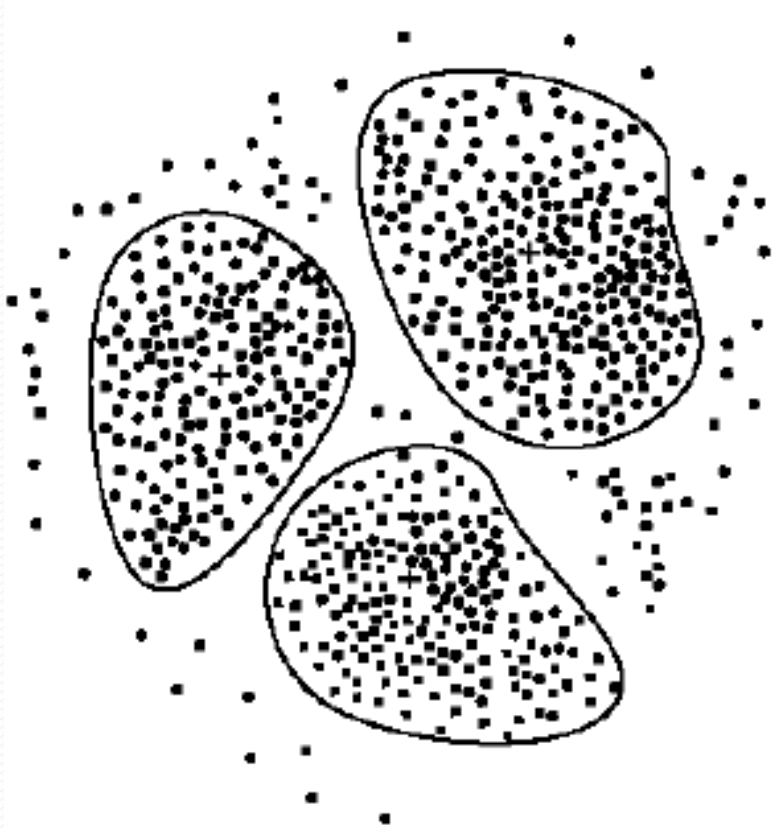
Clustering

- Phân cụm/Phân nhóm (clustering)
- Phát hiện các nhóm dữ liệu, nhóm tính chất



Clustering

- Ví dụ: Nhận diện phần tử biên (outliers) và giảm thiểu nhiễu (noisy data)



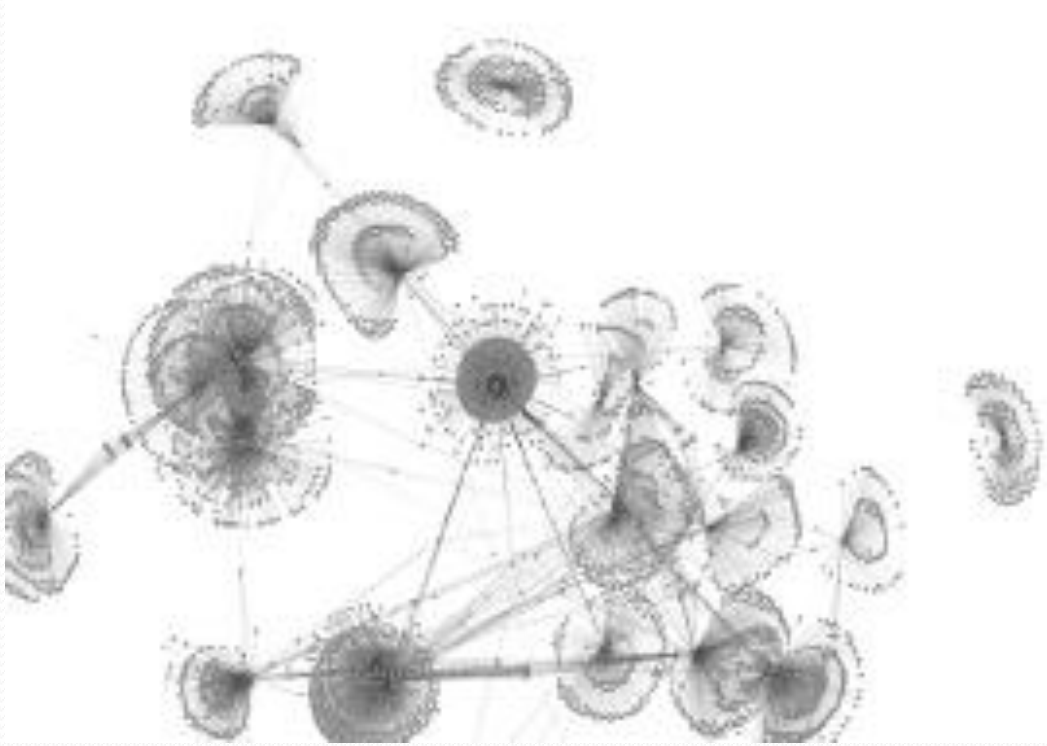
Clustering

- Ví dụ: Phân cụm ảnh



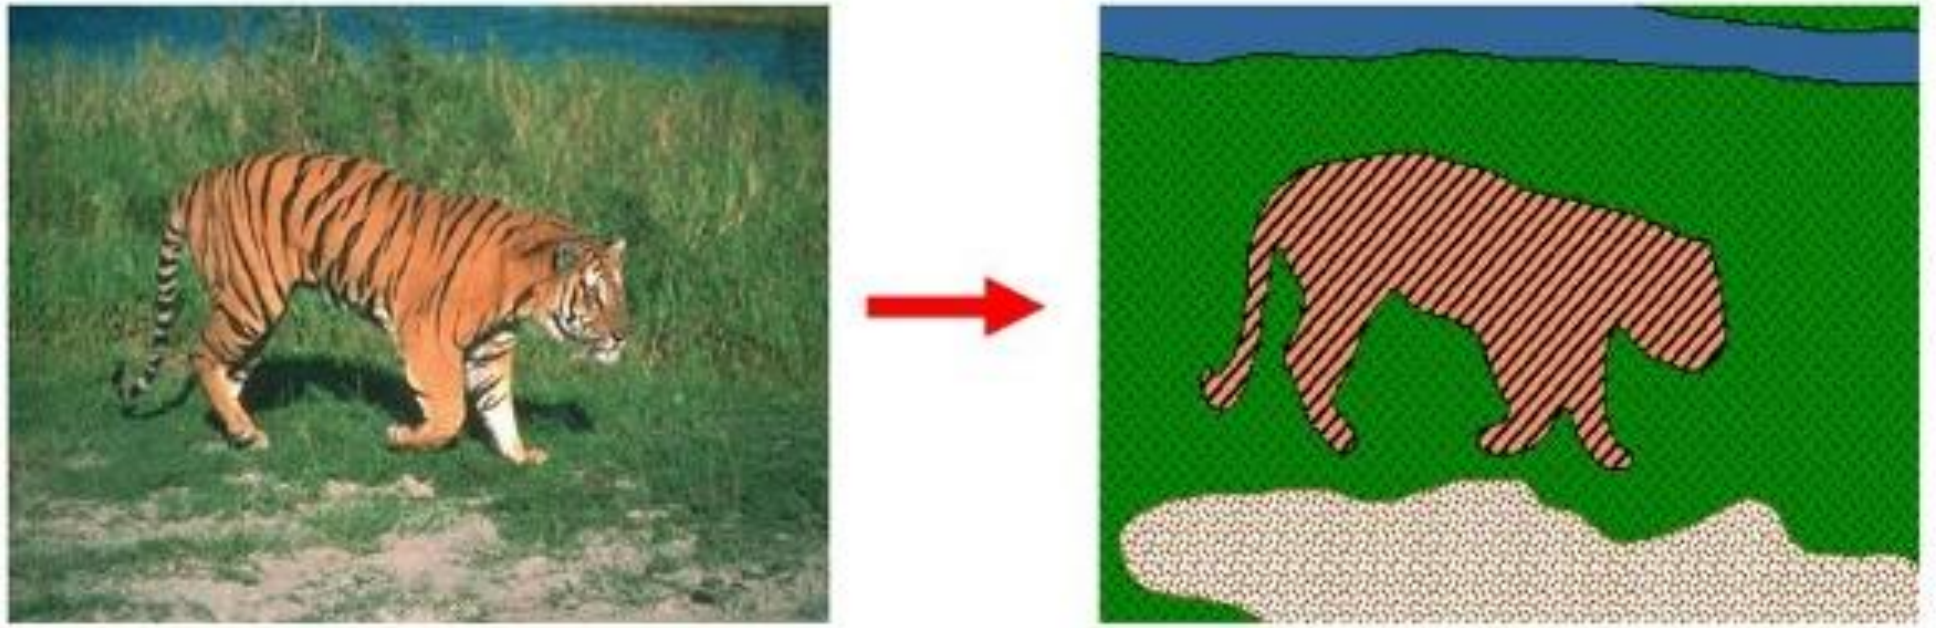
Clustering

- Ví dụ: Community detection
  - Phát hiện các cộng đồng trong mạng xã hội



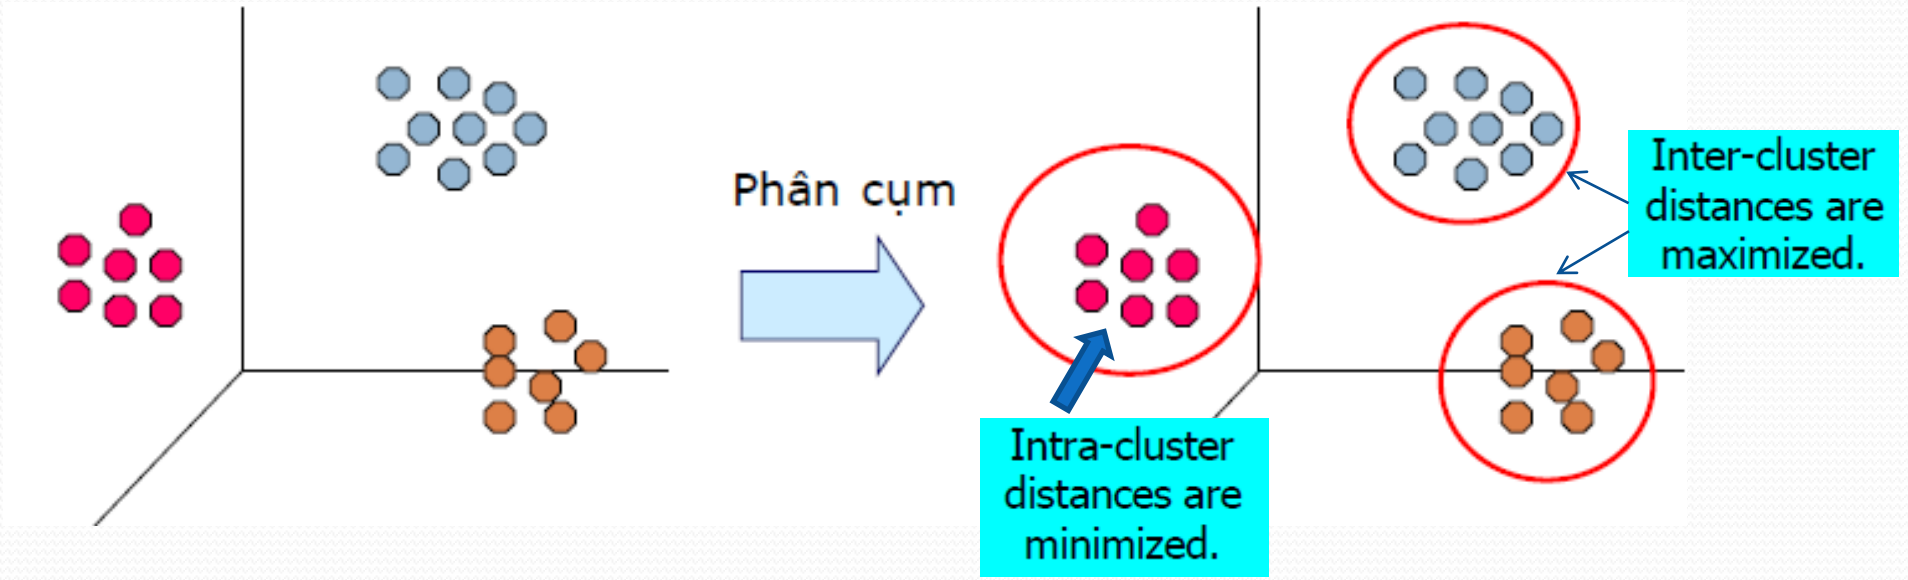
Clustering

- Ví dụ: Image segmentation



Clustering

- Clustering: là quá trình phân nhóm/cụm dữ liệu/đối tượng vào các nhóm/cụm
  - Các đối tượng trong cùng một nhóm tương tự (tương đồng) với nhau hơn so với đối tượng ở các nhóm khác.



Clustering

- Input: một tập dữ liệu $\{x_1, \ldots, x_M\}$ không có nhãn (hoặc giá trị đầu ra mong muốn)
- Output: các cụm (nhóm) của các quan sát
- Một cụm (cluster) là một tập các quan sát
  - Tương tự với nhau (theo một ý nghĩa, đánh giá nào đó)
  - Khác biệt với các quan sát thuộc các cụm khác

Clustering

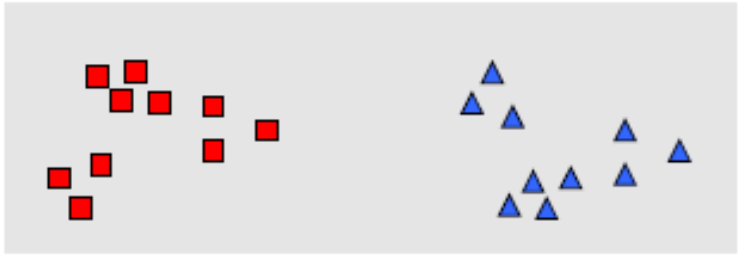
- Mỗi cụm/nhóm nên có bao nhiêu phần tử?
- Các phân tử nên được phân vào bao nhiêu cụm/nhóm?
- Bao nhiêu cụm/nhóm nên được tạo ra?



Bao nhiêu cụm?



6 cụm?



2 cụm?



4 cụm?

Clustering

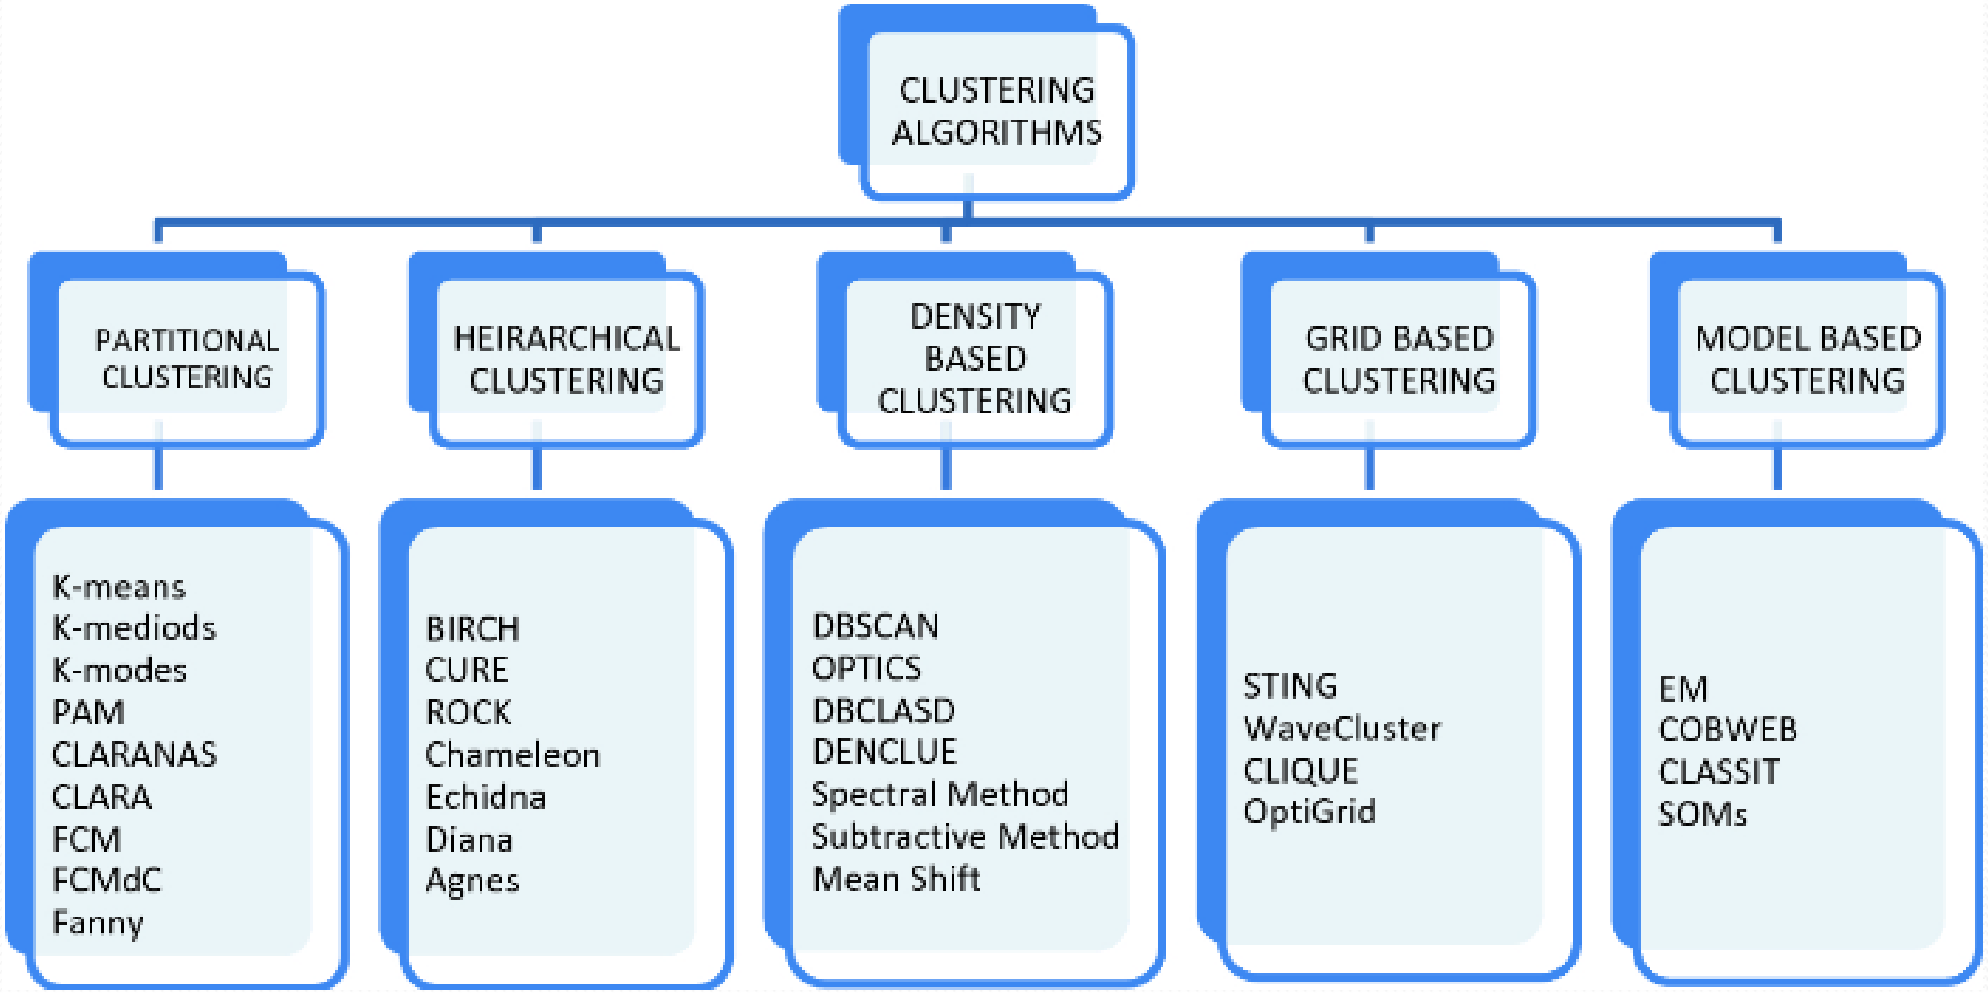
- Các yêu cầu khi thiết kế thuật toán phân cụm dữ liệu:

- Có thể tương thích, hiệu quả với dữ liệu lớn, số chiều lớn
- Có khả năng xử lý các dữ liệu khác nhau
- Có khả năng khám phá các cụm với các dạng bất kỳ
- Khả năng thích nghi với dữ liệu nhiễu
- Ít nhạy cảm với thứ tự của các dữ liệu vào
- Phân cụm rằng buộc
- Dễ hiểu và dễ sử dụng

Clustering

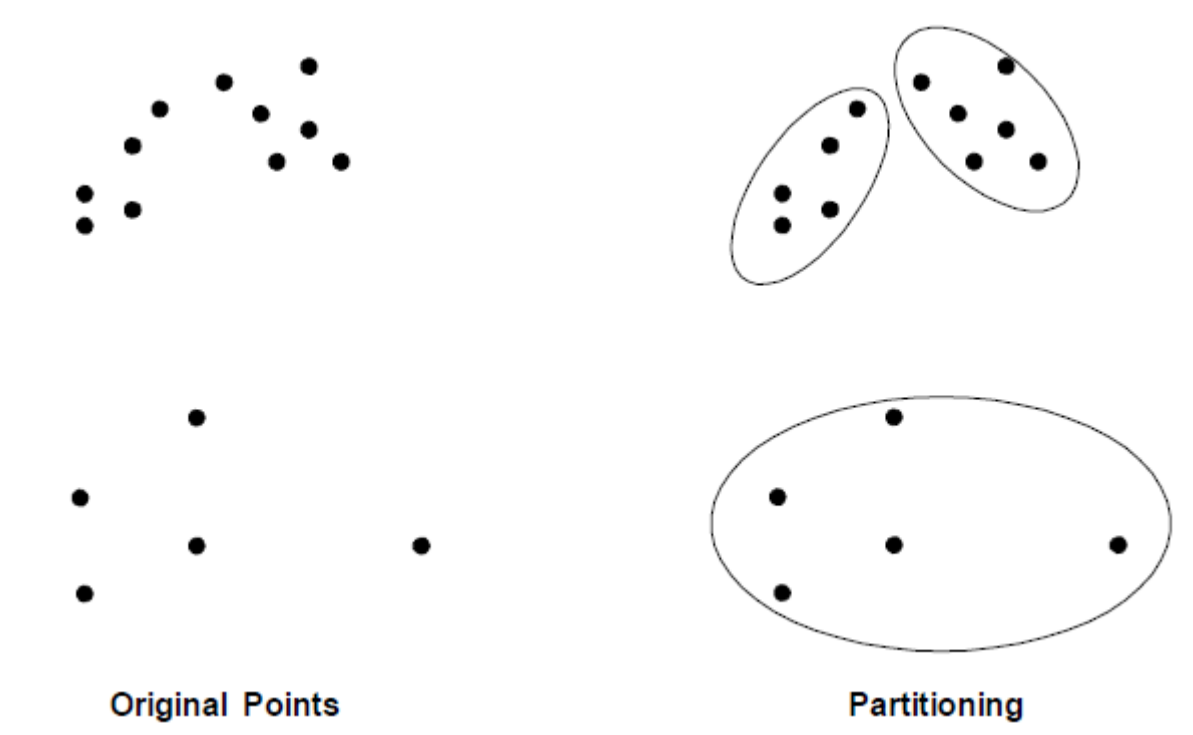
- Phân loại các phương pháp clustering
- Phân hoạch (partitioning): phân hoạch tập dữ liệu n phần tử thành k cụm
  - **Kmeans, Fuzzy C-mean,...**
- Phân cấp (hierarchical): xây dựng phân cấp các cụm trên cơ sở các đối tượng dữ liệu đang xem xét
  - **AGNES (Agglomerative NESting), DIANA (Divisive ANAlysis) ,...**
- Dựa trên mật độ (density-based): dựa trên hàm mật độ, số đối tượng lân cận của đối tượng dữ liệu.
  - **DBSCAN, OPTICS, MeanShift ,...**
- Dựa trên mô hình (model-based): một mô hình giả thuyết được đưa ra cho mỗi cụm; sau đó hiệu chỉnh các thông số để mô hình phù hợp với cụm dữ liệu/đối tượng nhất.
  - **EM, SOMs ,...**
- Spectral clustering **: phân cụm dựa trên đồ thị**
- **...**

Clustering


CLUSTERING ALGORITHMS
PARTITIONAL CLUSTERING
HEIRARCHICAL CLUSTERING
DENSITY BASED CLUSTERING
GRID BASED CLUSTERING
MODEL BASED CLUSTERING
K-means
K-mediods
K-modes
PAM
CLARANAS
CLARA
FCM
FCMdC
Fanny
BIRCH
CURE
ROCK
Chameleon
Echidna
Diana
Agnes
DBSCAN
OPTICS
DBCLASD
DENCLUE
Spectral Method
Subtractive Method
Mean Shift
STING
WaveCluster
CLIQUE
OptiGrid
EM
COBWEB
CLASSIT
SOMs

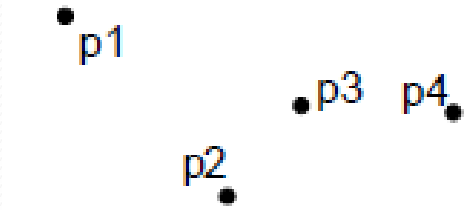
Clustering

- Ví dụ: Phân hoạch (partitioning)

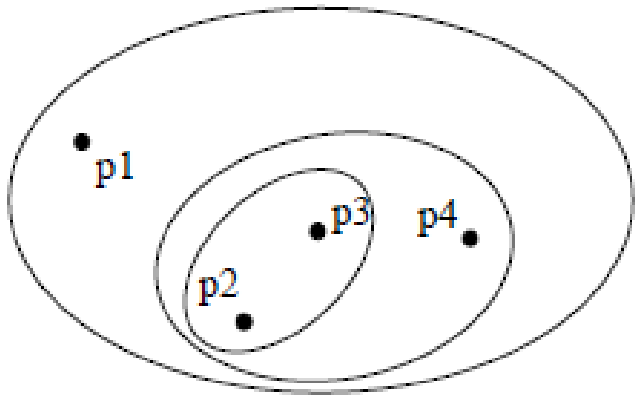


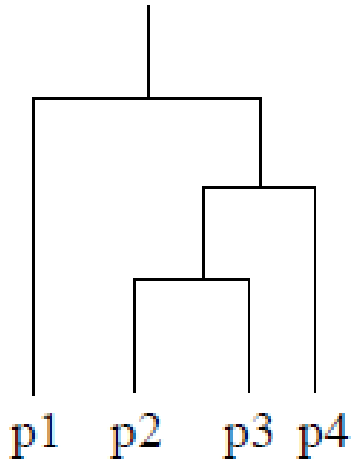
Clustering

- Ví dụ: Phân cấp (hierarchical)



Original Points



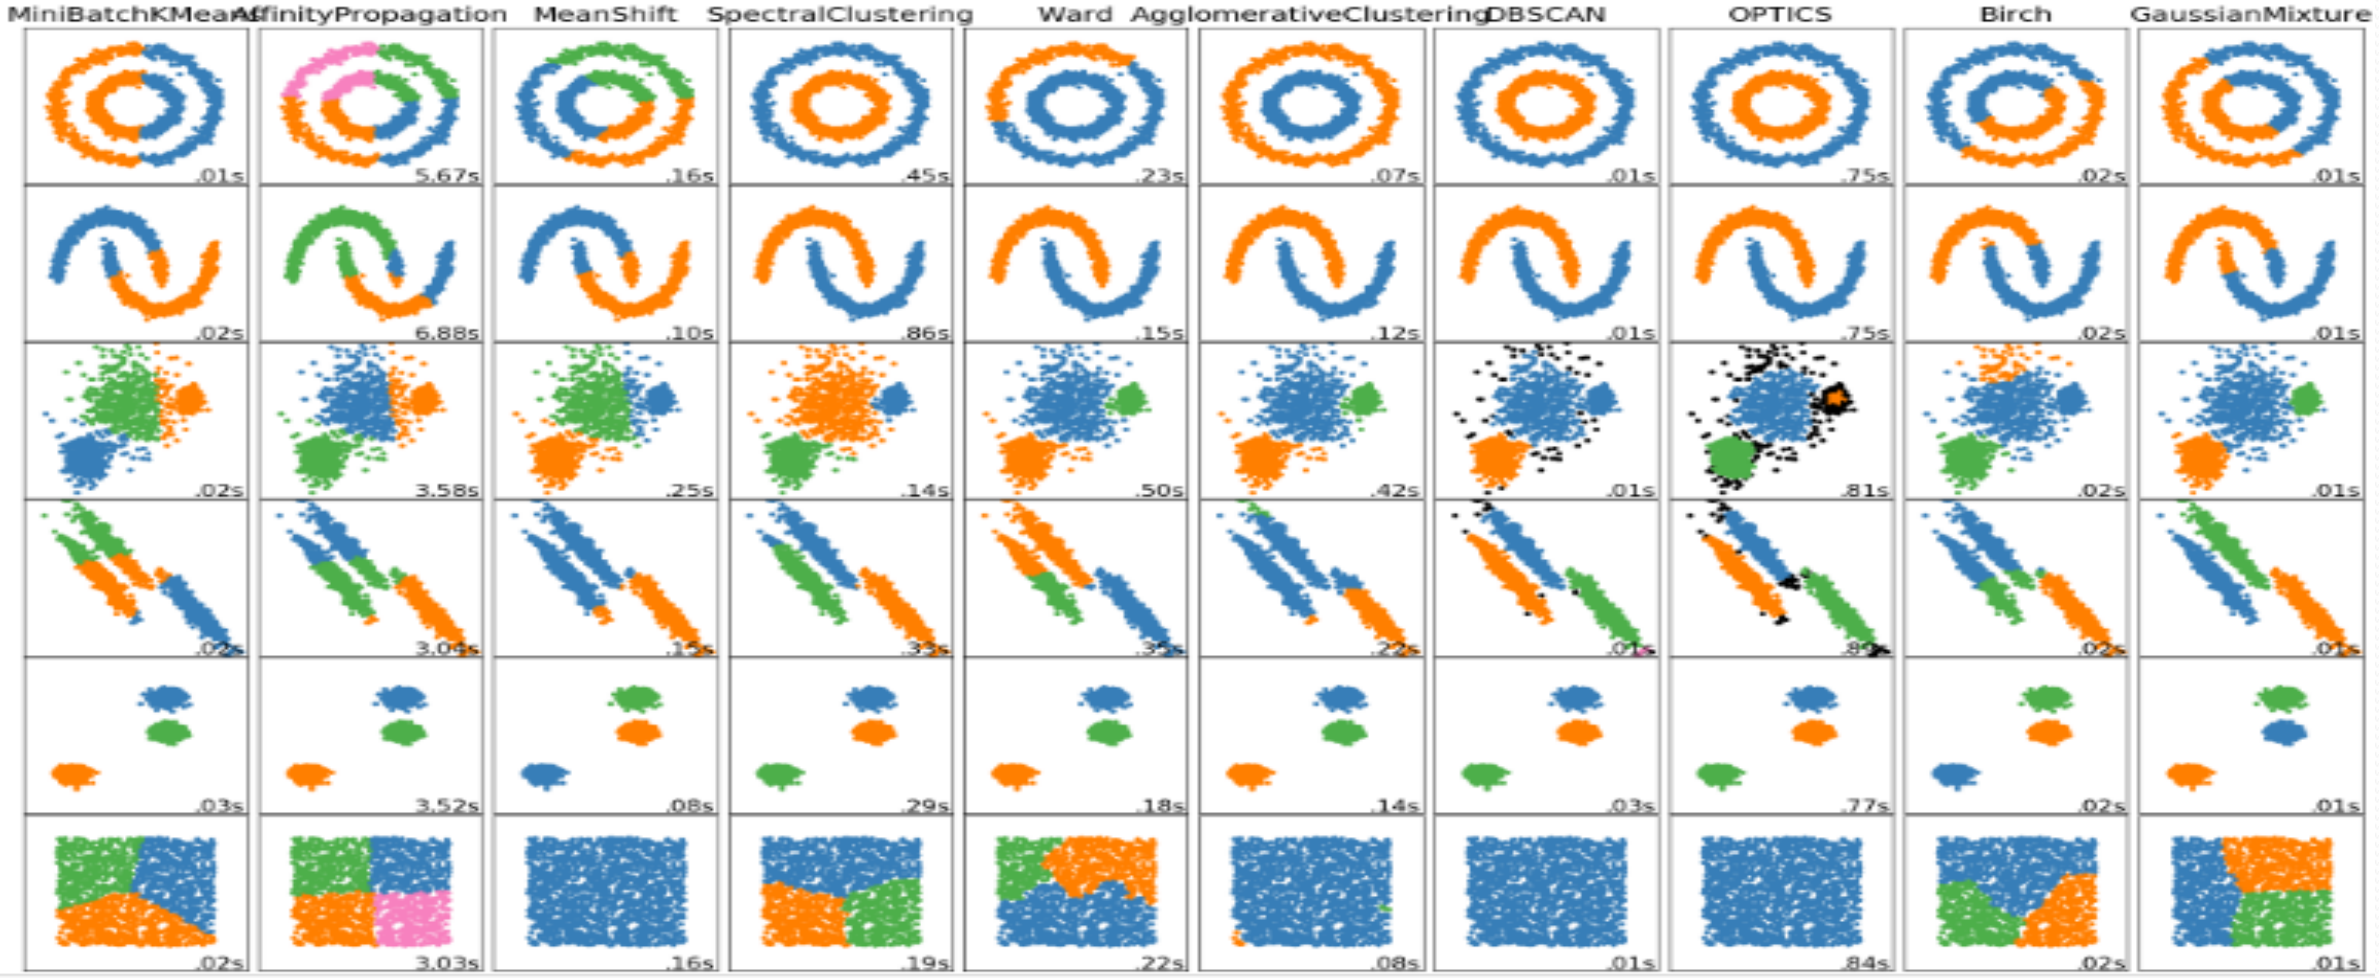


Hierarchical

Clustering

- Đánh giá chất lượng phân cụm (Clustering quality)
  - Khoảng cách/sự khác biệt *giữa các cụm* → *Cần được cực đại hóa*
  - Khoảng cách/sự khác biệt *bên trong một cụm* → *Cần được cực tiểu hóa*

Clustering : Example



https://scikit-learn.org/stable/modules/clustering.html

Kmeans

- K-means được giới thiệu đầu tiên bởi Lloyd năm 1957
- Là phương pháp phân cụm phổ biến nhất trong các phương pháp dựa trên phân hoạch (partition-based clustering)
- Giải thuật K-means phân chia tập dữ liệu thành *k cụm*
  - Mỗi cụm (cluster) có một điểm trung tâm/ trọng tâm, được gọi là **centroid**
  - *k (tổng số các cụm thu được) là một giá trị được cho trước*

  (vd: được chỉ định bởi người thiết kế hệ thống phân cụm)
  - Một đối tượng được phân vào một cụm nếu khoảng cách từ đối tượng đó đến trọng tâm của cụm đang xét là nhỏ nhất
  - Quá trình lặp đi lặp lại cho đến hàm mục tiêu bé hơn một ngưỡng cho phép hoặc các trọng tâm không đổi

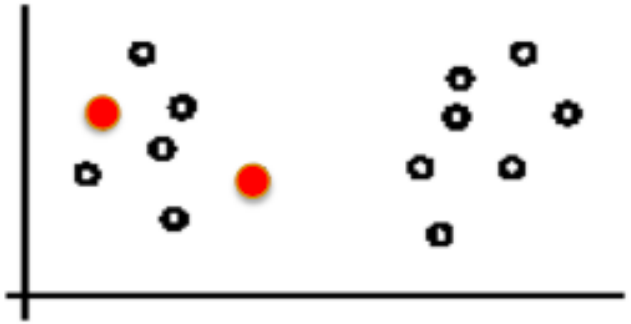
$$E = \sum_{i=1}^{k} \sum_{p \in C_i} |p - m_i|$$

Kmeans

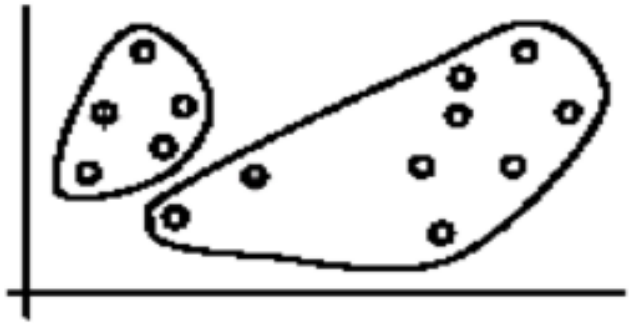
- Algorithm:
- Input:
  - tập học $D=\{x_1,x_2,...,x_r\}$ (x_i *là một quan sát - một vectơ trong một không gian n chiều)*)
  - số lượng cụm *k*
  - *khoảng cách d(x,y)*
- Step 1. Chọn ngẫu nhiên *k quan sát* **để sử dụng làm *các điểm trung tâm*** *ban đầu (initial centroids) của k cụm.*
- Step 2. Lặp liên tục hai bước sau cho đến khi *gặp điều kiện hội tụ (convergence criterion):*
  - 2.1. Đối với mỗi quan sát, *gán nó vào cụm (trong số k* cụm) mà có tâm (centroid) gần nó nhất.
  - 2.2. Đối với mỗi cụm, *tính toán lại điểm trung tâm của nó dựa trên tất cả các quan sát thuộc vào cụm đó.*

Kmeans

- Ví dụ:



(A). Random selection of k centers



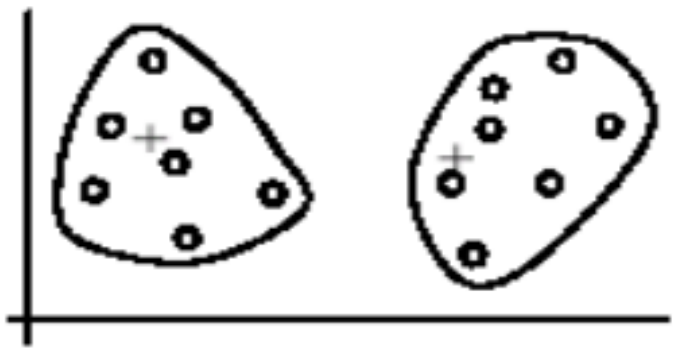
Iteration 1: (B). Cluster assignment



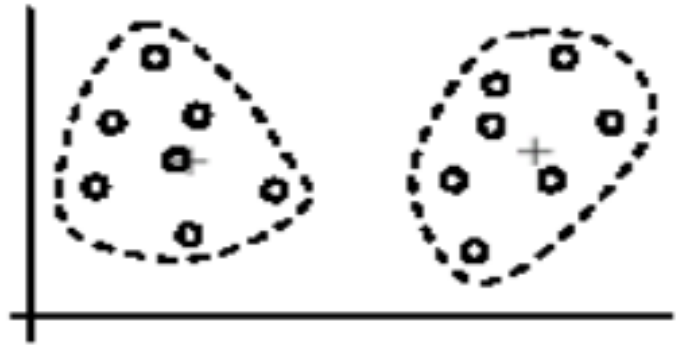
(C). Re-compute centroids

Kmeans

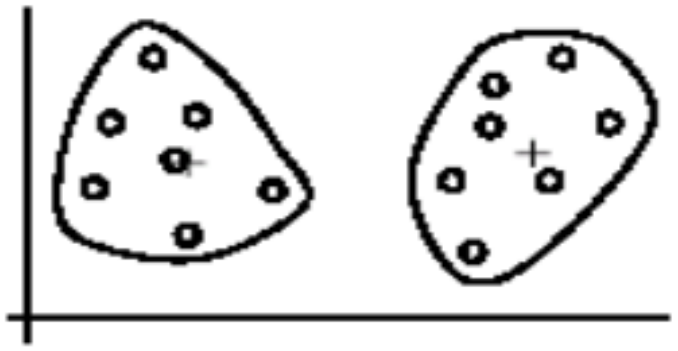
- Ví dụ:



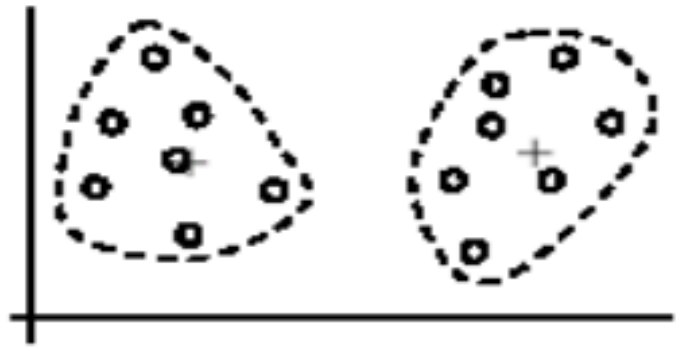
Iteration 2: (D). Cluster assignment



(E). Re-compute centroids



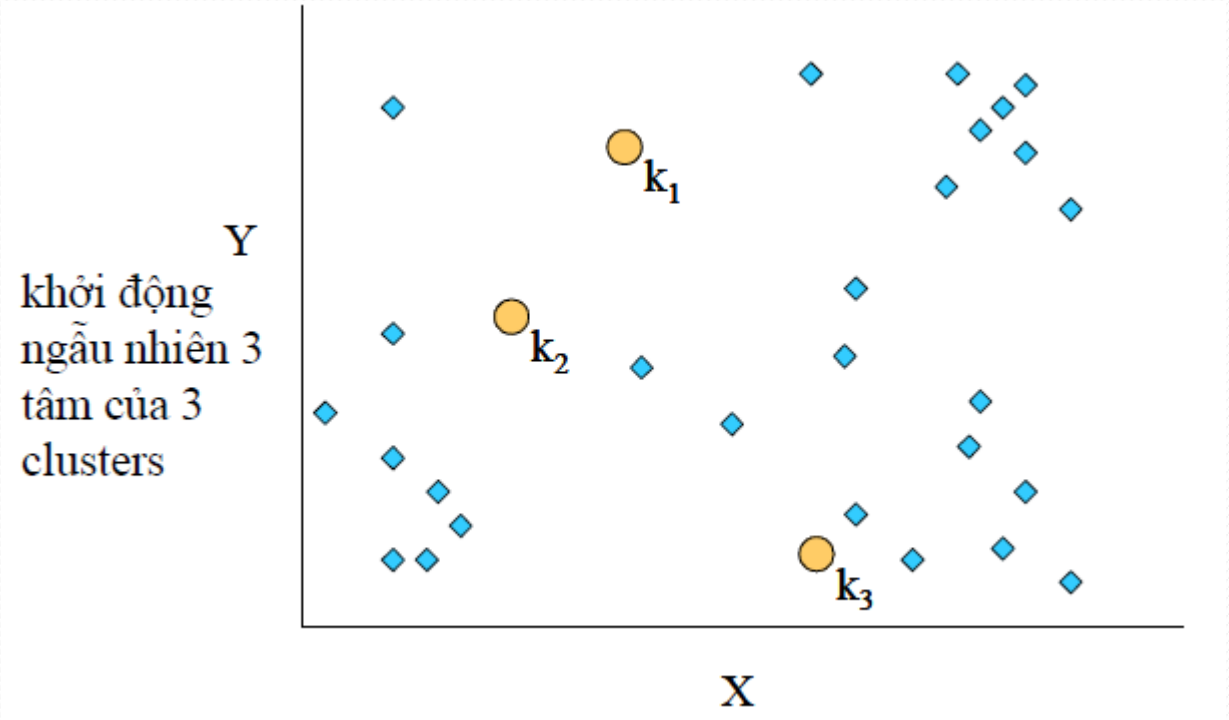
Iteration 3: (F). Cluster assignment



(G). Re-compute centroids

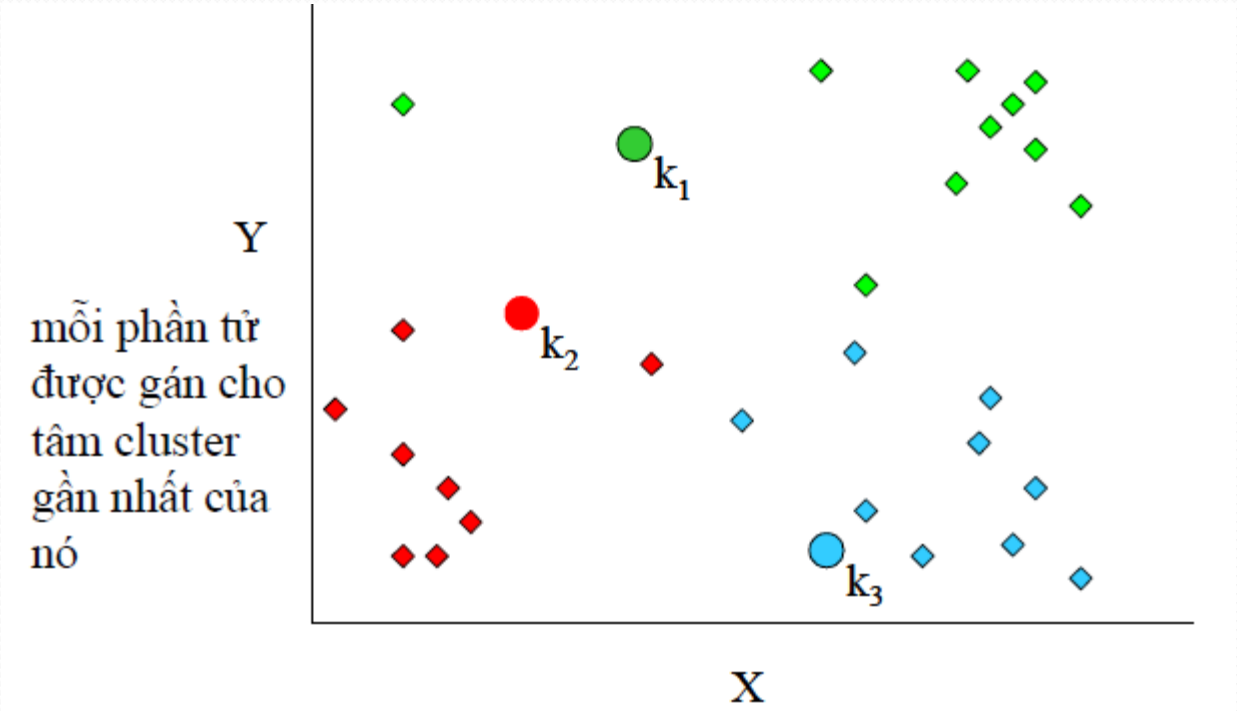
Kmeans

- Ví dụ:



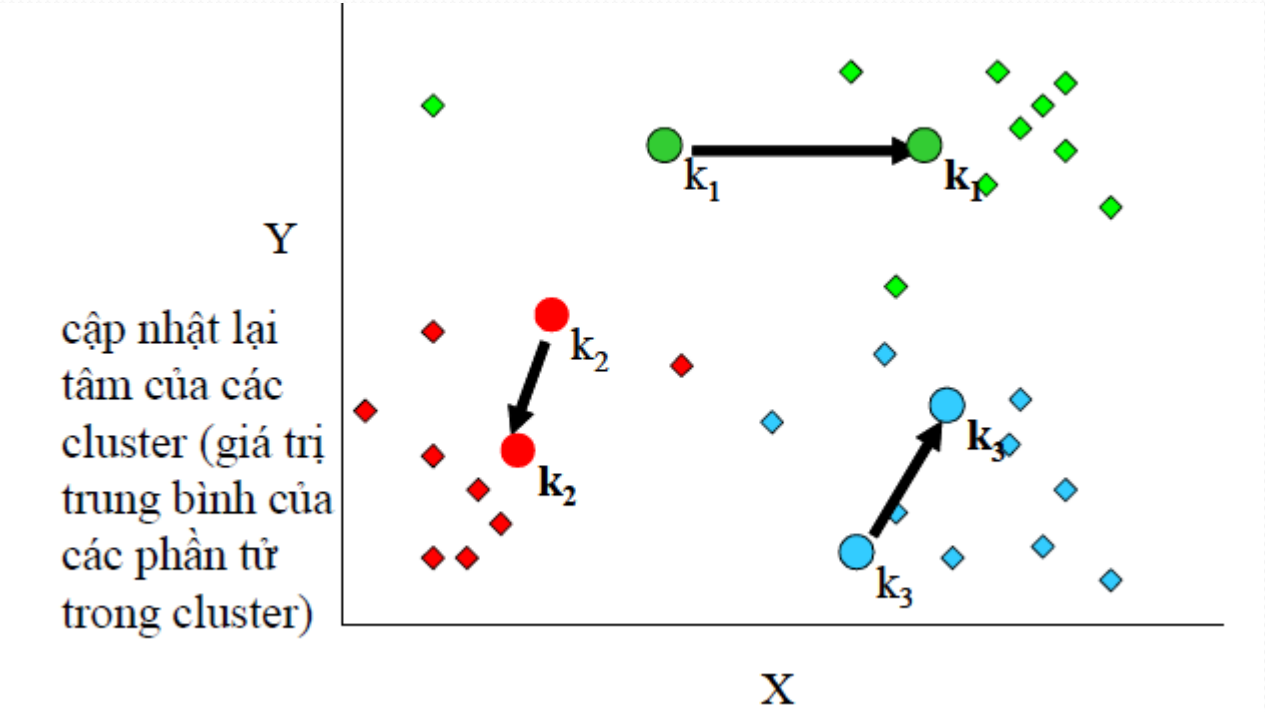
Kmeans

- Ví dụ:



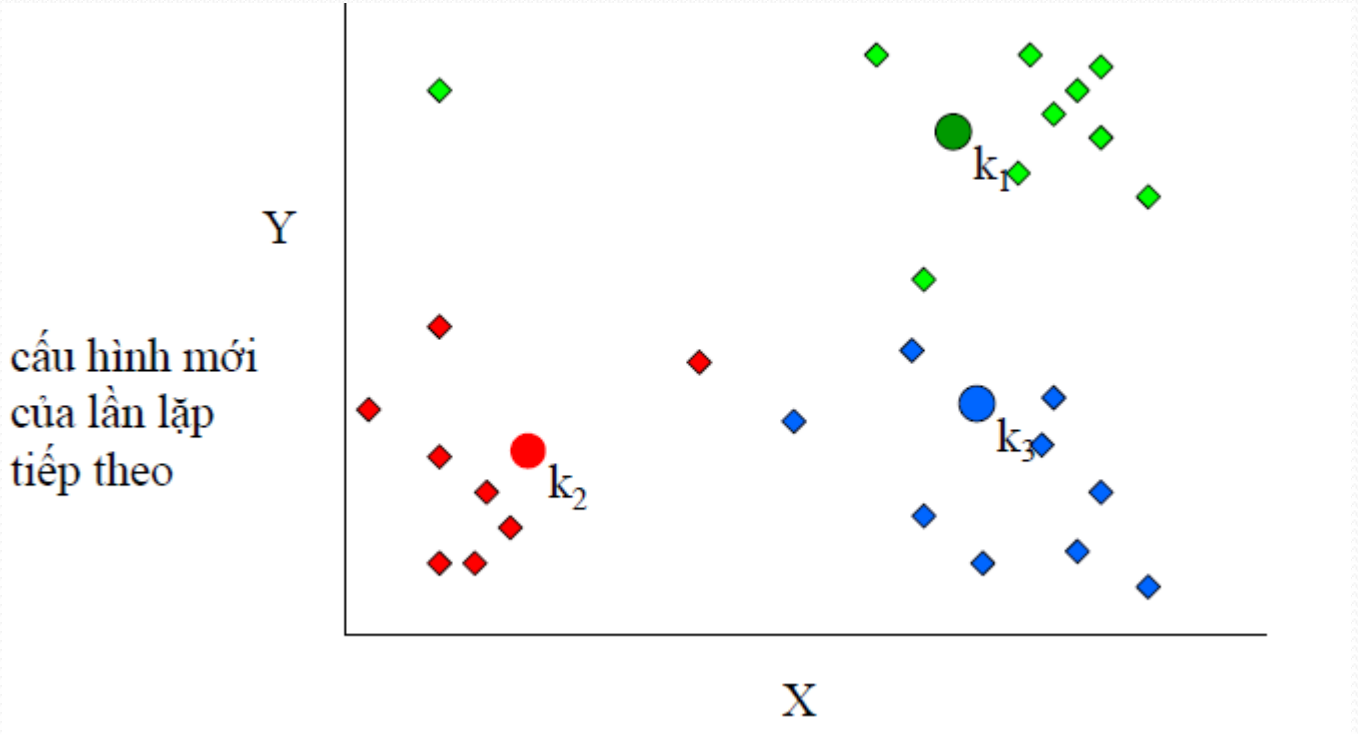
Kmeans

- Ví dụ:


Y
cập nhật lại tâm của các cluster (giá trị trung bình của các phần tử trong cluster)
k1
k1
k2
k2
k3
k3
X

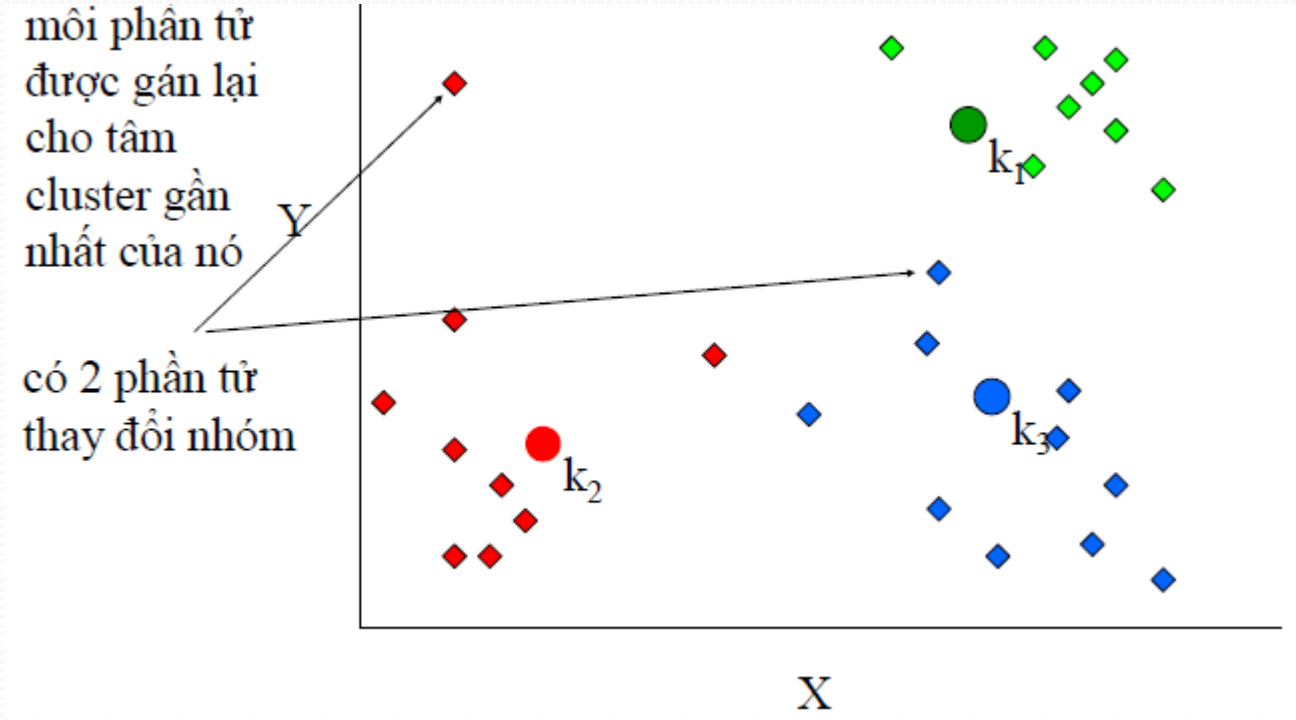
Kmeans

- Ví dụ:



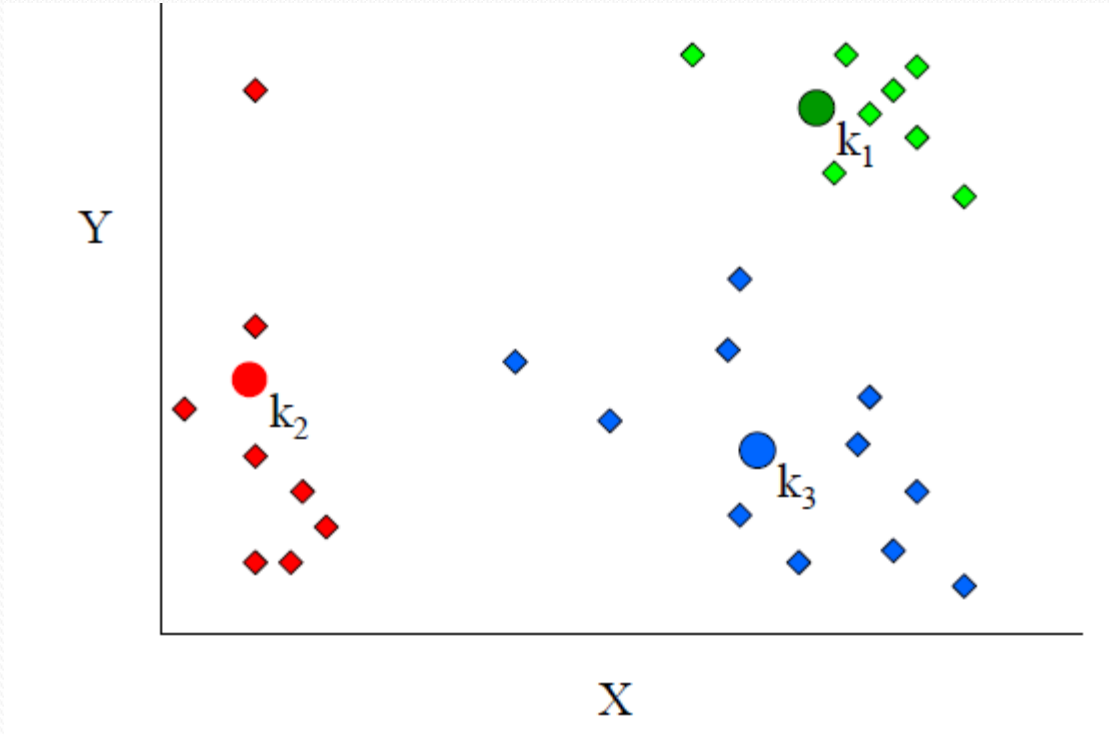
Kmeans

- Ví dụ:


môi phần tử
được gán lại
cho tâm
cluster gần
nhất của nó
có 2 phần tử
thay đổi nhóm
Y
X
k1
k2
k3

Kmeans

- Ví dụ:



Kmeans

- *Convergence criterion* :
- Quá trình phân cụm kết thúc, nếu:
  - Không có (hoặc có không đáng kể) việc gán lại các quan sát vào các cụm khác, *hoặc*
  - Không có (hoặc có không đáng kể) thay đổi về các điểm trung tâm (centroids) của các cụm, *hoặc*
  - Giảm không đáng kể về tổng lỗi phân cụm

$$Error = \sum_{i=1}^{k} \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{m_i})^2$$

- C_i: Cụm thứ i
- $\mathbf{m_i}$: Điểm trung tâm (centroid) của cụm C_i
- $d(\mathbf{x}, \mathbf{m}_i)$: Khoảng cách (khác biệt) giữa quan sát $\mathbf{x}$ và điểm trung tâm $\mathbf{m}_i$

Kmeans

- Centroids:
- Xác định điểm trung tâm: Điểm trung bình (*Mean centroid)*

$$\mathbf{m_i} = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$$

- (vectơ) $\boldsymbol{m_i}$ là điểm trung tâm (centroid) của cụm C_i
- $|C_i|$ kích thước của cụm C_i (tổng số quan sát trong C_i)

Kmeans

- Distance function

khoảng cách *Minkowski*

$$d(i,j)=\sqrt[q]{(|x_{i1}-x_{j1}|^q+|x_{i2}-x_{j2}|^q+...+|x_{ip}-x_{jp}|^q)}$$

$i = (x_{i1}, x_{i2}, \ldots, x_{ip})$ và $j = (x_{j1}, x_{j2}, \ldots, x_{jp})$ là 2 phần tử dữ liệu trong p-dimensional, q là số nguyên dương

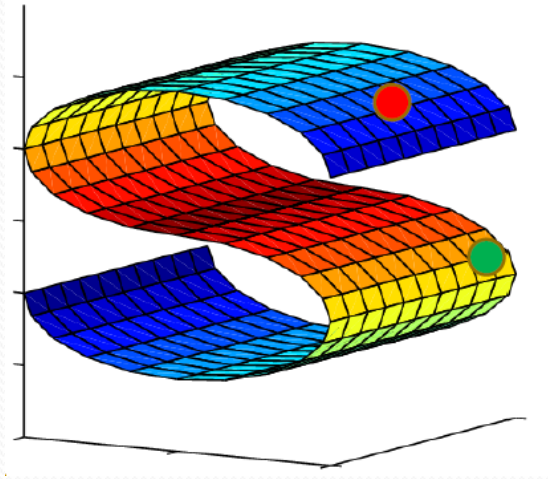
nếu $q = 1$, d là khoảng cách Manhattan

nếu $q = 2$, d là khoảng cách Euclid

khoảng cách cosine : $d_{cos}(i, j) = i^T j/(||i|| \, ||j||)$

Kmeans

- Distance function
  - Mỗi hàm sẽ tương ứng với một cách nh.n về dữ liệu.
  - Chọn hàm nào?
- Có thể thay bằng độ đo tương đồng (similarity measure)



Euclidean vs. Manhattan distance



Kmeans

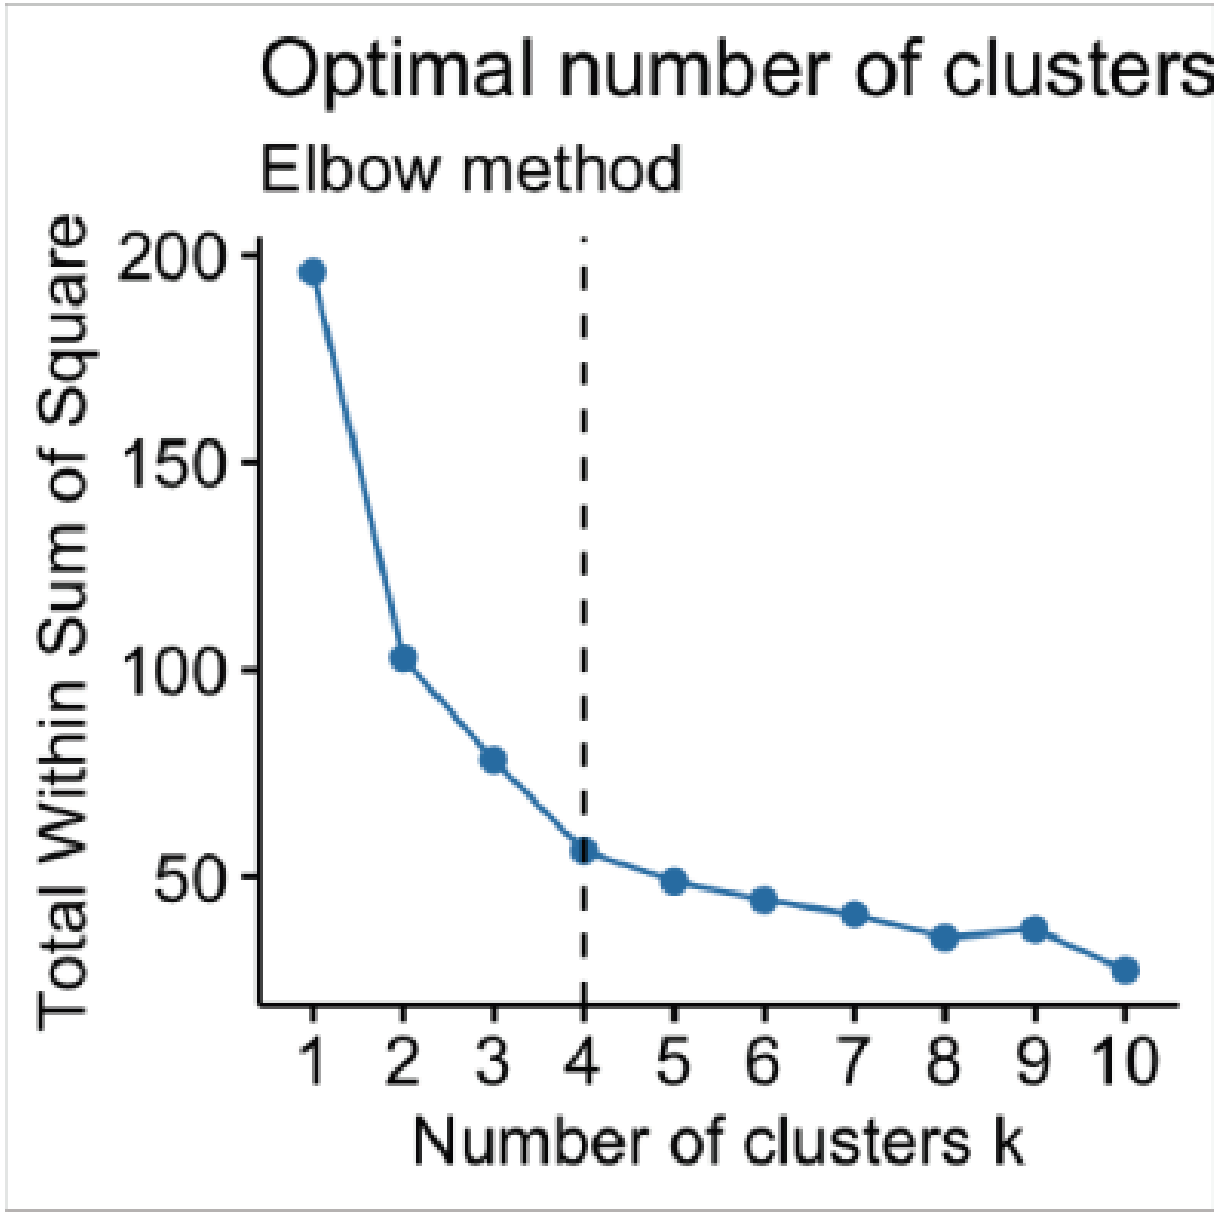
- Pros:
  - Đơn giản: dễ cài đặt, rất dễ hiểu
  - Rất linh động: cho phép dùng nhiều độ đo khoảng cách khác nhau
  - K-means thường phù hợp với các cụm hình cầu
  - được dùng phổ biến nhất
- Cons:
  - Phải xác định số cụm trước
  - Không thể xử lý nhiễu và ngoại lai
  - Phụ thuộc vào việc chọn các điểm trung tâm ban đầu (initial centroids)

Kmeans

- How to choose k?

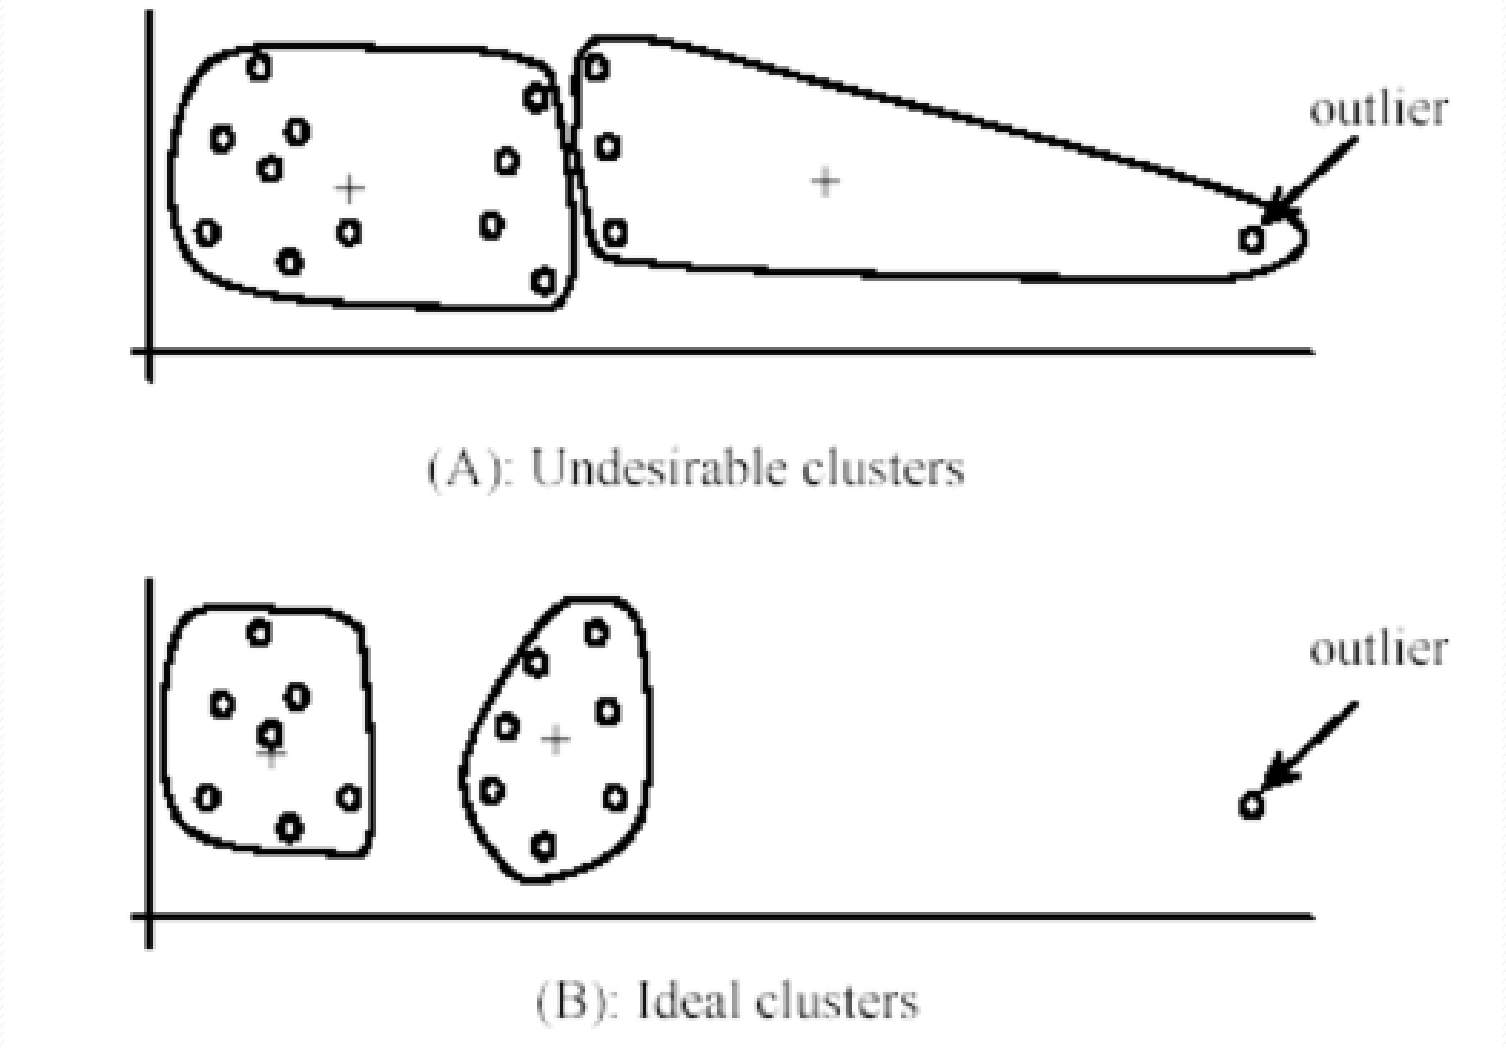
$$Error = \sum_{i=1}^{k} \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{m_i})^2$$

The location of a bend (knee) in the plot is generally considered as an indicator of the appropriate number of clusters.



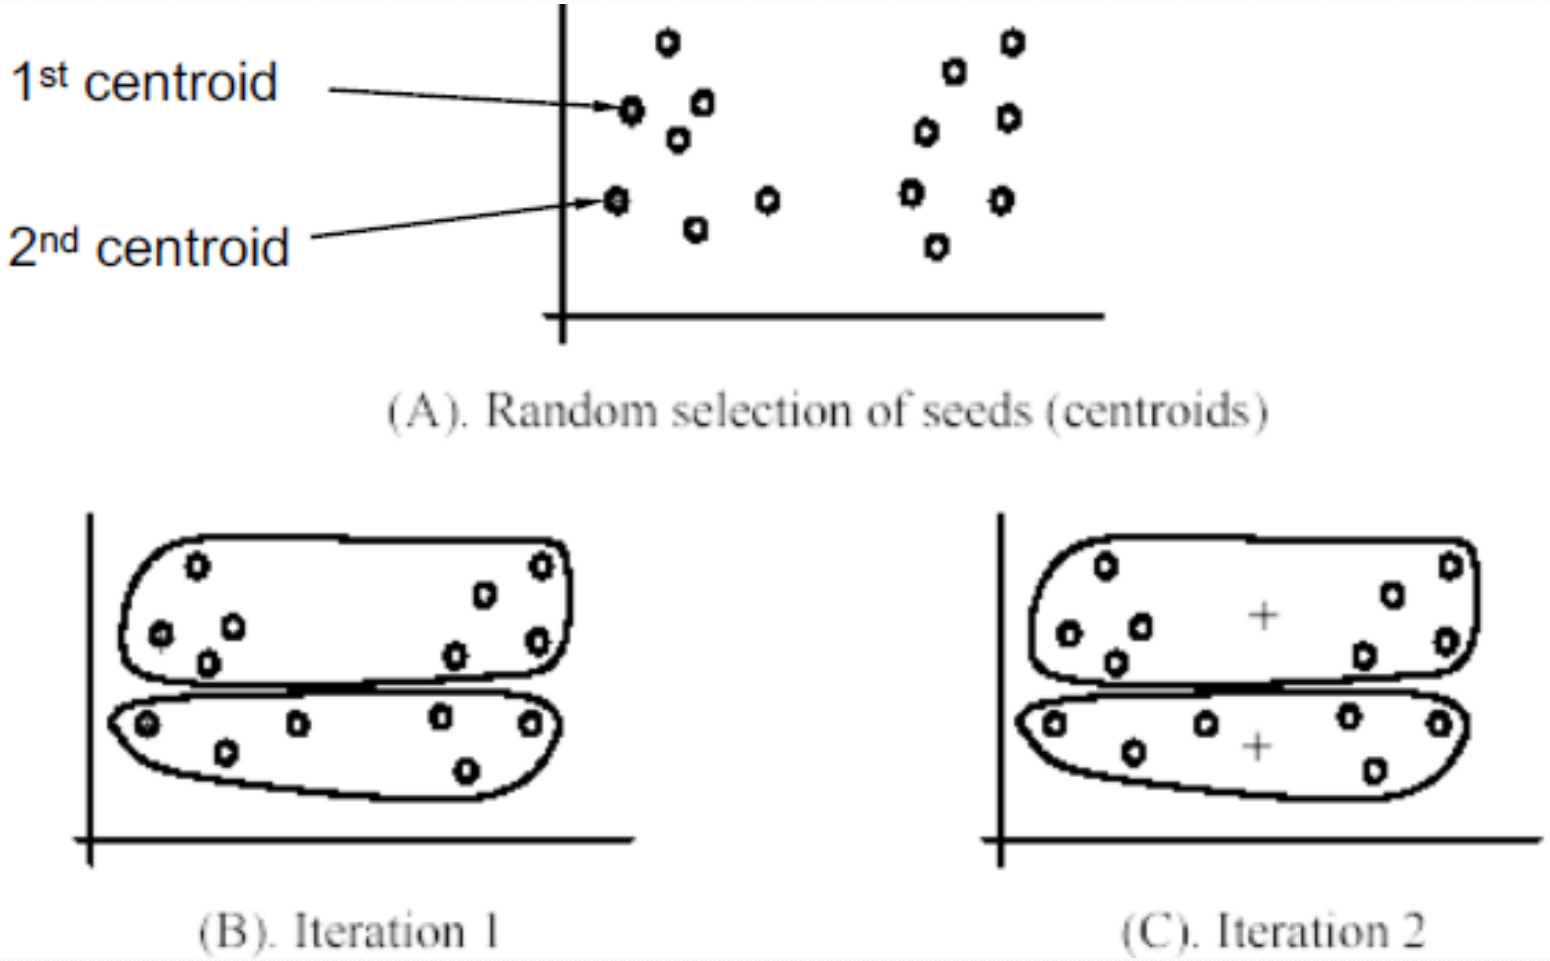
Kmeans

- Outlier



Kmeans

- Initial centroids



(A). Random selection of seeds (centroids)

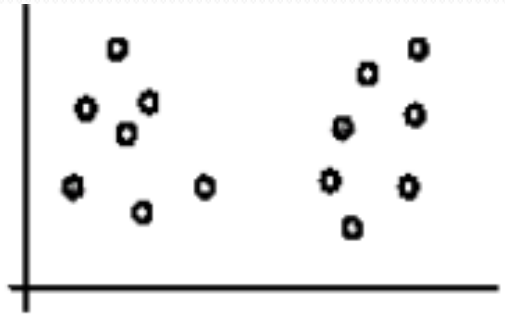
(B). Iteration 1

(C). Iteration 2

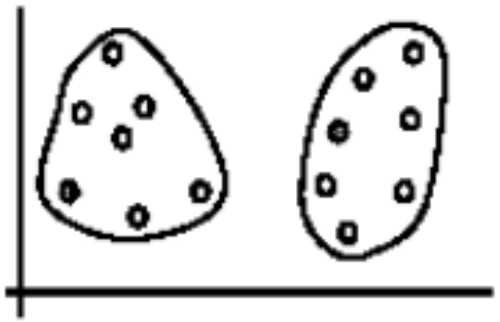
Kmeans

- Initial centroids

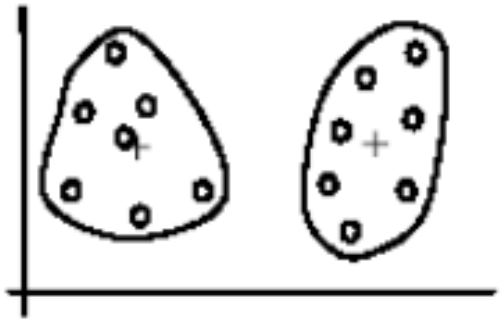
Kết hợp nhiều kết quả phân cụm với nhau → Kết quả tốt hơn!



(A). Random selection of k seeds (centroids)



(B). Iteration 1



(C). Iteration 2

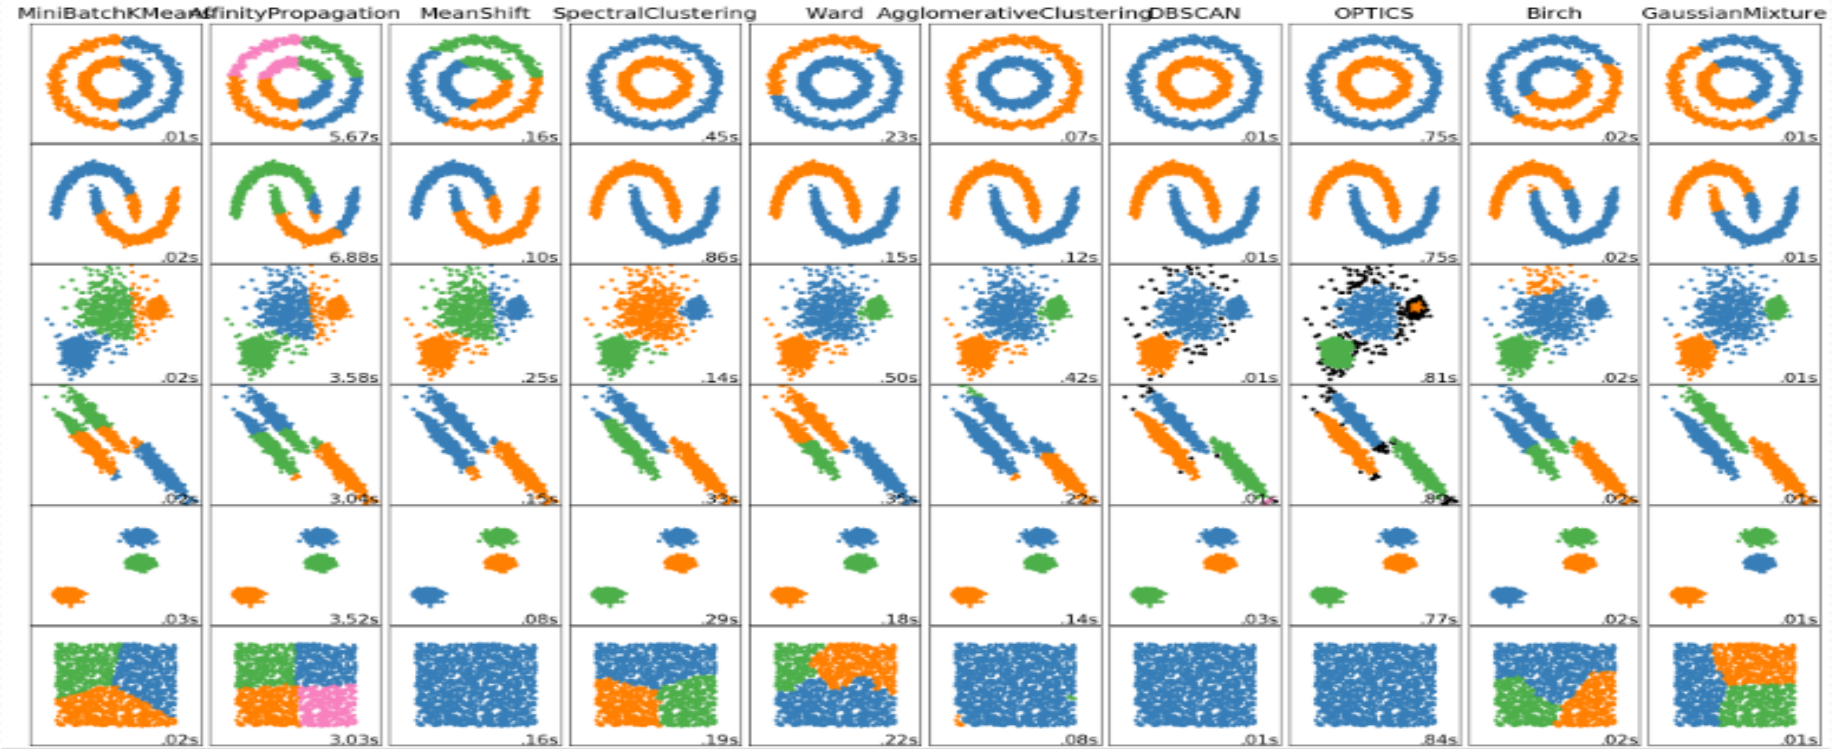
Kmeans

- Initial centroids
- Cải tiến : kmeans ++
- Idea:
  - Lựa chọn ngẫu nhiên hạt nhân thứ 1 (m1)
  - Lựa chọn hạt nhân thứ 2 (m2) càng xa càng tốt so với hạt nhân thứ 1 …

  ...
  - Lựa chọn hạt nhân thứ i (mi) càng xa càng tốt so với hạt nhân gần nhất trong số {m1, m2, … , mi-1}

Kmeans

- K-means (với khoảng cách Euclid) phù hợp với các cụm hình cầu.
- *K-means không phù hợp để phát hiện các cụm (nhóm) không có dạng hình cầu.*



Kmeans

- Online kmeans
- K-means:
  - Cần dùng toàn bộ dữ liệu tại mỗi bước lặp
  - Do đó không thể làm việc khi dữ liệu quá lớn (big data)
  - Không phù hợp với luồng dữ liệu (stream data, dữ liệu đến liên tục)
- *Online K-means cải thiện nhược điểm của K-means cho* phép ta phân cụm dữ liệu rất lớn, hoặc phân cụm luồng dữ liệu.
  - Online learning
  - Stochastic gradient descent

Online Kmeans based SGD

- Loss function

$$Q(w) = \sum_{i=1}^{M} \| x_i - w(x_i) \|_2^2$$

Trong đó $w(x_i)$ là tâm gần nhất với x_i.

Khởi tạo K tâm ban đầu.

Cập nhật các tâm mỗi khi một điểm dữ liệu mới đến:

- *Tại bước t, lấy một quan sát x_t .*
- *Tìm tâm w_t gần nhất với x_t. Sau đó cập nhật lại w_t như sau:*

$$w_{t+1} = w_t + \gamma_t (x_t - w_t)$$

Hierarchical Clustering

- Idea :
  - Xuất phát mỗi cụm có một đối tượng (nếu có n đối tượng thì sẽ có n cụm).
  - Tiếp theo, tiến hành góp các cụm cặp hai đối tượng có **khoảng cách bé nhất**.
  - Quá trình ghép cặp tiến hành lặp cho đến khi các cụm được ghép thành một cụm duy nhất.

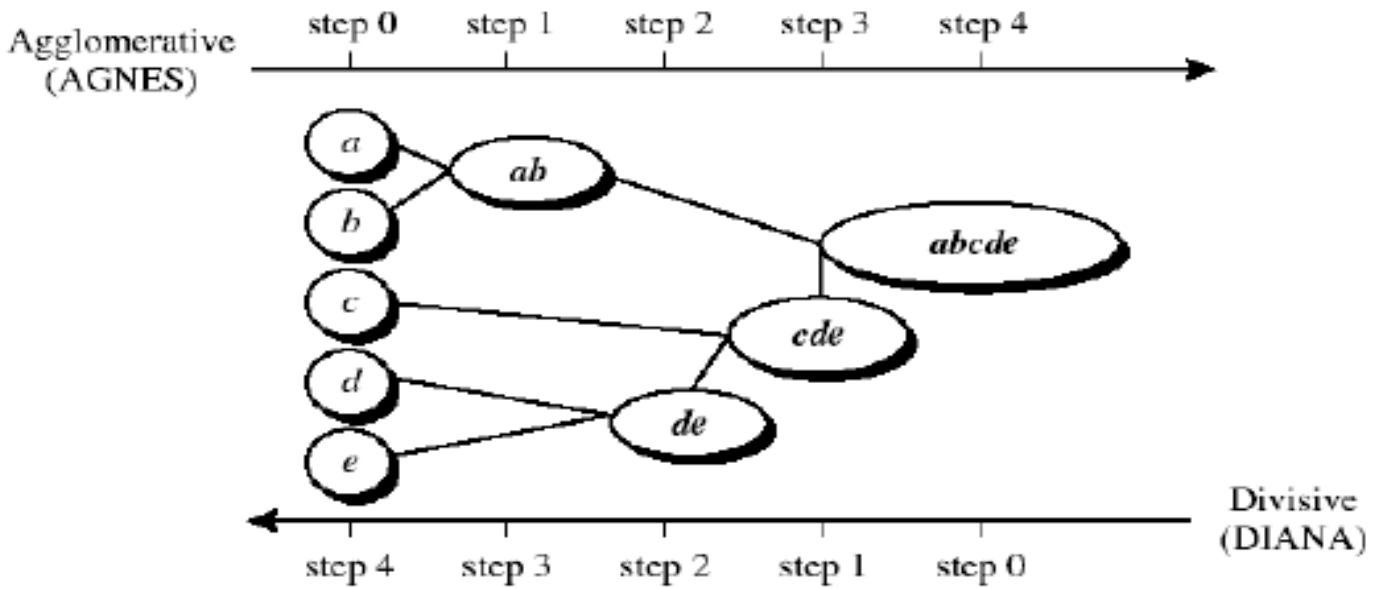
Hierarchical Clustering

- Phân cụm dữ liệu bằng phân cấp (hierarchical clustering): nhóm các đối tượng vào cây phân cấp của các cụm
  - Agglomerative: bottom-up (trộn các cụm)
  - Divisive: top-down (phân tách các cụm)
- Không yêu cầu thông số nhập k (số cụm)
- Yêu cầu điều kiện dừng
- Không thể quay lui ở mỗi bước trộn/phân tách

Hierarchical Clustering

An agglomerative hierarchical clustering method: AGNES (Agglomerative NESting) → bottom-up

A divisive hierarchical clustering method: DIANA (Divisive ANAlysis) → top-down

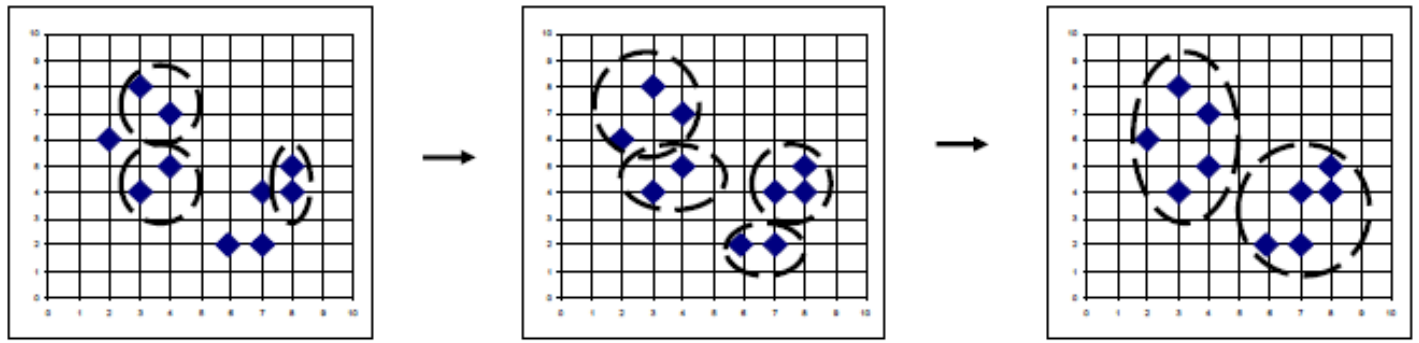


Agglomerative and divisive hierarchical clustering on data objects $\{a, b, c, d, e\}$.

Hierarchical Clustering

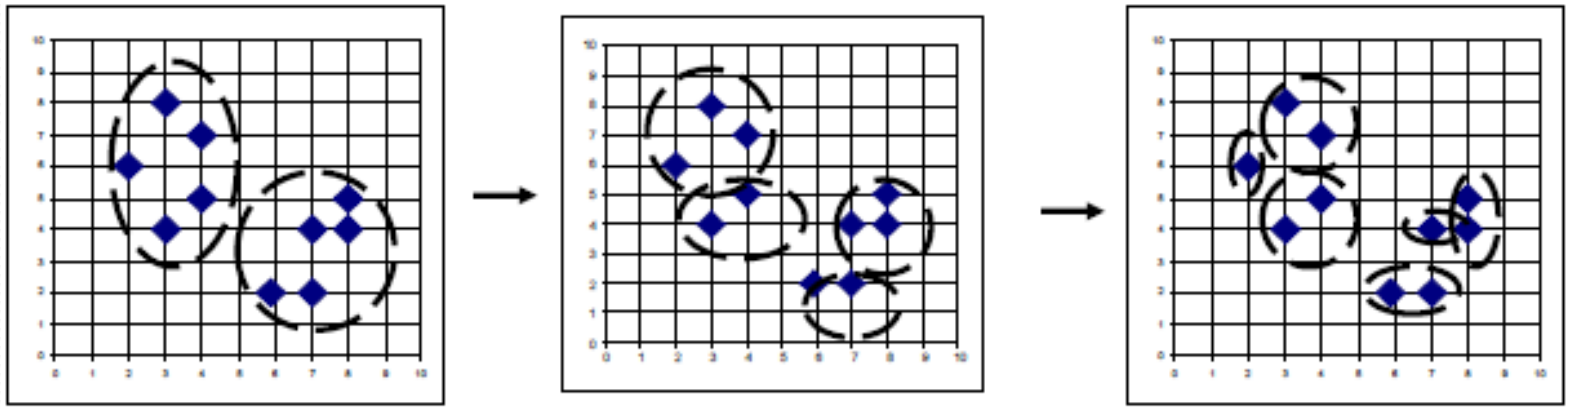
- AGNES (Agglomerative Nesting)

  - Khởi tạo: mỗi đối tượng là một cụm (lá)
  - Đệ quy trộn các nút có sự khác nhau thấp nhất
  - Tiêu chí: min distance, max distance, avg distance, center distance
  - Cuối cùng tất cả các nút thuộc về một cụm (gốc)



Hierarchical Clustering

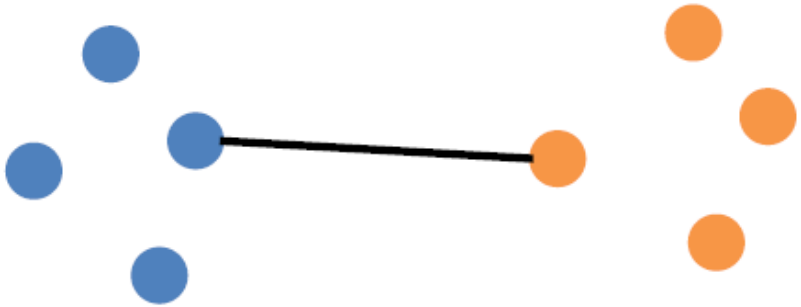
- DIANA (Divisive Analysis)
  - Ngược thứ tự so với AGNES
  - Bắt đầu với cụm gốc chứa tất cả các đối tượng
  - Thực hiện Đệ quy chia thành các cụm nhỏ
  - Cuối cùng, mỗi cụm chứa một đối tượng duy nhất



Hierarchical Clustering

- Khoảng cách giữa hai cụm có thể là một trong các loại sau:
- Single-linkage clustering :khoảng cách giữa hai cụm là ***khoảng cách ngắn nhất giữa hai đối tượng của hai cụm.***

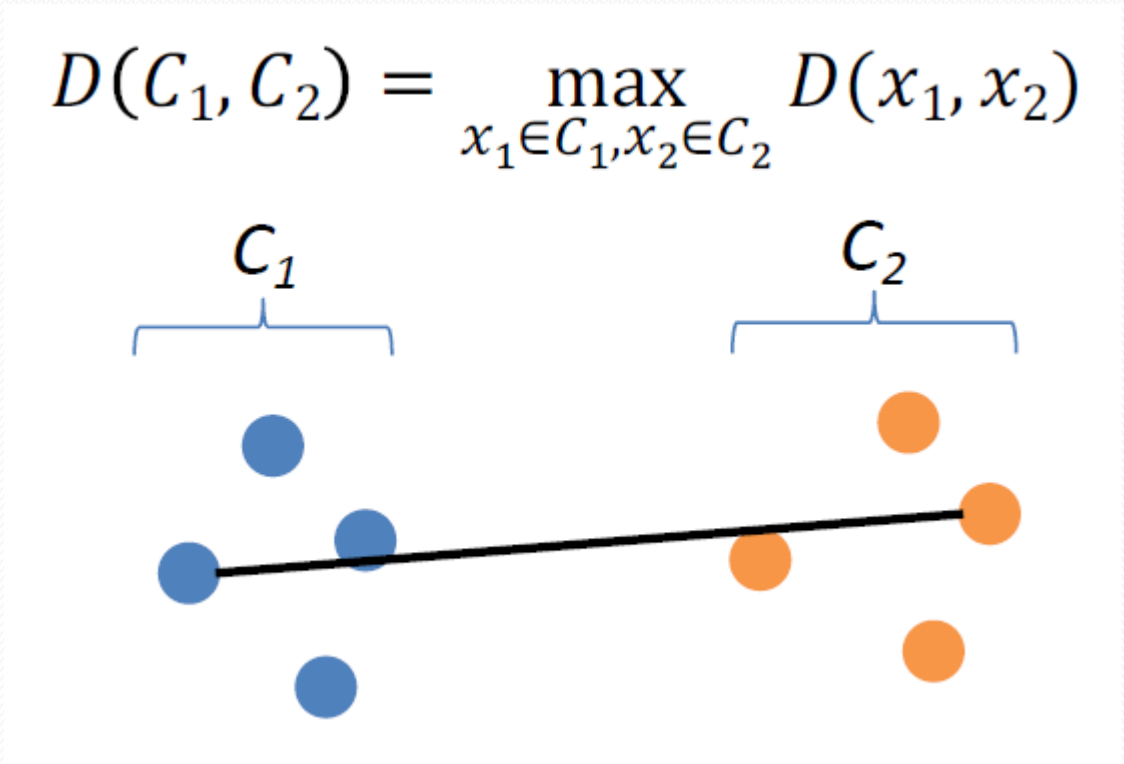
$$D(C_1, C_2) = \min_{x_1 \in C_1, x_2 \in C_2} D(x_1, x_2)$$



Hierarchical Clustering

- Complete-linkage clustering: khoảng cách giữa hai cụm là ***khoảng cách lớn nhất giữa hai đối tượng của hai cụm.***

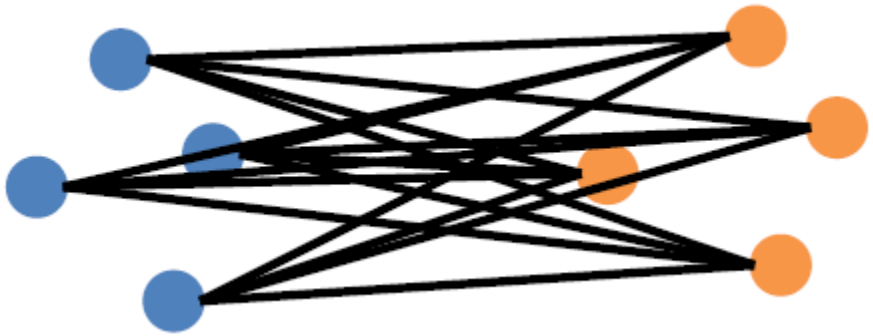
$$D(C_1, C_2) = \max_{x_1 \in C_1, x_2 \in C_2} D(x_1, x_2)$$



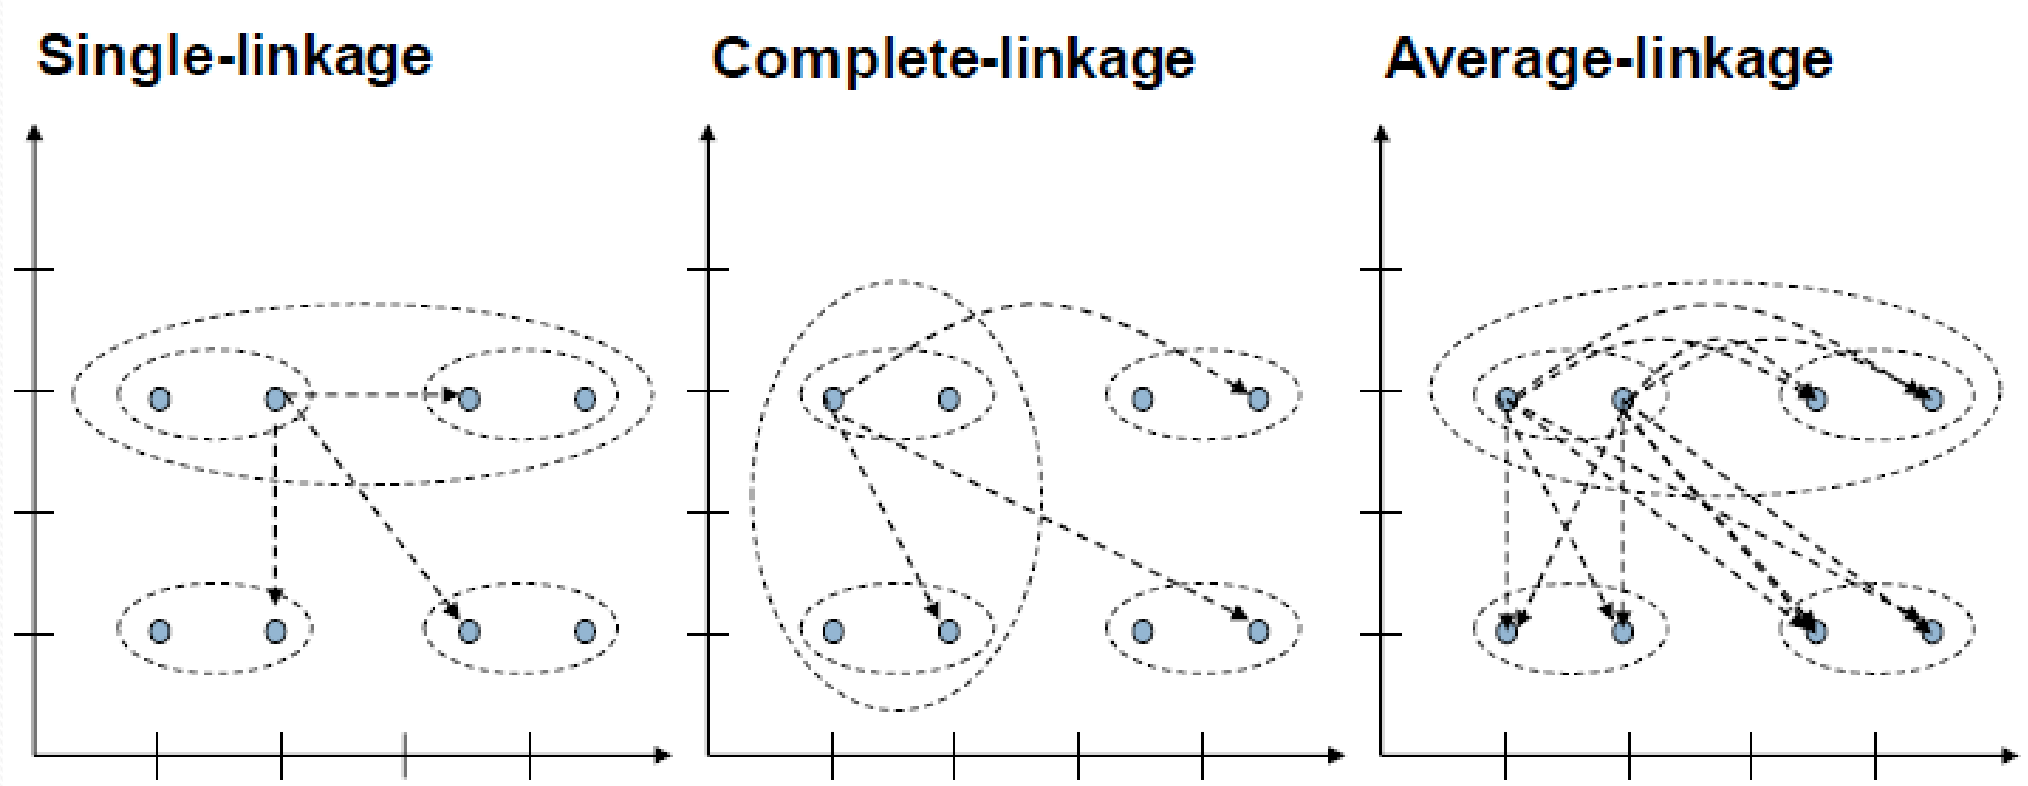
Hierarchical Clustering

- Average-linkage clustering: khoảng cách giữa hai cụm là ***khoảng cách trung bình giữa hai đối tượng của hai cụm***

$$D(C_1, C_2) = \frac{1}{|C_1|}\frac{1}{|C_2|}\sum_{x_1 \in C_1}\sum_{x_2 \in C_2} D(x_1, x_2)$$



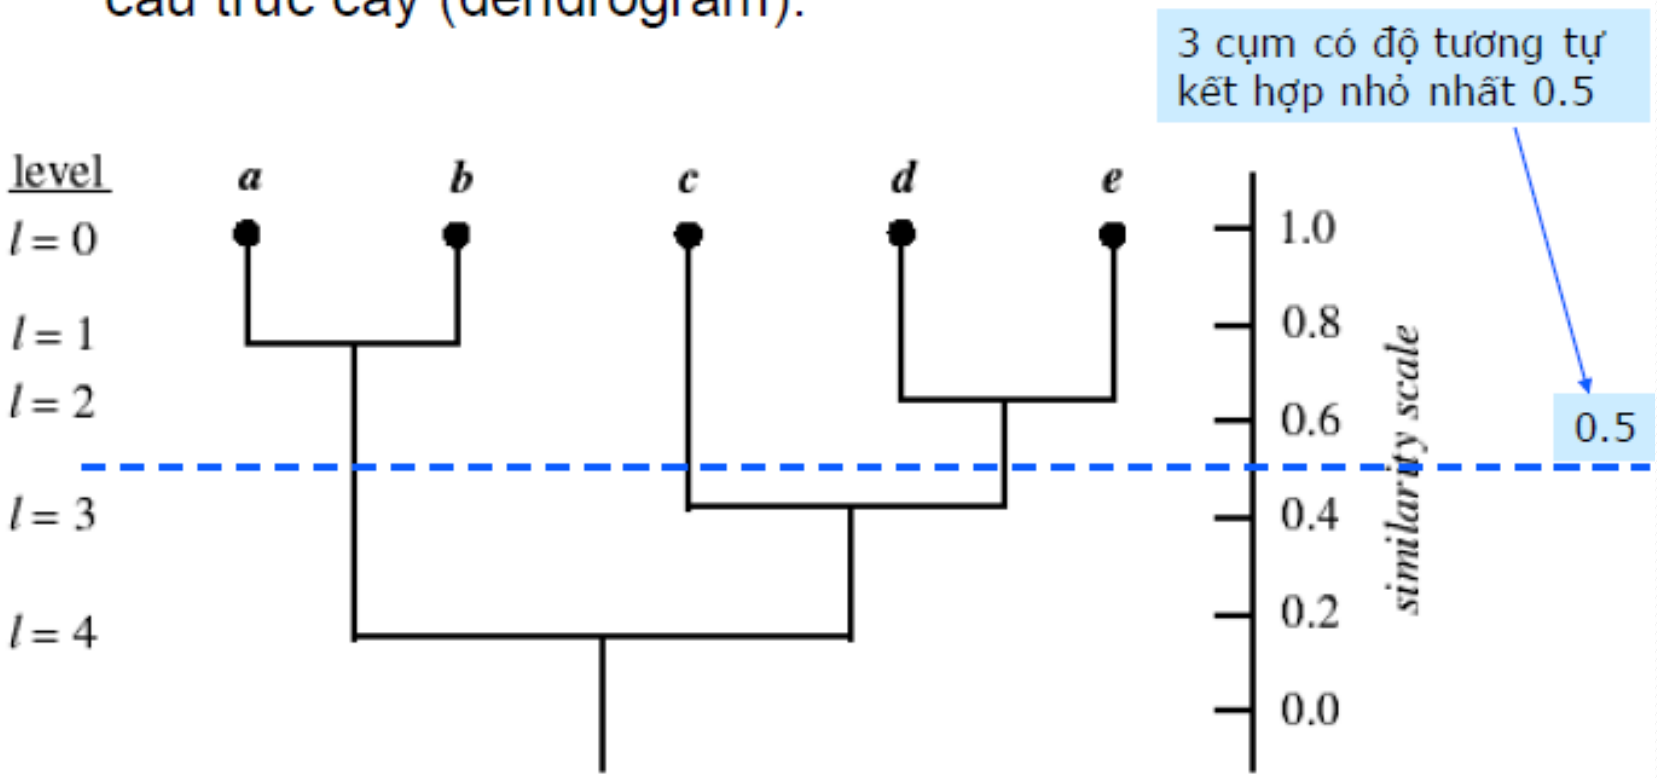
Hierarchical Clustering



Tiêu chí trộn các cụm: single-linkage, complete-linkage, và average-linkage

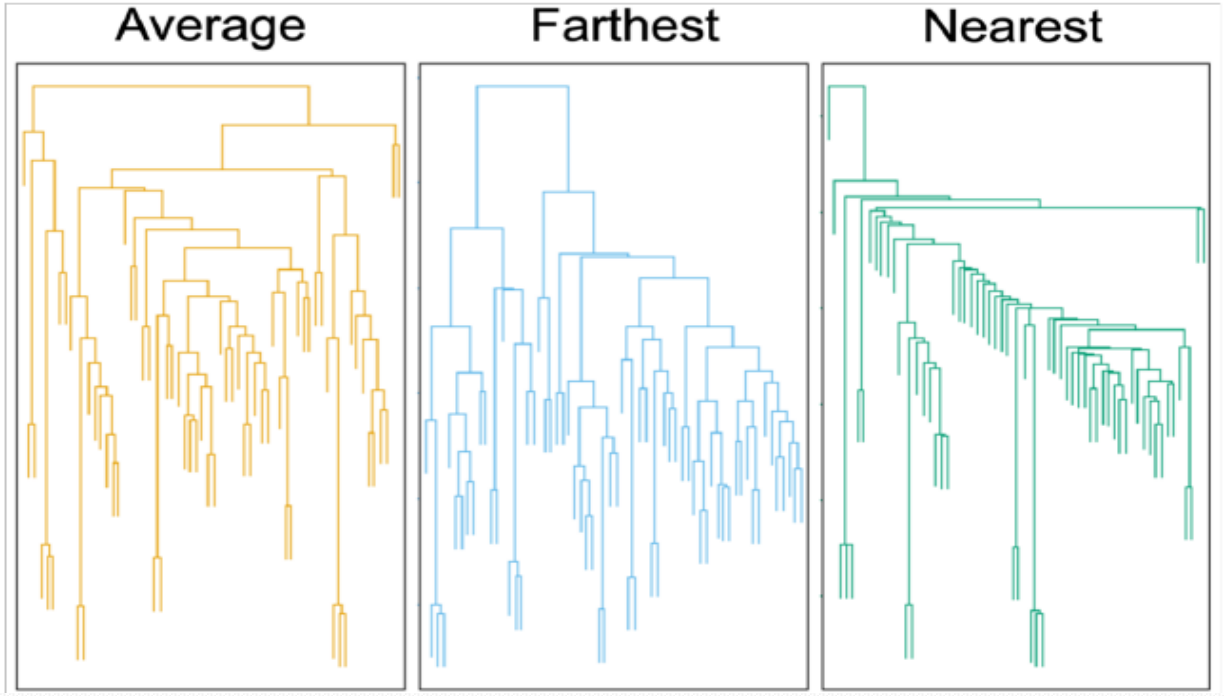
Hierarchical Clustering

- Ví dụ:
  - Quá trình Phân cụm bằng phân cấp được biểu diễn bởi cấu trúc cây (dendrogram).



Hierarchical Clustering

Clustering behavior

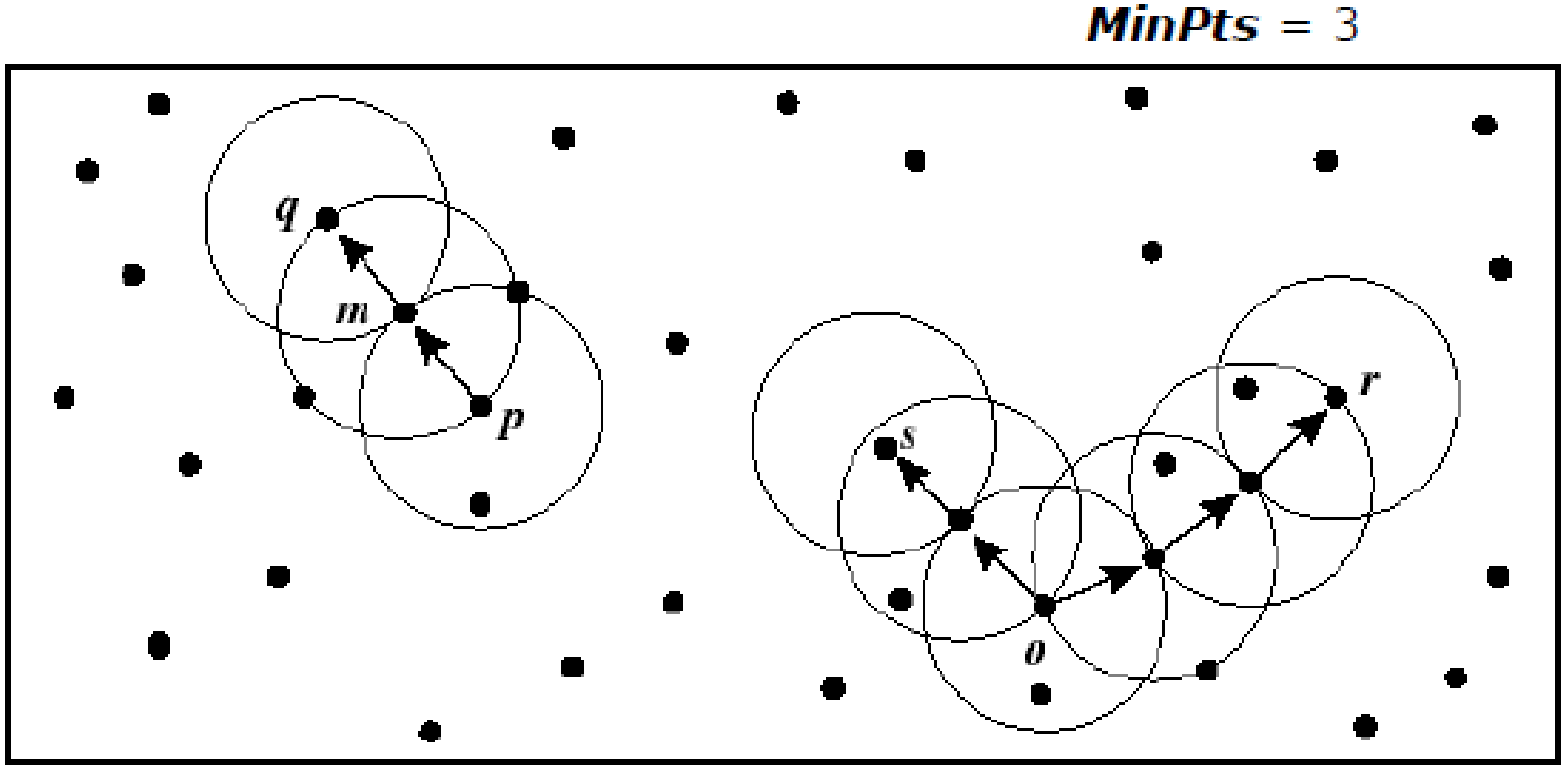


Complete link gives preference to **compact/spherical** clusters (i.e., clusters having consistent length). **Single link** can produce **long stretched** clusters (A→B→C→D…)

Density-Based Clustering

- Phân cụm dữ liệu dựa trên mật độ
  - Mỗi cụm là một vùng dày đặc (dense region) gồm các đối tượng.
  - Các đối tượng trong vùng thưa hơn được xem là nhiễu.
  - Mỗi cụm có dạng tùy ý.
- Giải thuật
- DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
- OPTICS (Ordering Points To Identify the Clustering Structure)
- DENCLUE (DENsity-based CLUstEring)
- MeanShift

Density-Based Clustering



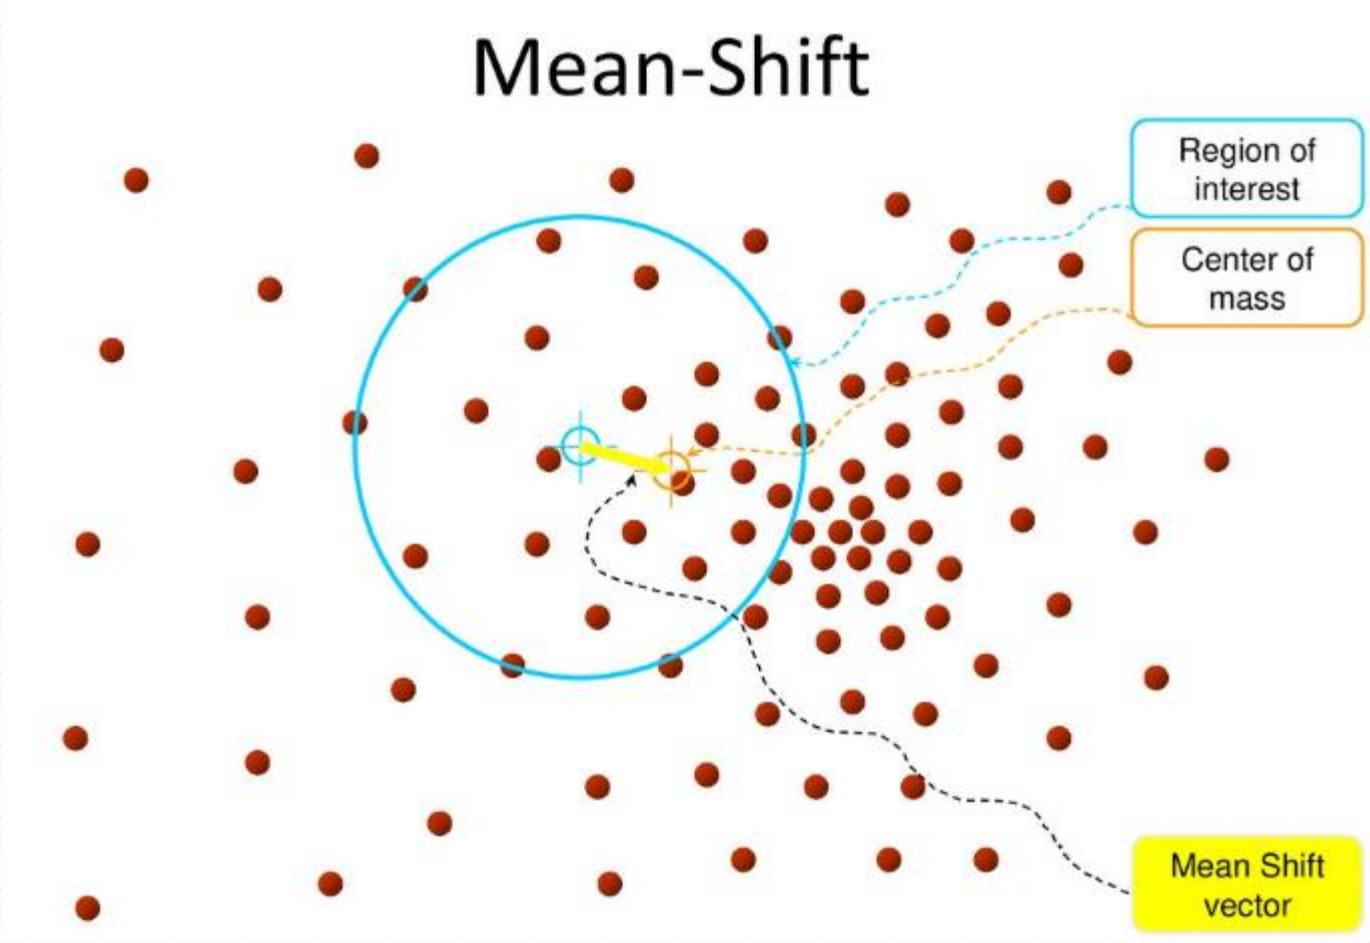
Density reachability and density connectivity in density-based clustering

Density-Based Clustering

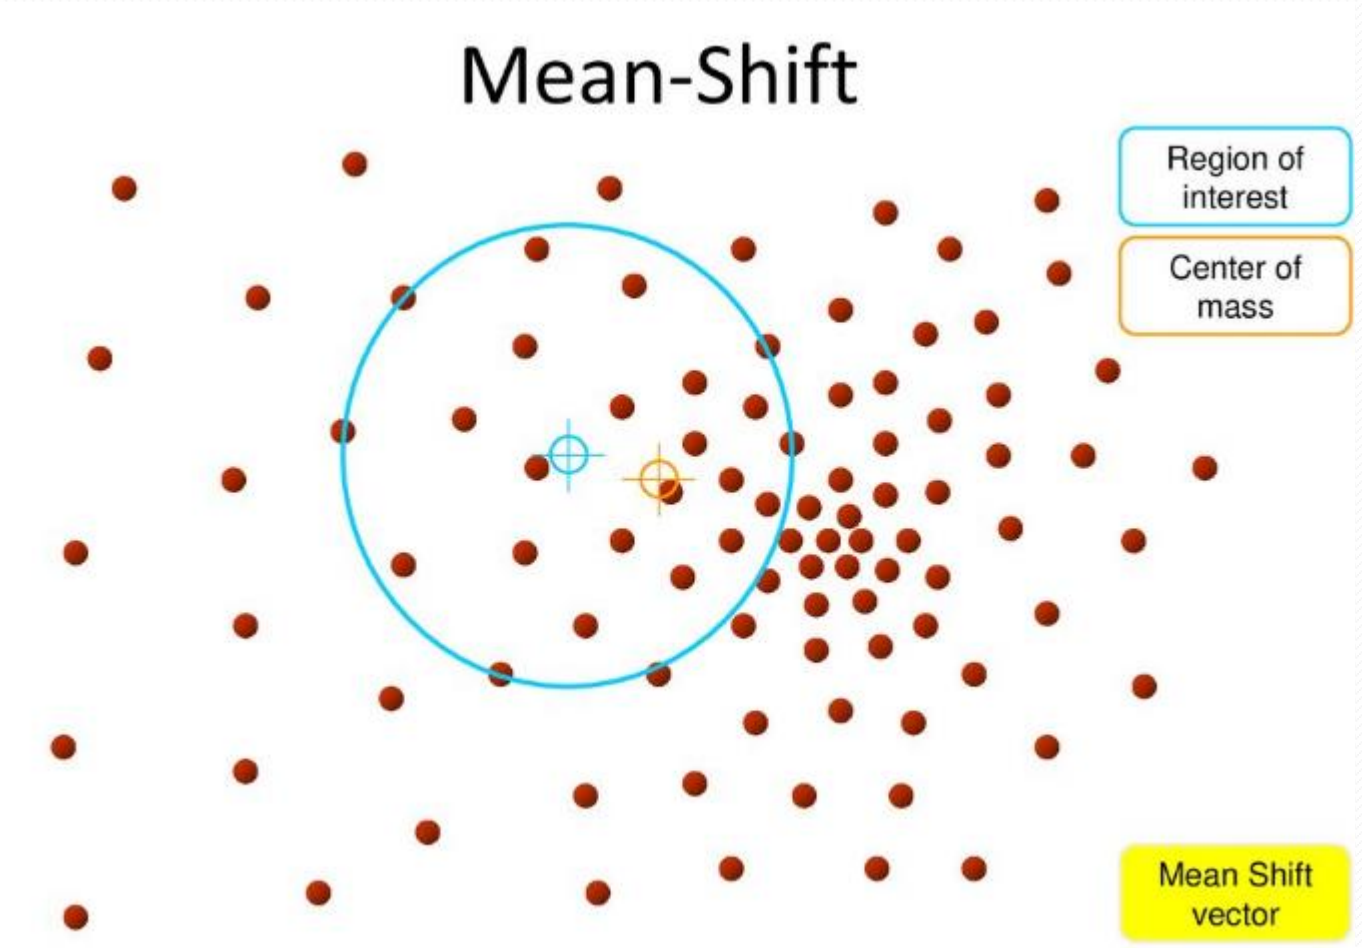
- Idea of MeanShift

- **Iterative Mode Search**
  1. Initialize random seed, and window W
  2. Calculate center of gravity (the "mean") of W: $\sum_{x \in W} x H(x)$
  3. Shift the search window to the mean
  4. Repeat Step 2 until convergence

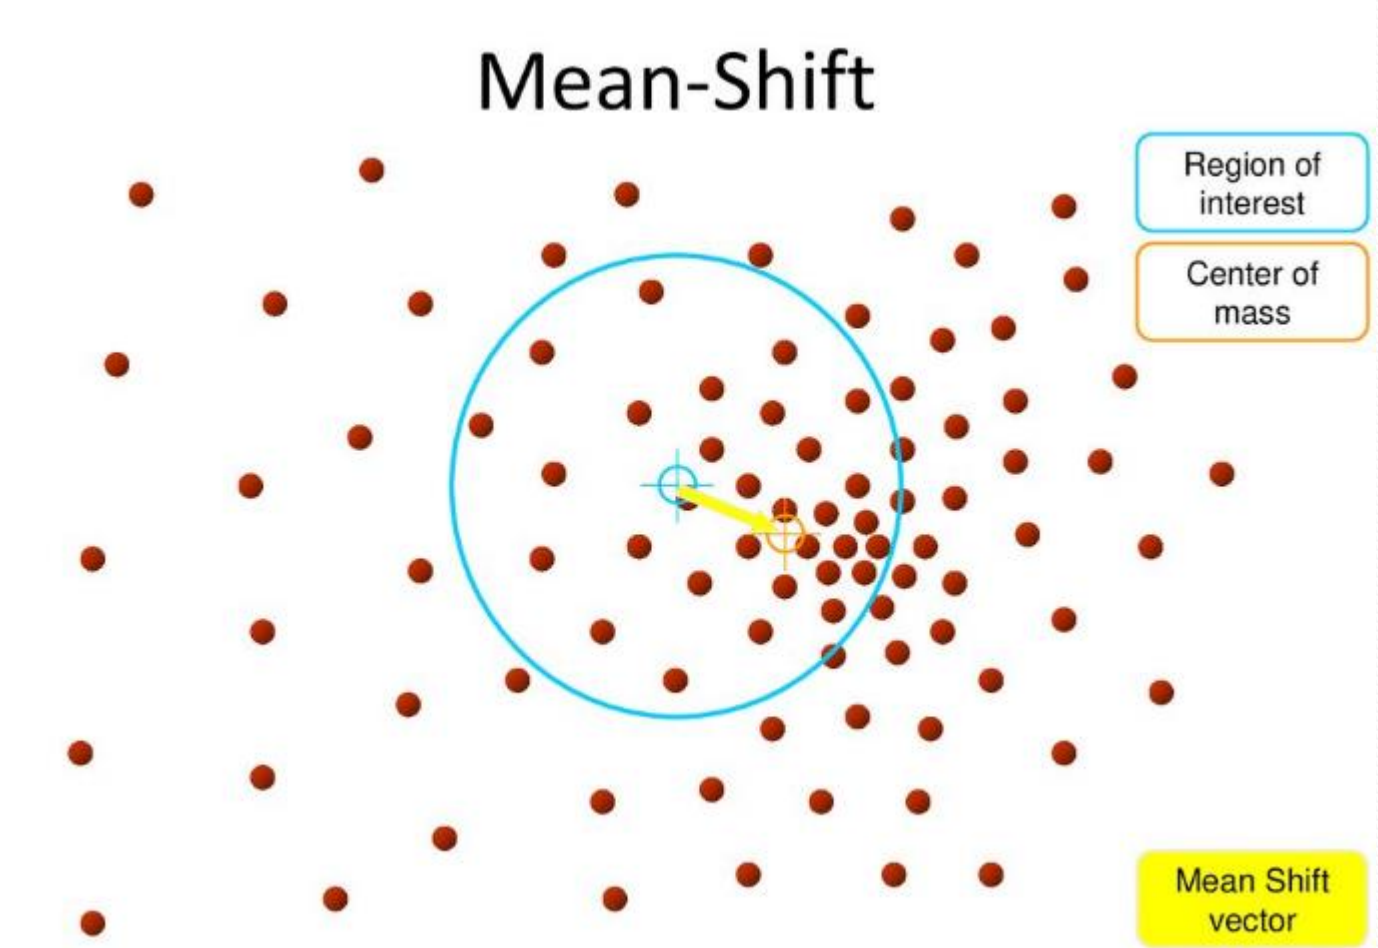
MeanShift


Mean-Shift
Region of interest
Center of mass
Mean Shift vector

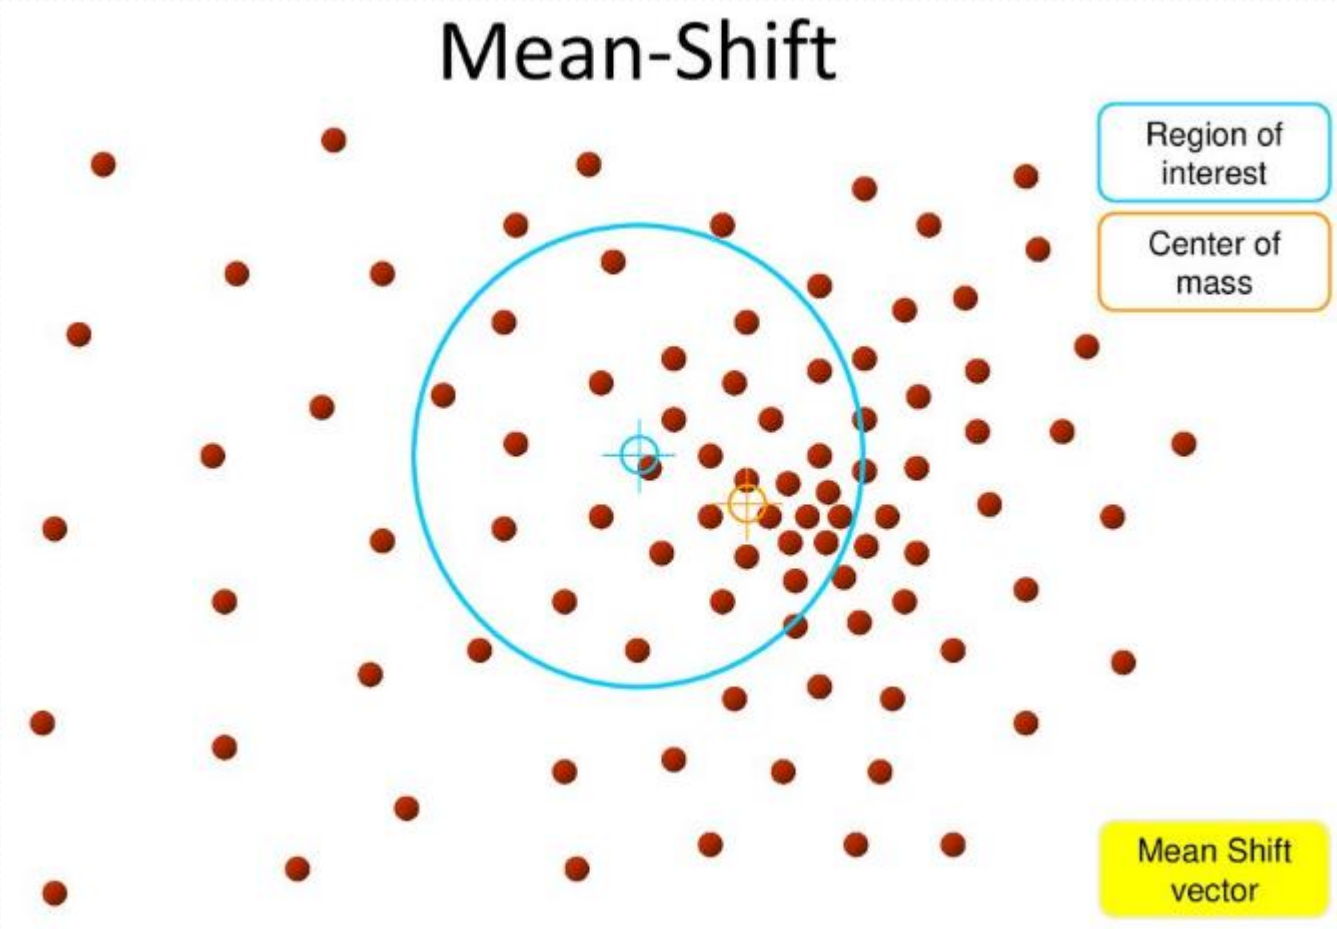
MeanShift


Mean-Shift
Region of interest
Center of mass
Mean Shift vector

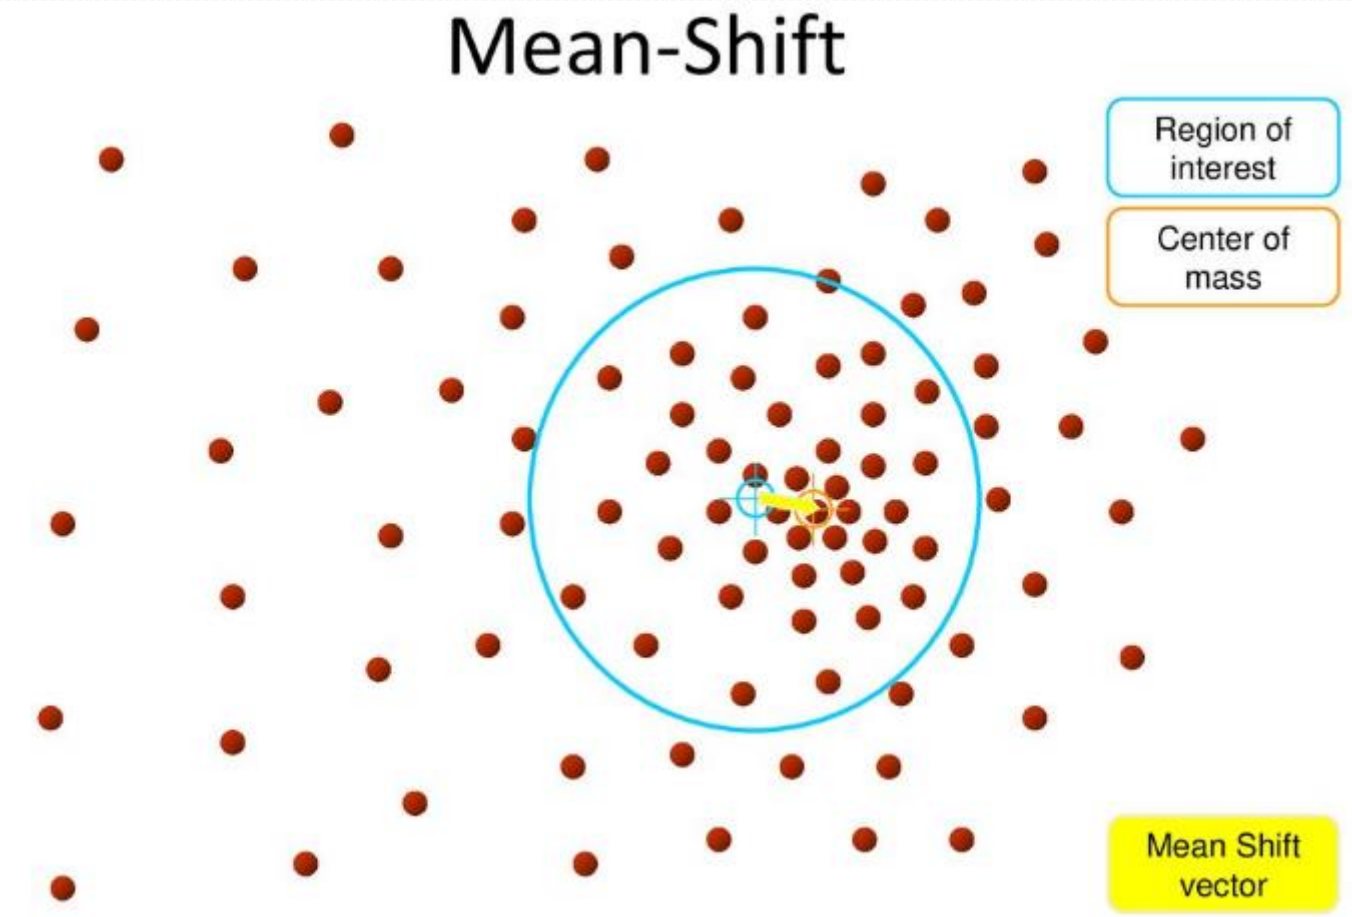
MeanShift


Mean-Shift
Region of interest
Center of mass
Mean Shift vector

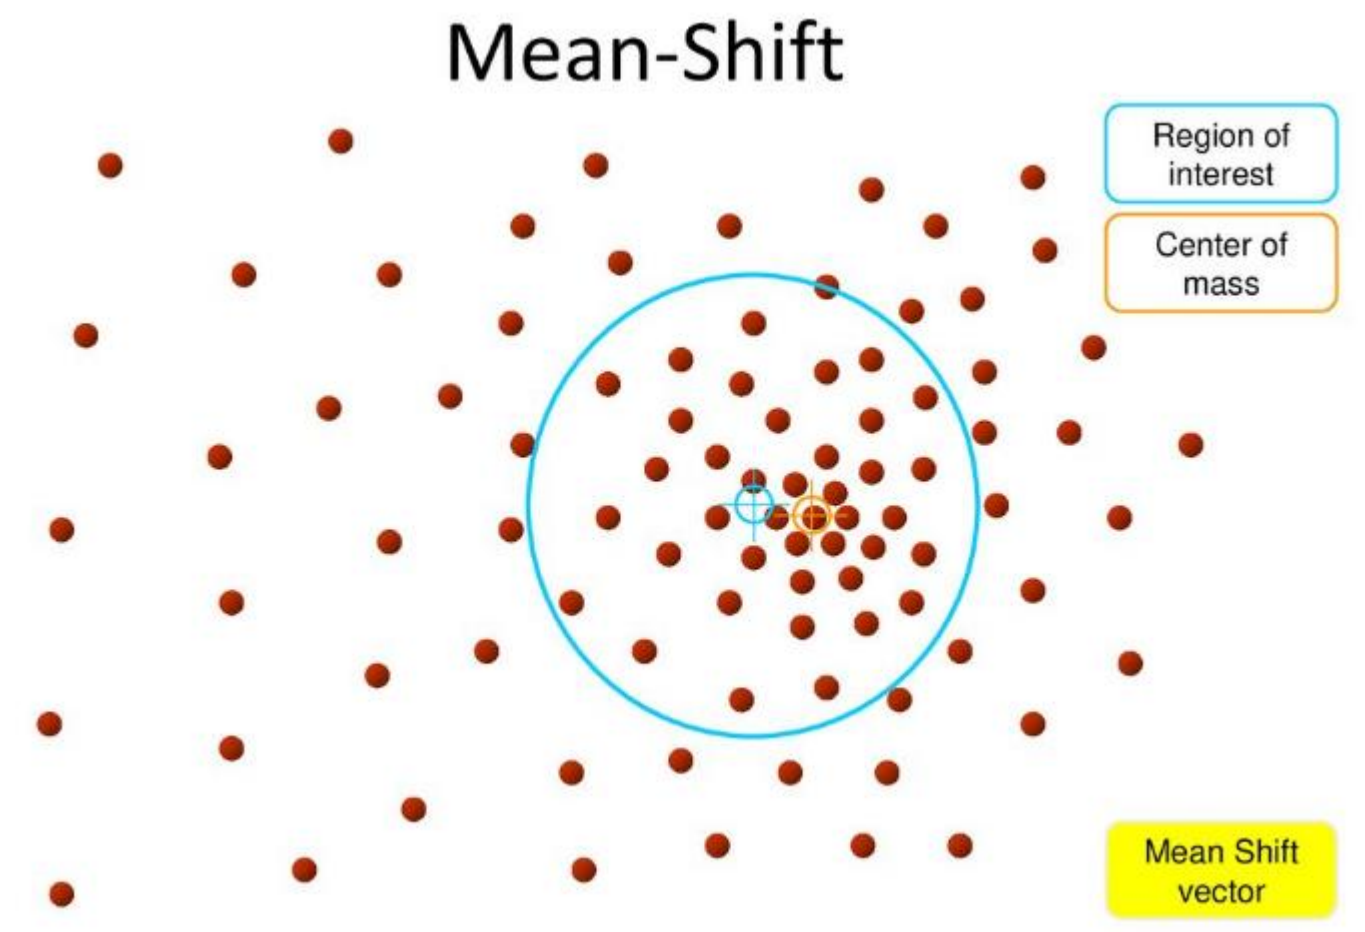
MeanShift


Mean-Shift
Region of interest
Center of mass
Mean Shift vector

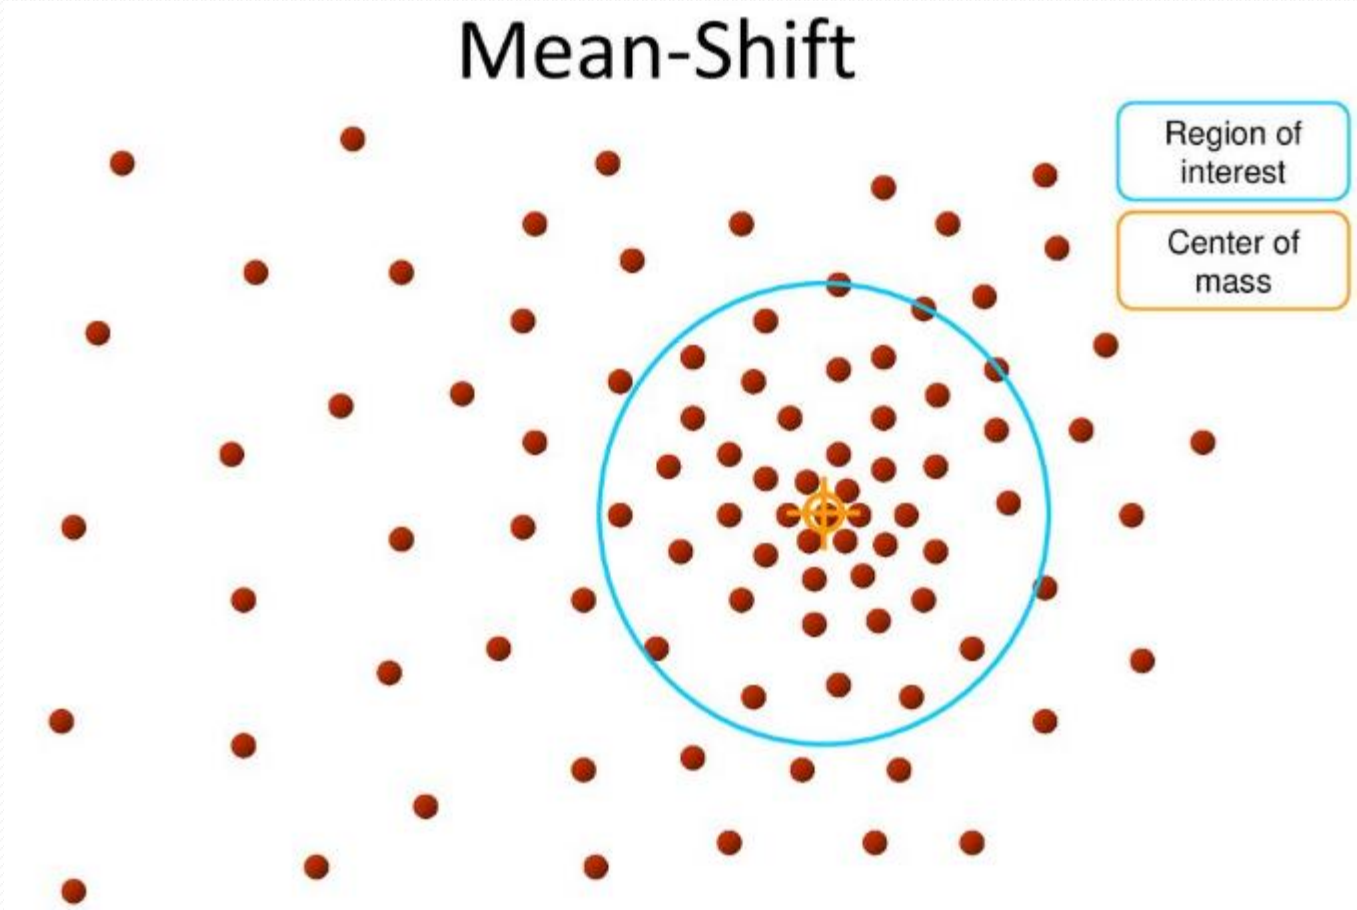
MeanShift


Mean-Shift
Region of interest
Center of mass
Mean Shift vector

MeanShift

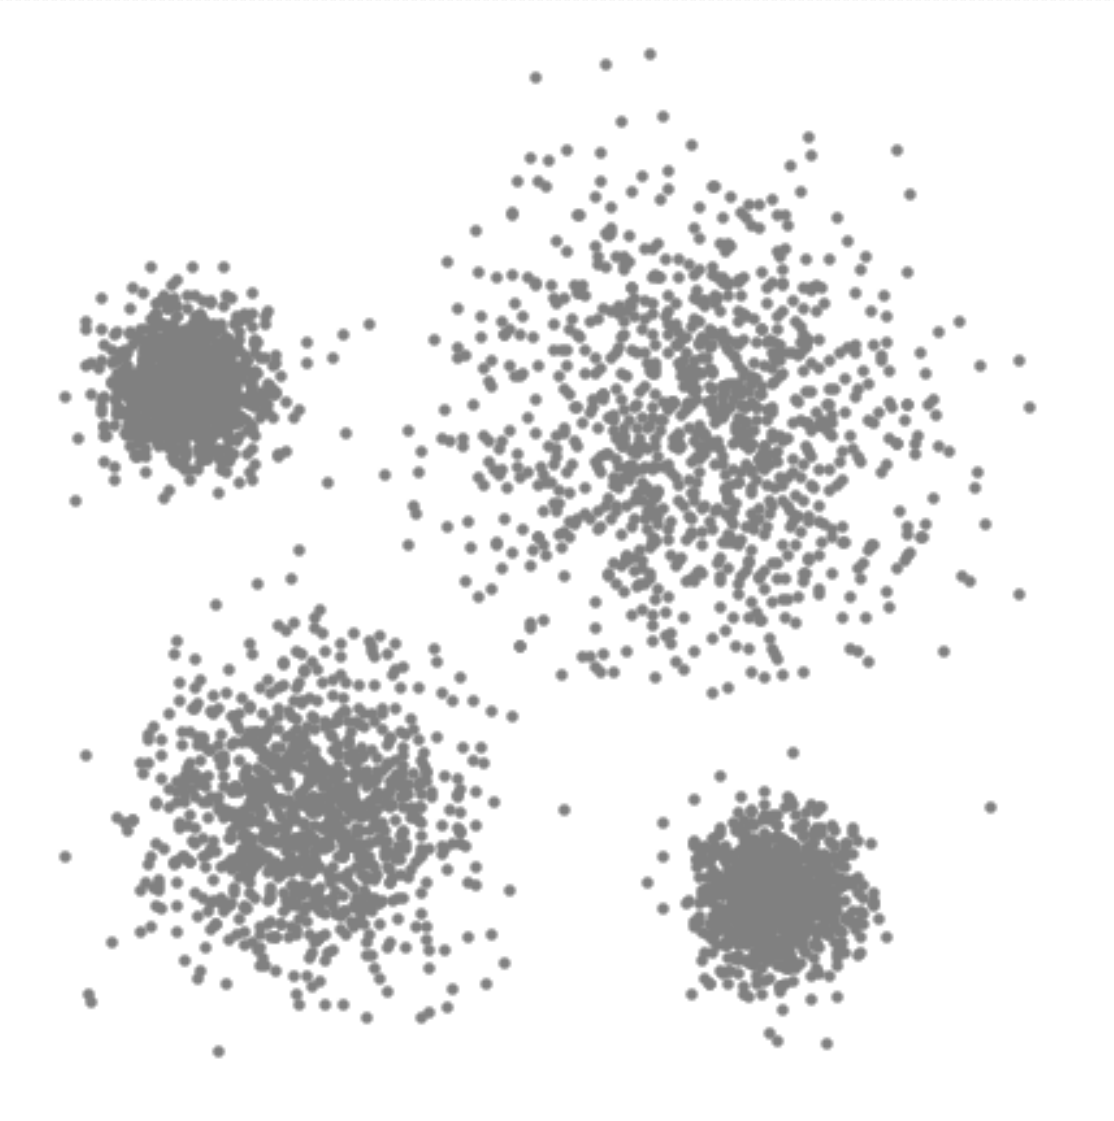

Mean-Shift
Region of interest
Center of mass
Mean Shift vector

MeanShift



MeanShift

- MeanShift không cần chọn trước số nhóm cần phân loại. Thuật toán có thể tìm được số nhóm vì chúng sẽ dịch chuyển tự động.
- Vấn đề trong MeanShift là chọn window - bán kính vùng quét để tính mean - là bao nhiêu



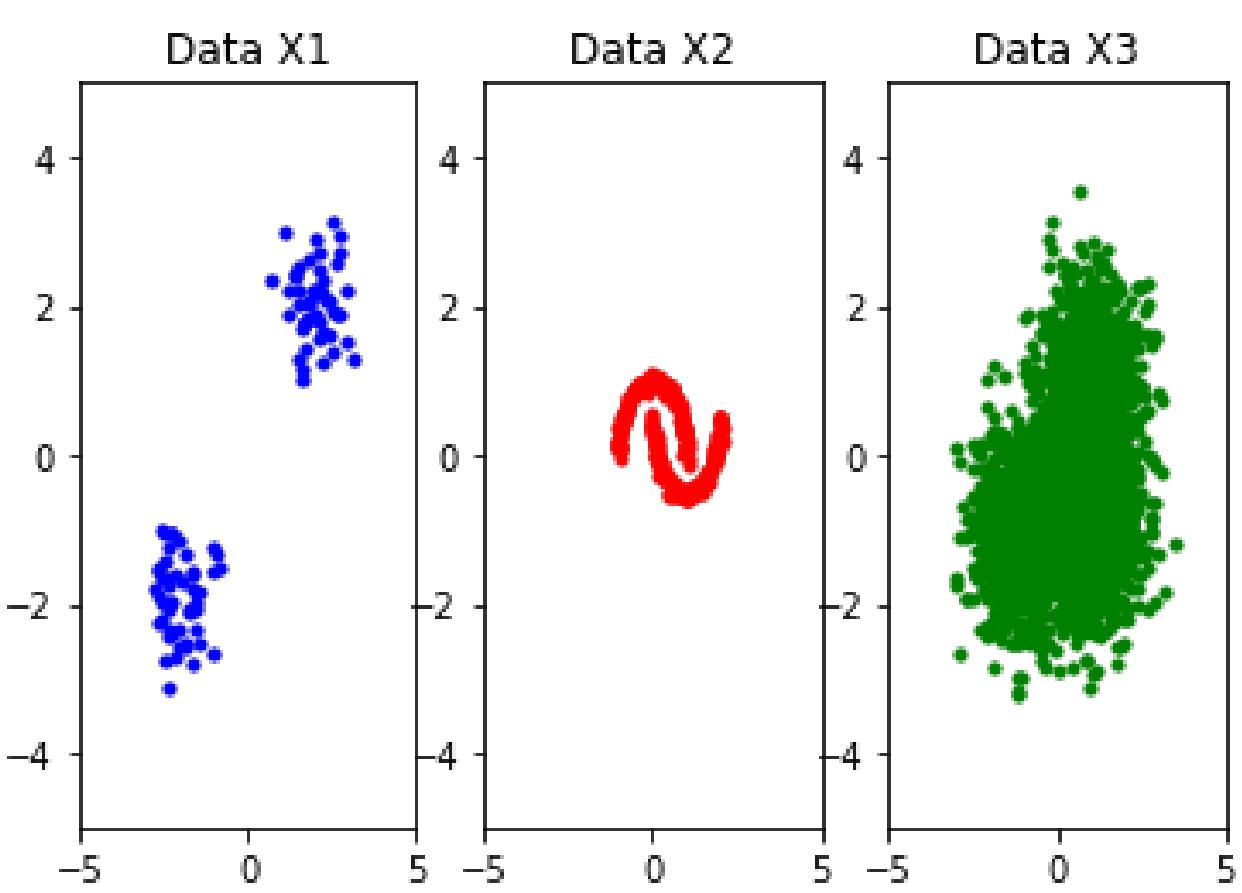
Tìm hiểu thêm

- Subspace Clustering

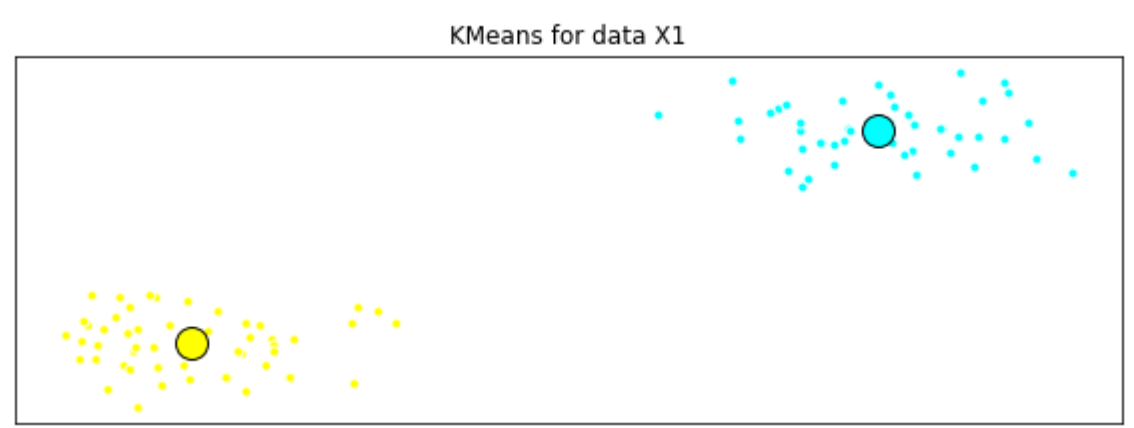
Bài Tập

1) Toy Example: Tạo ngẫu nhiên 3 loại dữ liệu như sau

- Three Data: X1 , X2, X3
  - X1 : 2 clusters
  - X2 : 2 clusters
  - X3: 1 cluster + outlier
- Cài đặt và so sánh hiệu quả của
  - Kmean
  - DBSCAN



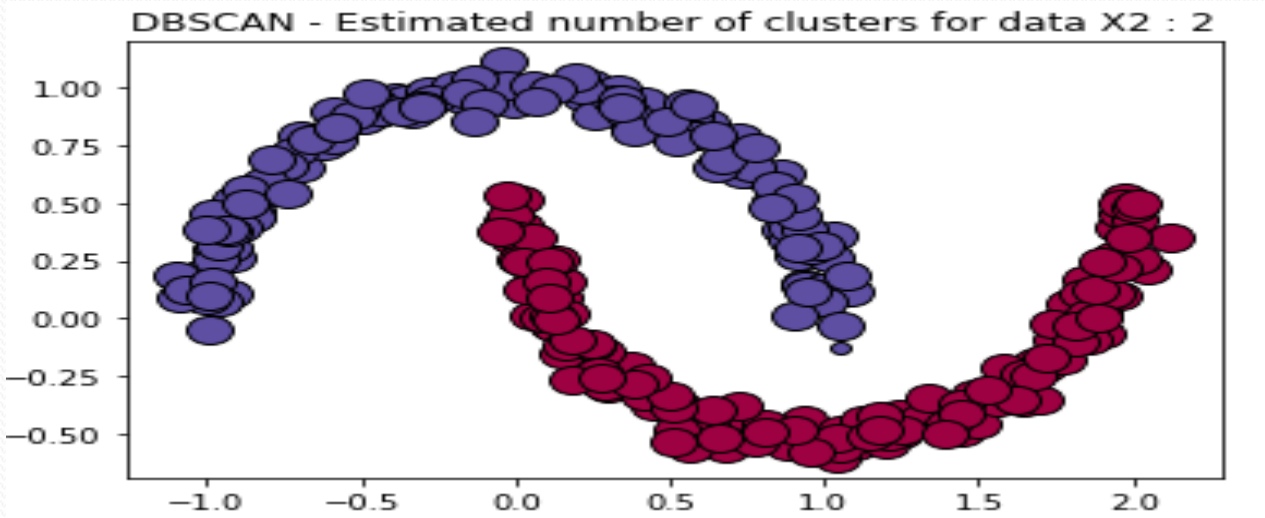
Toy Example


KMeans for data X1

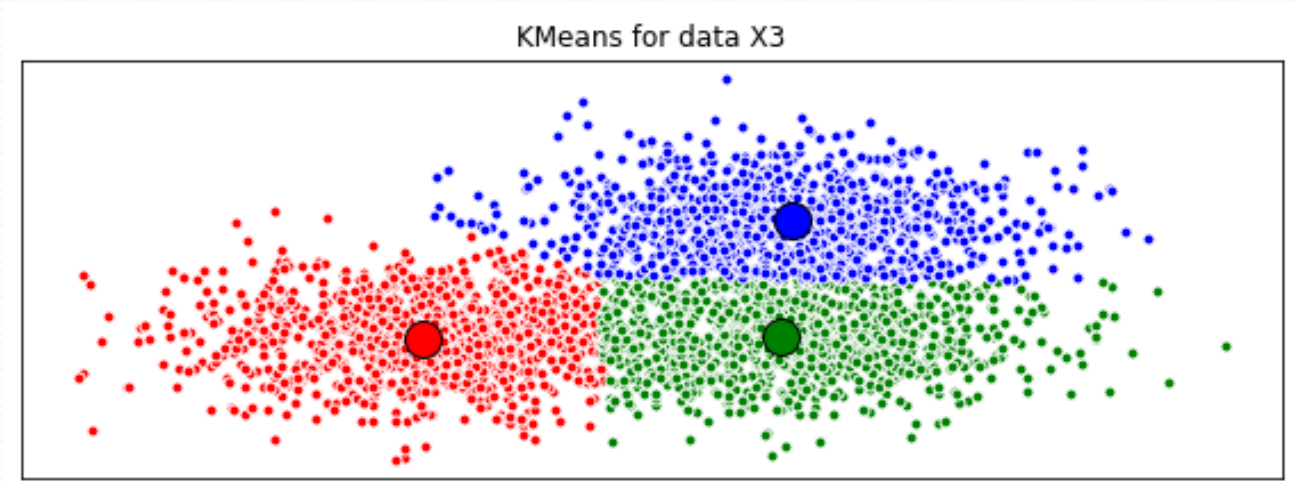

DBSCAN - Estimated number of clusters for data X1 : 2
3
2
1
0
−1
−2
−3
−3
−2
−1
0
1
2
3

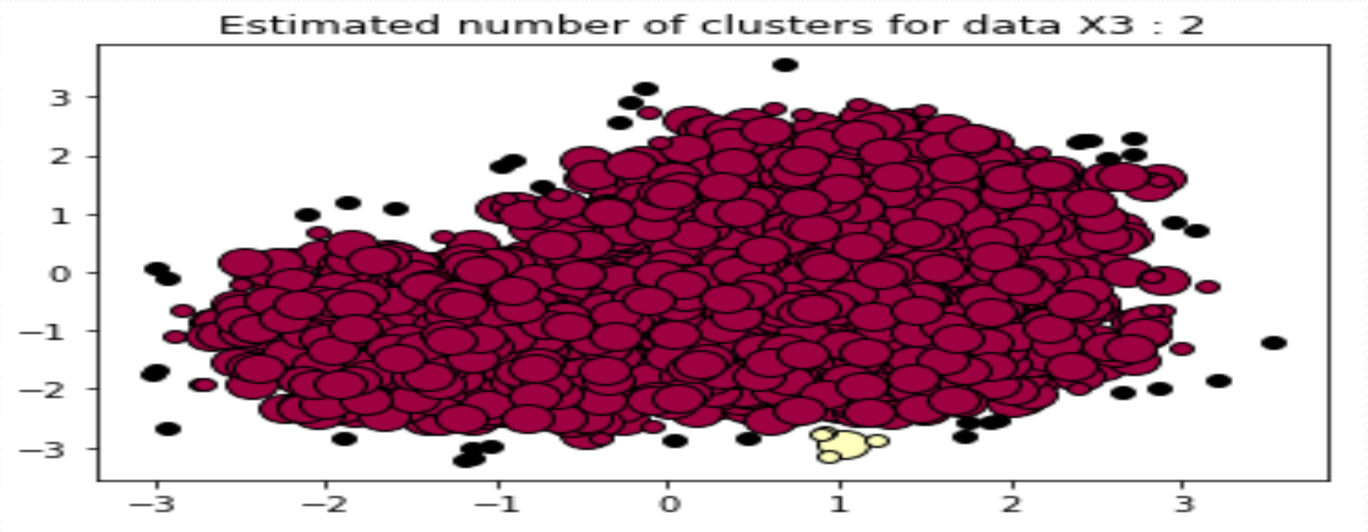
Toy Example


KMeans for data X2


DBSCAN - Estimated number of clusters for data X2 : 2
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0

Toy Example


KMeans for data X3


Estimated number of clusters for data X3 : 2
3
2
1
0
−1
−2
−3
−3
−2
−1
0
1
2
3

Bài Tập

2) Color Clustering based Kmeans

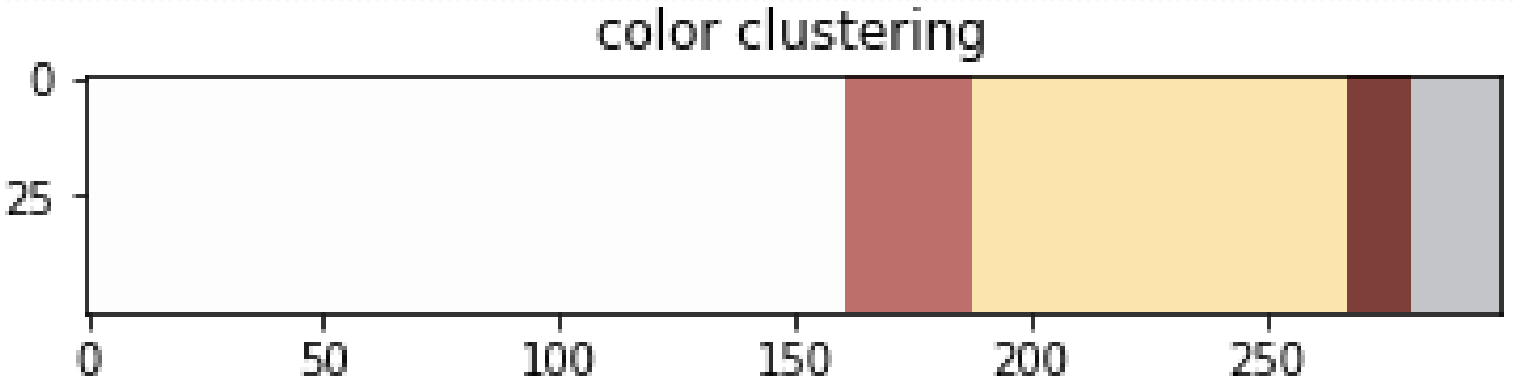
- Imagine you have an image with millions of colors.
- In most images, a large number of the colors will be unused, and many of the pixels in the image will have similar or even identical colors



https://jakevdp.github.io/PythonDataScienceHandbook/05.11-k-means.html
https://towardsdatascience.com/introduction-to-image-segmentation-with-k-means-clustering-83fd0a9e2fc3

Dominant Color





https://buzzrobot.com/dominant-colors-in-an-image-using-k-means-clustering-3c7af4622036