UỶ BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA TOÁN - ỨNG DỤNG

BÁO CÁO
HỌC PHẦN: KHAI PHÁ DỮ LIỆU (858016)

Giảng viên hướng dẫn: Đỗ Như Tài

Sinh viên thực hiện: Trần Quốc Hoàng (3123580015)
Trần Chí Vỹ (3123580065)
Phan Trần Hữu Tấn (3123580042)

Lớp: DDU1231

Thành phố Hồ Chí Minh, tháng 12 năm 2025

QUÁ TRÌNH THAM GIA

Tên - MSSV	Phân công	Tham gia (%)
Trần Quốc Hoàng - 3123580015 (Nhóm trưởng)	Câu 3.1.1, 3.1.3, 3.1.4 và viết báo cáo	100%
Trần Chí Vỹ - 3123580065	Câu 3.2.3, 3.2.4	100%
Phan Trần Hữu Tấn - 3123580042	Câu 3.2.1	100%

BÁO CÁO

1. Giới thiệu chung

Báo cáo này tổng hợp kết quả phân tích ứng dụng hai thuật toán phân cụm chính là K-Means Clustering và Agglomerative Clustering (Phân cụm Đa cấp) trên hai tập dữ liệu độc lập:

1. Dữ liệu chim cánh cụt (Penguins Dataset): Phân nhóm các loài dựa trên đặc trưng hình thái.
2. Dữ liệu bán lẻ trực tuyến (Online Retail Dataset): Phân khúc khách hàng dựa trên mô hình RFM (Recency, Frequency, Monetary).

Mục tiêu chung là khám phá các nhóm tự nhiên hoặc phân khúc có ý nghĩa kinh doanh trong các tập dữ liệu, phục vụ cho mục đích nghiên cứu sinh học và chiến lược kinh doanh.

2. K-Means Clustering trên dữ liệu chim cánh cụt

2.1. Phương pháp và dữ liệu

- Dữ liệu: clustering_penguins_species.csv (Palmer Penguins Dataset).
- Đặc trưng sử dụng: Các đặc trưng hình thái (chiều dài và độ sâu mỏ, chiều dài vây, khối lượng cơ thể).
- Tiền xử lý: Làm sạch dữ liệu, chuẩn hóa dữ liệu bằng Standard Scaler.
- Mô hình: K-Means Clustering.
- Số lượng Cụm (K): $K = 3$ được xác định là tối ưu (dựa trên Elbow Method, Silhouette Score, và việc dữ liệu biết có 3 loài).

2.2. Tóm tắt kết quả phân cụm (K = 3)

Mô hình K-Means đã phân cụm thành công 3 nhóm, khớp gần như hoàn hảo với 3 loài chim cánh cụt thực tế:

Cụm	Đặc trưng nổi bật	Loài tương ứng
Cụm 0	Mỏ ngắn & sâu, vây ngắn, nhẹ cân nhất.	Adelie
Cụm 1	Mỏ dài & nông, vây rất dài, nặng cân nhất.	Gentoo
Cụm 2	Mỏ dài & sâu, kích thước trung bình.	Chinstrap

2.3. Đánh giá

- Chỉ số: Silhouette Score đạt xấp xỉ 0.451.
- Kết luận: Điểm Silhouette cao này chứng tỏ K-Means đã phân cụm tốt và các cụm được tách biệt rõ ràng, cho thấy K-Means là lựa chọn cực kỳ hiệu quả để khám phá 3 loài chim cánh cụt từ dữ liệu đo đạc hình thái.

3. K-Means Clustering trên dữ liệu bán lẻ RFM

3.1. Phương pháp và dữ liệu

- Dữ liệu: online_retail_clustering.csv.
- Đặc trưng sử dụng: Mô hình RFM (Recency, Frequency, Monetary).
- Tiền xử lý: Làm sạch dữ liệu giao dịch, tính toán RFM, Chuẩn hóa dữ liệu RFM.
- Mô hình: K-Means Clustering.
- Số lượng Cụm (K): *K* tối ưu được xác định (thường là 3-5).

3.2. Tóm tắt phân khúc khách hàng

Mô hình đã phân cụm khách hàng thành các nhóm dựa trên hành vi mua sắm RFM.

Phân khúc	Đặc trưng RFM nổi bật	Đề xuất chiến lược Marketing
VIP/Trung thành	Recency, Frequency, Monetary đều cao.	Tri ân, Chương trình khách hàng thân thiết, Bán chéo (Cross-selling), Upsell.
Nguy cơ (At Risk)	Recency trung bình/thấp, Frequency/Monetary còn ổn.	Gửi email kích hoạt lại (reactivation), Voucher lớn, Nhắc nhở sản phẩm từng mua.
Mất (Lost/Churned)	Recency rất cao (đã lâu không mua).	Chiến dịch giành lại (Win-back) mạnh: discount 30-50%, Khảo sát lý do rời bỏ.

3.3. Đánh giá

- Kết luận: K-Means là lựa chọn hiệu quả để phân tích RFM. Kết quả phân cụm cung cấp cái nhìn sâu sắc, giúp doanh nghiệp cá nhân hóa marketing để tăng tỷ lệ giữ chân khách hàng (retention) và doanh thu (revenue).

4. Agglomerative Clustering trên dữ liệu chim cánh cụt

4.1. Phương pháp và dữ liệu

- Mô hình: Agglomerative Clustering (Phân cụm Đa cấp).
- Tiền xử lý: Xử lý giá trị thiếu (NA), chuẩn hóa dữ liệu bằng Standard Scaler.
- Số lượng Cụm (K): $K = 3$ được xác định dựa trên mục tiêu phân tách các loài chính và cô lập các điểm ngoại lai.

4.2. Tóm tắt kết quả phân cụm (K = 3)

Mô hình Agglomerative đã thành công trong việc phân tách chim cánh cụt thành ba nhóm chính dựa trên kích thước mỏ:

Cụm	Vị trí (Sau chuẩn hóa)	Đặc trưng hình thái nổi bật	Ý nghĩa sinh học (Dự đoán)
0	Trên - Trái	Mỏ Ngắn & Sâu, thân hình nhỏ hơn.	Loài Adelie (Phổ biến, hình thái mỏ cứng cáp).
1	Dưới - Phải	Mỏ Dài & Nông, thân hình lớn hơn.	Loài Gentoo (Lớn nhất, hình thái mỏ mảnh mai hơn).
2	Cực Phải (Outlier)	Mỏ Cực Dài (Điểm ngoại lai).	Dữ liệu Ngoại Lai (Outlier) hoặc lỗi đo lường.

4.3. Đánh giá

- Kết luận: Kết quả phân cụm cho thấy rõ ràng sự khác biệt về hình thái có thể được sử dụng hiệu quả để phân loại các loài. Đặc biệt, Cụm 2, chứa các điểm ngoại lai, đã được mô hình cô lập thành công, giúp nhà phân tích dễ dàng kiểm tra dữ liệu không chính xác.

5. Agglomerative Clustering trên dữ liệu bán lẻ RFM

5.1. Phương pháp và dữ liệu

- Mô hình: Agglomerative Clustering.
- Đặc trưng sử dụng: Mô hình RFM.
- Tiền xử lý chuyên sâu:
- Xử lý lỗi, loại bỏ giao dịch bị hủy, giá trị âm/thiếu.
- Áp dụng Log Transformation để giảm độ lệch.
- Chuẩn hóa (Standardization) bằng StandardScaler.
- Sử dụng Phân tích Thành phần Chính (PCA) để giảm chiều từ 3D xuống 2D.
- Số lượng Cụm (K): $K = 3$ là số lượng tối ưu để tách biệt các phân khúc khách hàng.

5.2. Tóm tắt phân khúc khách hàng (K = 3)

Mô hình đã phân tách khách hàng thành ba phân khúc có ý nghĩa chiến lược:

Cụm	Đặc trưng RFM nổi bật	Tên phân khúc	Đề xuất chiến lược Marketing
0	Recency cao, Frequency cao.	Khách hàng Trung thành/Tốt nhất	Tri ân, Chương trình khách hàng thân thiết độc quyền, Bán chéo (Cross-selling) sản phẩm mới.
1	Recency thấp (lâu không mua).	Khách hàng Nguy cơ/Không hoạt động	Chiến dịch kích hoạt lại (Re-engagement), Mã giảm giá hấp dẫn, Khảo sát lý do ngừng mua.
2	Monetary cực cao.	Khách hàng VIP/Nhà bán buôn	Quan hệ đối tác, Dịch vụ cá nhân hóa, Chiết khấu số lượng lớn, Đánh giá chất lượng dịch vụ.

5.3. Đánh giá

- Kết luận: Việc áp dụng Log Transform và Chuẩn hóa trước khi phân cụm là rất quan trọng để đảm bảo mô hình không bị thiên vị bởi sự chênh lệch lớn về thang đo giữa các biến RFM. Kết quả cung cấp cái nhìn sâu sắc, giúp doanh nghiệp tập trung nguồn lực để duy trì Khách hàng Trung thành và VIP.

6. Tổng kết và kết luận

Cả hai thuật toán phân cụm (K-Means và Agglomerative) đều chứng minh hiệu quả cao trong việc khám phá cấu trúc ẩn của dữ liệu:

- Trong Sinh học (Penguins): Cả hai thuật toán đều thành công trong việc phân loại loài dựa trên hình thái, với K-Means cho Silhouette Score cao (0.451) và Agglomerative giúp cô lập các điểm ngoại lai.
- Trong Kinh doanh (Retail RFM): Cả hai thuật toán đều tạo ra các phân khúc khách hàng rõ ràng (Trung thành, Nguy cơ, VIP), trực tiếp hỗ trợ việc ra quyết định và tối ưu hóa chiến lược tiếp thị cá nhân hóa.

Quá trình tiền xử lý dữ liệu phức tạp (như Log Transform và Chuẩn hóa) là chìa khóa thành công cho việc trích xuất các cụm có ý nghĩa, đặc biệt đối với dữ liệu RFM có độ lệch cao.

SGU25