Hướng dẫn tải bài tập

- Trước khi làm bài tập chương, ta truy cập vào đường link Github sau để tải các bài tập trong chương đó: https://github.com/hhohho/Learn-Data-Mining-through-Excel-2.

- Sau khi truy cập vào đường link ta sẽ thấy có 14 folder đại diện cho từng chương và bài tập của chương đó, bây giờ bấm vào folder có tên "chapter8", trong folder sẽ chứa 11 file excel (5 file bài tập, 5 file đáp án của bài tập đó và 1 file tham khảo). Sau đó ta bấm vào từng file và tải "Download raw file" ở dưới icon "History".

Hiểu biết

1. Lý thuyết

1.1. Khái niệm

- **Phân cụm phân cấp (Hierarchical Clustering)**: Là một phương pháp phân loại không giám sát (Unsupervised Classification) dùng để phân loại các đối tượng dữ liệu thành các nhóm dựa trên sự tương đồng về đặc điểm.

- **Dendrogram**: Là sản phẩm cuối cùng của Hierarchical Clustering. Đây là biểu đồ trực quan thể hiện khoảng cách tương đối giữa các điểm dữ liệu gốc và các cụm trong quá trình gom nhóm.

- **Khoảng cách**: Khoảng cách trong Dendrogram thể hiện độ khác biệt. Nhánh gộp ở mức chiều cao thấp có nghĩa là các cụm/điểm đó rất tương đồng (gần nhau).

1.2. Thuật toán gom cụm (Agglomerative Clustering)

- **Nguyên tắc**: Gom cụm từ dưới lên (Bottom-up). Ban đầu, mỗi điểm dữ liệu được coi là một cụm riêng biệt, sau đó các cụm gần nhất sẽ được gộp dần lại.

- **Quy trình cơ bản (đã được tóm tắt):**

a. Tính ma trận khoảng cách (Proximity Matrix).

b. Tìm khoảng cách nhỏ nhất và gộp hai cụm tương ứng.

c. Cập nhật trọng tâm (Centroid) của cụm mới.

d. Lặp lại cho đến khi tất cả các điểm nằm trong một cụm duy nhất.

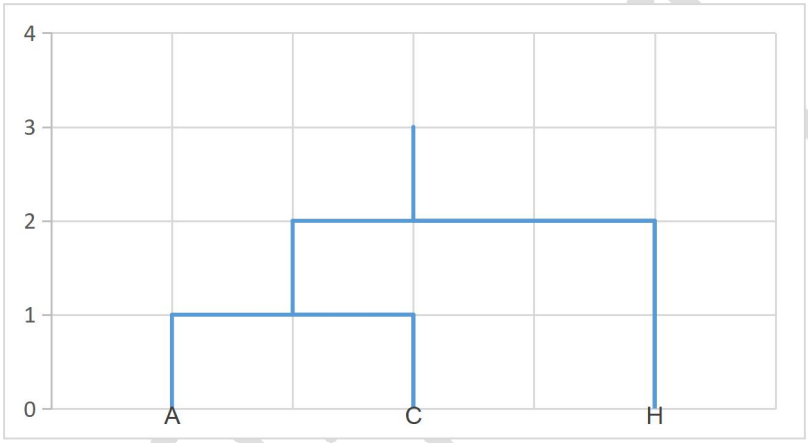
3125800015

2. Thực hành

2.1. File Chapter8-1a

- Ở phần này sẽ hướng dẫn cách vẽ hình Dendrogram mà không cần cài đặt phần mềm bên ngoài.

- Đầu tiên mở file lên, ta sẽ thấy một hình dendrogram đã vẽ sẵn. Bây giờ click chuột phải vào chữ Y trên hình và chọn "Delete", cùng với đó là click chuột phải vào một trong các số ở trục x và bấm "Delete" để xóa hết số ở trục x. Tiếp theo, bấm vào hình, vào phần "Chart Elements", chọn "Data Labels", bên trong đó chọn mục "Below". Ta tiếp tục xóa các giá trị ở trong hình, chừa lại các số ở 2 trục x và y. Sau đó, ta đổi tên các số ở trục X là ta đã có được một hình Dendrogram hoàn chỉnh (Hình kết quả bên dưới).



2.2. File Chapter8-2a

- Ở phần này sẽ hướng dẫn cách phân lớp phân cụm bằng Excel. Ở trong file này chứa kết quả cuối cùng, hướng dẫn vẽ Dendrogram và kết quả của từng bước thực hiện.

- Bước 1: Đầu tiên mở file lên, ta sẽ thấy được một bảng dữ liệu. Đi tới ô G1 và nhập "Step-1" sau đó autofill tới ô P1. Để cho dễ nhìn thì ta in đậm và cho các ô chữ đó thành màu đỏ. Tiếp theo, ta tới ô B13 và nhập "1" rồi autofill cho tới K13, giống như vậy nhưng ta làm với A14:A23. Đi tới ô B14, ta nhập vào công thức sau:
=IFERROR(IF($A14=B$13;1000000;SQRT(SUMXMY2($C2:$F2;INDEX($C$2:$F$11;B$13;0))));1000000) rồi autofill tới K23. Tiếp tục, ở ô L14 ta nhập vào công thức **=MATCH(MIN($B$14:$K$23);B14:K14;0)** rồi sau đó autofill tới L23. Cái hình ma trận khoảng cách sẽ như hình bên dưới, nó thể hiện điểm dữ liệu 4 và 1 có khoảng cách ngắn nhất.

		1	2	3	4	5	6	7	8	9	10	
1	1	1000000	37,88139385	40,58324778	17	57,7754273	39,5347948	160,8726204	22,04540769	70,47694659	57,16642371	4
2	2	37,88139385	1000000	35,4682957	52,64978632	48,89785271	65,31462317	193,8324018	47,86439178	52,47856705	89,02246907	#N/A
3	3	40,58324778	35,4682957	1000000	55,29918625	18,94729532	56,76266379	192,4967532	31,89043744	33,7934905	92,82779756	#N/A
4	4	17	52,64978632	55,29918625	1000000	71,72865536	35,24202037	144,7515112	29,3428015	86,56789243	42,22558466	1
5	5	57,7754273	48,89785271	18,94729532	71,72865536	1000000	65,55150647	202,9630508	47,01063709	28,93095228	106,0471593	#N/A
6	6	39,5347948	65,31462317	56,76266379	35,24202037	65,55150647	1000000	138,4160395	36,51027253	89,72179222	45,83666655	#N/A
7	7	160,8726204	193,8324018	192,4967532	144,7515112	202,9630508	138,4160395	1000000	163,3217683	225,5548714	106,0377291	#N/A
8	8	22,04540769	47,86439178	31,89043744	29,3428015	47,01063709	36,51027253	163,3217683	1000000	63,58458933	66,10597552	#N/A
9	9	70,47694659	52,47856705	33,7934905	86,56789243	28,93095228	89,72179222	225,5548714	63,58458933	1000000	125,1119499	#N/A
10	10	57,16642371	89,02246907	92,82779756	42,22558466	106,0471593	45,83666655	106,0377291	66,10597552	125,1119499	1000000	#N/A

- Bước 2: Ta copy số từ G2:G11 rồi paste qua H2:H11, thay đổi số từ H2:H5 thành 1. Ở đây, 1 chỉ ra rằng đây là cụm đầu tiên. Đi tới ô N14, ta nhập **=AVERAGE(C2;C5)** rồi autofill tới Q14. Xin lưu ý rằng một cluster được biểu diễn bằng trung tâm của nó trong bài tập này. Copy giá trị của ô N14:Q14 rồi paste xuống N15:Q15. Mục đích là để tránh tính toán lặp lại tình cờ trong bước tiếp theo. Tiếp tục ta lấy giá trị từ ô N14:Q14 ta gán cho C2:F2, sau đó xóa hết giá trị từ C5:F5. Lưu ý, rất quan trọng để xóa đi nội dung C5:F5 cho Country L4 vì Country L1 (C2:F2) hiện đang đại diện cho cụm 1. Sau khi hoàn thành ta sẽ thấy được thay đổi ở ô L14:L23, nó nói rằng Country L5 và L3 đang trong cùng một cụm, nhưng giá trị của chúng đều lớn hơn 10, nên chúng sẽ ở trong cụm 2. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	10	185	50,5	19	11	1									
3	2	L2	9	222	39	42	12	1									
4	3	L3	6	226	72	30	13	1									
5	4	L4					14	1									
6	5	L5	7	235	86	39	15	1									
7	6	L6	5	170	78	37	16	16									
8	7	L7	0	35	75	7	17	17									
9	8	L8	4	198	70	15	18	18									
10	9	L9	13	259	74	30	19	19									
11	10	L10	15	136	52	24	20	20									
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	45,06939094	47,75196331	1000000	64,56972975	36,47259245	152,7882522	24,52039967	78,47451816	49,53029376	#N/A		10	185	50,5	19
15	2	45,06939094	1000000	35,4682957	1000000	48,89785271	65,31462317	193,8324018	47,86439178	52,47856705	89,02246907	#N/A		10	185	50,5	19
16	3	47,75196331	35,4682957	1000000	1000000	18,94729532	56,76266379	192,4967532	31,89043744	33,7934905	92,82779756	5					
17	4	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
18	5	64,56972975	48,89785271	18,94729532	1000000	1000000	65,55150647	202,9630508	47,01063709	28,93095228	106,0471593	3					
19	6	36,47259245	65,31462317	56,76266379	1000000	65,55150647	1000000	138,4160395	36,51027253	89,72179222	45,83666655	#N/A					
20	7	152,7882522	193,8324018	192,4967532	1000000	202,9630508	138,4160395	1000000	163,3217683	225,5548714	106,0377291	#N/A					
21	8	24,52039967	47,86439178	31,89043744	1000000	47,01063709	36,51027253	163,3217683	1000000	63,58458933	66,10597552	#N/A					
22	9	78,47451816	52,47856705	33,7934905	1000000	28,93095228	89,72179222	225,5548714	63,58458933	1000000	125,1119499	#N/A					
23	10	49,53029376	89,02246907	92,82779756	1000000	106,0471593	45,83666655	106,0377291	66,10597552	125,1119499	1000000	#N/A					

- Bước 3: Copy giá trị ô H2:H11 rồi paste qua ô I2:I11, thay đổi giá trị từ I4:I4 thành 2. Bây giờ ta tính Centroid của Country L3 và L5, ở ô N14 ta nhập vào **=AVERAGE(C4;C6)** rồi autofill tới Q14, copy giá trị từ N14:Q14 rồi paste xuống N15:Q15. Sau đó ta copy giá trị N15:Q15 ta gán vào C4:F4. Bây giờ ta đang sử dụng C4:F4 (Country L4) đại diện cho cụm 2. Tiếp theo, xóa hết giá trị từ C6:F6. Như vậy Country L3 và L5 thì ở cụm 2, còn Country L8 thì ở cùng cụm với L1 là cụm 1. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	10	185	50,5	19	11	1	1								
3	2	L2	9	222	39	42	12	1	1								
4	3	L3	6,5	230,5	79	34,5	13	1	2								
5	4	L4					14	1	2								
6	5	L5					15	1	2								
7	6	L6	5	170	78	37	16	16	16								
8	7	L7	0	35	75	7	17	17	17								
9	8	L8	4	198	70	15	18	18	18								
10	9	L9	13	259	74	30	19	19	19								
11	10	L10	15	136	52	24	20	20	20								
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	45,06939094	55,99107072	1000000	1000000	36,47259245	152,7882522	24,52039967	78,47451816	49,53029376	8		6,5	230,5	79	34,
15	2	45,06939094	1000000	41,65033013	1000000	1000000	65,31462317	193,8324018	47,86439178	52,47856705	89,02246907	#N/A		6,5	230,5	79	34,
16	3	55,99107072	41,65033013	1000000	1000000	1000000	60,57846152	197,5721387	39,03524049	29,99583304	99,2055946	#N/A					
17	4	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
19	6	36,47259245	65,31462317	60,57846152	1000000	1000000	1000000	138,4160395	36,51027253	89,72179222	45,83666655	#N/A					
20	7	152,7882522	193,8324018	197,5721387	1000000	1000000	138,4160395	1000000	163,3217683	225,5548714	106,0377291	#N/A					
21	8	24,52039967	47,86439178	39,03524049	1000000	1000000	36,51027253	163,3217683	1000000	63,58458933	66,10597552	1					
22	9	78,47451816	52,47856705	29,99583304	1000000	1000000	89,72179222	225,5548714	63,58458933	1000000	125,1119499	#N/A					
23	10	49,53029376	89,02246907	99,2055946	1000000	1000000	45,83666655	106,0377291	66,10597552	125,1119499	1000000	#N/A					

- Bước 4: Copy giá trị từ I2:I11 paste cho J2:J11, đổi giá trị J9 thành 1. Bây giờ ta sẽ đi tính lại Centroid của cụm 1. Đầu tiên, nhập **=SUM(C2*2;C9)/3** vào ô N14 (Lưu ý, vì cụm 1 đã có hai điểm dữ liệu và bây giờ bao gồm cả Country L8, nên ta cần nhân đôi C2 trước) rồi autofill tới Q14, copy giá trị N14:Q14 rồi paste cho N15:Q15 và C2:F2. Rồi xóa đi giá trị từ C9:F9, như vậy bảng của ta sẽ hiển thị Country L3 và L9 là ở trong cùng một cụm. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	8	189,3333333	57	17,66666667	11	1	1	1							
3	2	L2	9	222	39	42	12	1	1	1							
4	3	L3	6,5	230,5	79	34,5	13	1	2	2							
5	4	L4					14	1	2	2							
6	5	L5					15	1	2	2							
7	6	L6	5	170	78	37	16	16	16	16							
8	7	L7	0	35	75	7	17	17	17	17							
9	8	L8					18	18	18	1							
10	9	L9	13	259	74	30	19	19	19	19							
11	10	L10	15	136	52	24	20	20	20	20							
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	44,54460935	49,64177228	1000000	1000000	34,60571565	155,9504907	1000000	72,93528334	54,39260571	#N/A		5,33333	126,222222	38	11,7777778
15	2	44,54460935	1000000	41,65033013	1000000	1000000	65,31462317	193,8324018	1000000	52,47856705	89,02246907	#N/A		8	189,333333	57	17,6666667
16	3	49,64177228	41,65033013	1000000	1000000	1000000	60,57846152	197,5721387	1000000	29,99583304	99,2055946	9					
17	4	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
19	6	34,60571565	65,31462317	60,57846152	1000000	1000000	1000000	138,4160395	1000000	89,72179222	45,83666655	#N/A					
20	7	155,9504907	193,8324018	197,5721387	1000000	1000000	138,4160395	1000000	1000000	225,5548714	106,0377291	#N/A					
21	8	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
22	9	72,93528334	52,47856705	29,99583304	1000000	1000000	89,72179222	225,5548714	1000000	1000000	125,1119499	3					
23	10	54,39260571	89,02246907	99,2055946	1000000	1000000	45,83666655	106,0377291	1000000	125,1119499	1000000	#N/A					

- Bước 5: Chắc chắn là Country L9 đang ở cùng cụm 2 với L3, ta copy giá trị từ J2:J11 paste cho K2:K11, đổi giá trị K10 thành 2. Ta tính lại lại Centroid của cụm 2, nhập **=SUM(C4*2;C10)/3** vào ô N14 rồi autofill tới Q14, copy giá trị từ N14:Q14 rồi paste cho N15:Q15 và C4:F4, xóa đi giá trị C10:F10. Ta có thể thấy bảng ma trận khoảng cách sẽ hiển thị Country L6 ở cùng cụm với L1.

- Bước 6: Copy giá trị từ K2:K11 paste cho L2:L11, đổi giá trị ô L7 thành 1. Bây giờ ta tính lại Centroid của cụm 1, nhập **=SUM(C2*3;C7)/4** vào ô N14 rồi autofill tới Q14, copy giá trị từ N14:Q14 rồi paste cho N15:Q15 và C2:F2, sau đó xóa hết giá trị C7:F7. Như vậy ta có thể thấy Country L3 và L2 đang ở cùng cụm. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	7,25	184,5	62,25	22,5	11	1	1	1	1	1					
3	2	L2	9	222	39	42	12	1	1	1	1	1					
4	3	L3	8,666666667	240	77,33333333	33	13	1	2	2	2	2					
5	4	L4					14	1	2	2	2	2					
6	5	L5					15	1	2	2	2	2					
7	6	L6					16	16	16	16	16	1					
8	7	L7	0	35	75	7	17	17	17	17	17	17					
9	8	L8					18	18	18	1	1	1					
10	9	L9					19	19	19	19	2	2					
11	10	L10	15	136	52	24	20	20	20	20	20	20					
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	48,27136833	58,48088482	1000000	1000000	1E+06	151,02	1E+06	1E+06	50,196	#N/A		5,4375	138,38	46,688	16,875
15	2	48,27136833	1000000	43,29613788	1000000	1000000	1E+06	193,83	1E+06	1E+06	89,022	3		7,25	184,5	62,25	22,5
16	3	58,48088482	43,29613788	1000000	1000000	1000000	1E+06	206,84	1E+06	1E+06	107,61	2					
17	4	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
19	6	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
20	7	151,0153138	193,8324018	206,8370266	1000000	1000000	1E+06	1E+06	1E+06	1E+06	106,04	#N/A					
21	8	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
22	9	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
23	10	50,19586636	89,02246907	107,6052456	1000000	1000000	1E+06	106,04	1E+06	1E+06	1E+06	#N/A					

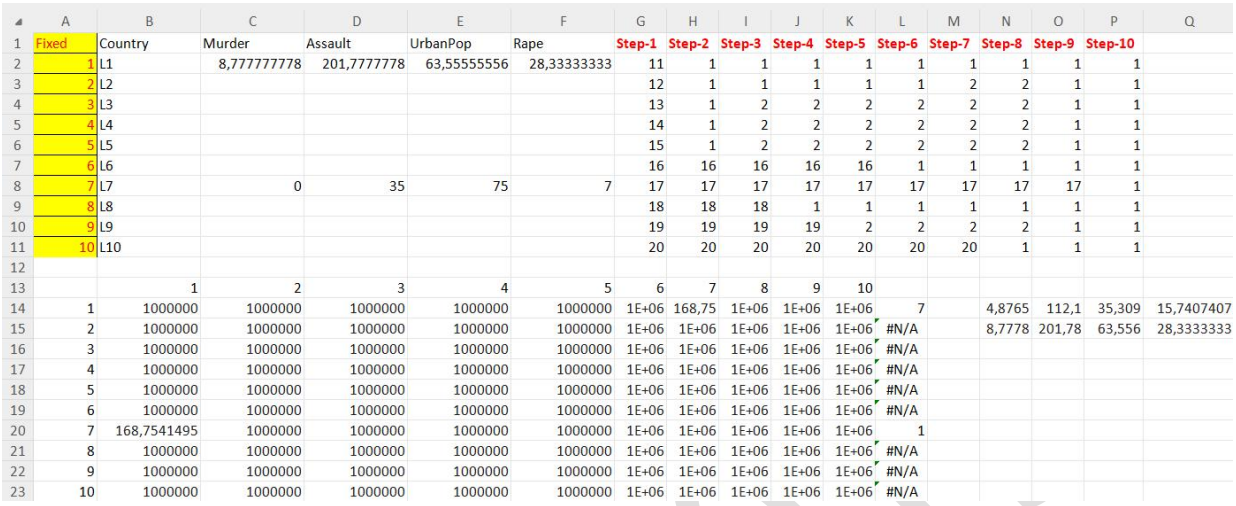
- Bước 7: Copy giá trị từ L2:L11 paste cho M2:M11, vì Country L2 đang ở cùng cụm với L3 (cụm 2) nên ta đổi giá trị M3 thành 2. Rồi tính lại Centroid của cụm 2, ta nhập **=SUM(C4*3;C3)/4** vào ô N14 rồi autofill tới Q14, copy giá trị xuống cho N15:Q15 và C4:F4, xóa hết giá trị C3:F3. Ta có thể thấy được lúc này Country L10 và L1 ở cùng cụm.

- Bước 8 : Copy M2:M11 cho N2:N11 và đổi giá trị N11 thành 1. Ở ô N14 ta nhập **=SUM(C2*4;C11)/5** rồi autofill tới Q14, copy giá trị xuống cho N15:Q15 và cho C2:F2. Sau khi xóa đi giá trị C11:F11, bảng ma trận khoảng cách cho ta thấy được rằng Country L3 và L1 ở cùng cụm. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	8,8	174,8	60,2	22,8	11	1	1	1	1	1	1	1			
3	2	L2					12	1	1	1	1	1	2	2			
4	3	L3	8,75	235,5	67,75	35,25	13	1	2	2	2	2	2	2			
5	4	L4					14	1	2	2	2	2	2	2			
6	5	L5					15	1	2	2	2	2	2	2			
7	6	L6					16	16	16	16	16	1	1	1			
8	7	L7	0	35	75	7	17	17	17	17	17	17	17	17			
9	8	L8					18	18	18	1	1	1	1	1			
10	9	L9					19	19	19	19	2	2	2	2			
11	10	L10					20	20	20	20	20	20	20	1			
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	1000000	62,42193124	1000000	1000000	1E+06	141,74	1E+06	1E+06	1E+06	3		7,04	139,84	48,16	18,24
15	2	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A		8,8	174,8	60,2	22,8
16	3	62,42193124	1000000	1000000	1000000	1000000	1E+06	202,8	1E+06	1E+06	1E+06	1					
17	4	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
19	6	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
20	7	141,7397615	1000000	202,7990076	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
21	8	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
22	9	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
23	10	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					

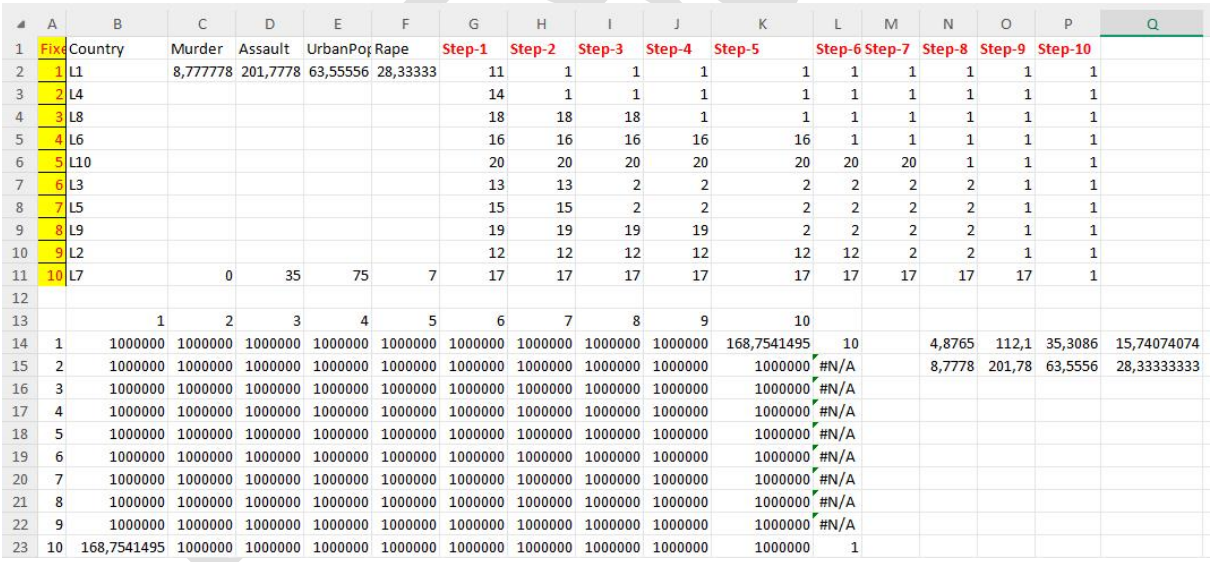
- Bước 9: Bởi vì Country L1 ở cụm 1 và L3 ở cụm 2, mà cả hai đã được xử lý. Điều này chứng tỏ rằng chúng ta phải gộp cả cụm 1 và cụm 2 lại với nhau. Ta copy N2:N11 qua O2:O11, đầu tiên ta tính lại Centroid của cụm đã gộp trước bằng cách nhập **=SUM(C2*5;C4*4)/9** vào ô N14 rồi autofill tới Q14, copy xuống cho N15:Q15 (sau bước này ta đổi hết số 2 trong O2:O11 thành 1) và C2:F2, sau khi paste giá trị cho C2:F2 thì mới xóa giá trị C4:F4. Lúc này bảng ma trận khoảng cách nói rằng Country L7 và L1 ở cùng cụm.

- Bước 10: Bây giờ copy O2:O11 qua cho P2:P11, đổi hết giá trị thành 1. Lúc này tất cả điểm dữ liệu đã được phân cụm vào cụm 1. (Hình kết quả bên dưới)



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixed	Country	Murder	Assault	UrbanPop	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	8,777777778	201,7777778	63,55555556	28,33333333	11	1	1	1	1	1	1	1	1	1	
3	2	L2					12	1	1	1	1	1	2	2	1	1	
4	3	L3					13	1	2	2	2	2	2	2	1	1	
5	4	L4					14	1	2	2	2	2	2	2	1	1	
6	5	L5					15	1	2	2	2	2	2	2	1	1	
7	6	L6					16	16	16	16	16	1	1	1	1	1	
8	7	L7	0	35	75	7	17	17	17	17	17	17	17	17	17	1	
9	8	L8					18	18	18	1	1	1	1	1	1	1	
10	9	L9					19	19	19	19	2	2	2	2	1	1	
11	10	L10					20	20	20	20	20	20	20	1	1	1	
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	1000000	1000000	1000000	1000000	1E+06	168,75	1E+06	1E+06	1E+06	7		4,8765	112,1	35,309	15,7407407
15	2	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A		8,7778	201,78	63,556	28,3333333
16	3	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
17	4	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
19	6	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
20	7	168,7541495	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	1					
21	8	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
22	9	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					
23	10	1000000	1000000	1000000	1000000	1000000	1E+06	1E+06	1E+06	1E+06	1E+06	#N/A					

Nhiệm vụ của ta vẫn chưa hoàn thành. Cần tổ chức lại mười điểm dữ liệu để có thể hình dung rõ hơn cách vẽ Dendrogram. Để làm điều đó, chúng ta cần sắp xếp bảng B1:P11. Ta chọn B1:P11, đi tới phần "Data", chọn Custom sort, đổi Column thành Step-2 rồi bấm OK, sau đó tiếp tục làm như vậy Step-3,4,5... tới Step-9 thì ngưng. (Hình kết quả bên dưới)



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Fixe	Country	Murder	Assault	UrbanPo	Rape	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7	Step-8	Step-9	Step-10	
2	1	L1	8,777778	201,7778	63,55556	28,33333	11	1	1	1	1	1	1	1	1	1	
3	2	L4					14	1	1	1	1	1	1	1	1	1	
4	3	L8					18	18	18	1	1	1	1	1	1	1	
5	4	L6					16	16	16	16	16	1	1	1	1	1	
6	5	L10					20	20	20	20	20	20	20	1	1	1	
7	6	L3					13	13	2	2	2	2	2	2	1	1	
8	7	L5					15	15	2	2	2	2	2	2	1	1	
9	8	L9					19	19	19	19	2	2	2	2	1	1	
10	9	L2					12	12	12	12	12	12	2	2	1	1	
11	10	L7	0	35	75	7	17	17	17	17	17	17	17	17	17	1	
12																	
13		1	2	3	4	5	6	7	8	9	10						
14	1	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	168,7541495	10		4,8765	112,1	35,3086	15,74074074
15	2	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A		8,7778	201,78	63,5556	28,33333333
16	3	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
17	4	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
18	5	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
19	6	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
20	7	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
21	8	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
22	9	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A					
23	10	168,7541495	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1000000	1					

Sau khi sắp xếp, dữ liệu đã sẵn sàng để vẽ Dendrogram. Hãy xem kỹ B1:B11, cho thấy khi vẽ Dendrogram, chúng ta nên sắp xếp các điểm dữ liệu (Country) từ trái sang phải theo thứ tự này: L1, L4, L8, L6, L10, L3, L5, L9, L2, L7.

Dữ liệu bên trong G1:P11 nói ta rằng:

• (L1, L4) là cấp độ đầu tiên của cụm.

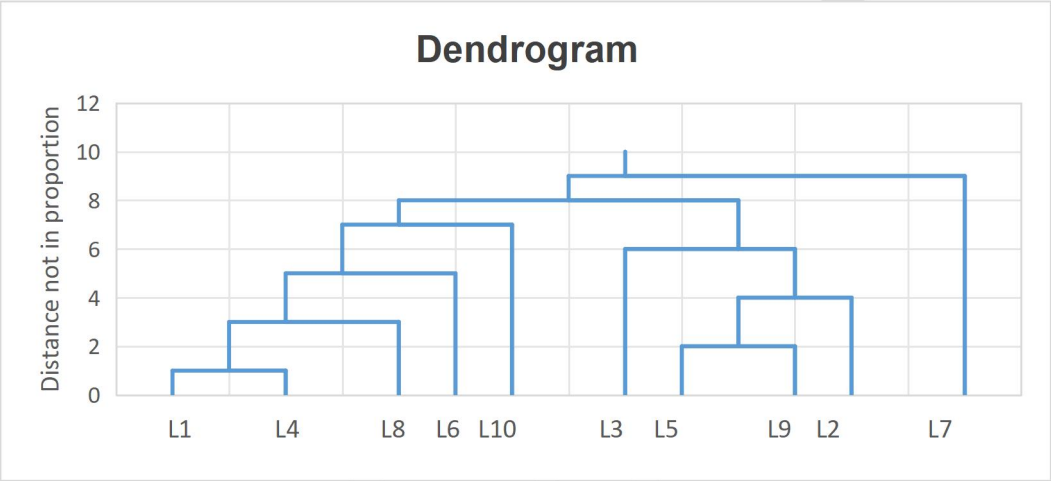
• (L3, L5) là cấp độ thứ hai của cụm..

• ((L1, L4), L8) là cấp độ thứ ba của cụm..

• ((L3, L5), L9) là cấp độ thứ tư của cụm..

• (((L1, L4), L8), L6) là cấp độ thứ năm của cụm., và cứ tiếp tục như vậy.

- Chuyển qua Sheet “Dendrogram” ta sẽ hướng dẫn vẽ Dendrogram, đầu tiên ta chọn 2 cột là R và S, sau đó đi tới mục “Insert” trên thanh Excel, ta chọn vẽ “Scatter with Straight Lines”, có được hình rồi ta đổi tên hình từ “Y” sang “Dendrogram”, xóa trục x, vào phần Chart Elemnents thêm “Axis Titles”, đổi tên Axis Titles thành “Distance not in proportion”, ở trục x ta nhập vào “L1 L4 L8 L6 L10 L3 L5 L9 L2 L7“ để có thể canh cho nó ngay ngắn ta chỉ việc bấm Space để canh thôi. (Hình kết quả bên dưới)



2.3. File Chapter8-HW-1

- Ở trong file này sẽ chứa 2 Sheet tên là “Hierarchical Clustering” và “Dendrogram”. Chúng có chức năng như sau:

- “Hierarchical Clustering”: chứa dữ liệu và ma trận khoảng cách, dữ liệu đầu vào có 7 bệnh nhân P1-P7 và mỗi bệnh nhân có 6 chỉ số gen (biến độc lập) đã được chuẩn hóa.

- “Dendrogram”: chứa hình Dendrogram vẽ được từ kết quả của “Hierarchical Clustering” bằng cách viết tay ra giấy sau đó thêm vào 2 cột là R và S.

- Các cột từ Step-1 đến Step-7 thể hiện kết quả sau mỗi lần gộp nhóm. Vì có 7 điểm dữ liệu, quá trình cần 6 bước gộp để về 1 cụm lớn duy nhất, do đó cột Step-7 thường đại diện cho trạng thái cuối cùng (1 cụm). (Hình kết quả cuối cùng bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	Patients-GeneSymbol	CREB3L1	RPS11	PNMA1	MMP2	C10orf90	ZHX3	Step-1	Step-2	Step-3	Step-4	Step-5	Step-6	Step-7		
2	P2	0,658	0,4225	-0,74125	0,005	-1,27375	-0,27	11	1	1	1	1	1	1		
3	P3							12	1	1	1	1	1	1		
4	P1							10	10	2	1	1	1	1		
5	P5							14	14	2	1	1	1	1		
6	P6							15	15	15	15	1	1	1		
7	P4	2,39	0,465	-0,285	1,22	-2,515	-0,56	13	13	13	13	13	3	1		
8	P7							16	16	16	16	16	3	1		
9																
10		1	2	3	4	5	6	7								
11	1	1000000	1000000	1000000	1000000	1000000	2,512134725	1000000	6		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!
12	2	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A		2,39	0,465	-0,285	1,22	-2,515	-0,56
13	3	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A							
14	4	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A							
15	5	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A							
16	6	2,512135	1000000	1000000	1000000	1000000	1000000	1000000	1							
17	7	1000000	1000000	1000000	1000000	1000000	1000000	1000000	#N/A							

- Cách thực hiện từng bước làm dưới dạng bảng:

Bước	Mô tả thao tác trong Excel	Kết quả/Mục đích
1	Tính Ma trận Khoảng cách ban đầu	Sử dụng công thức Khoảng cách Euclid (SQRT(SUMXMY2)) để tính khoảng cách giữa tất cả các cặp bệnh nhân (P1 vs P2, P1 vs P3, v.v.). 5
2	Tìm Min và Gộp	Dùng hàm MIN để tìm khoảng cách nhỏ nhất trong ma trận. Gộp hai bệnh nhân/cụm có khoảng cách nhỏ nhất đó vào một cụm mới.
3	Cập nhật Centroid	Tính giá trị trung bình (Centroid) của 6 gen cho cụm mới vừa gộp. (Ví dụ: Trung bình của P1 và P5).
4	Lặp lại	Dán Centroid mới vào bảng dữ liệu gốc (sử dụng Paste Values), sau đó tính lại Ma trận Khoảng cách cho vòng lặp tiếp theo (Step-2, Step-3,...) cho đến khi tất cả các bệnh nhân được gộp thành 1 cụm. 6

- Bạn có thể tham khảo lại cách làm ở trên cho file Chapter8-2a để làm lại, kết quả sau khi thực hiện được và vẽ hình thì cũng xem lại hướng dẫn ở Chapter8-2a luôn.

2.4. File Chapter8-HW-2

- Ở trong file này sẽ chứa nhiều Sheet khác nhau, nó sẽ chứa từng bước làm phân cụm phân cấp cho 50 quốc gia và từng bước thực hiện để vẽ hình Dendrogram sau khi có được kết quả phân cụm.

- Bước đầu tiên: Ta thực hiện K-Means (K = 6) để thực hiện 9 vòng lặp để tìm ra 6 Centroid hội tụ là C_1 đến C_6 với dữ liệu đầu vào là 50 quốc gia với 4 biến: Murder, Assault, UrbanPop, Rape.
- Các bước thực hiện bài tập dưới dạng bảng:

Giai đoạn	Bước	Mô tả hành động	File/Sheet Liên quan
I. K-MEANS (K=6)	**1. Khởi tạo & Tính khoảng cách**	Khởi tạo 6 Centroid ban đầu. Tính Khoảng cách Euclid từ 50 quốc gia đến 6 Centroid.	1
	2. Gán lại cụm	Gán mỗi quốc gia vào cụm có khoảng cách nhỏ nhất (MIN).	1
	3. Cập nhật Centroid	Tính Centroid mới ($C_{mới}$) bằng cách lấy **trung bình** của tất cả các quốc gia vừa được gán vào cụm đó.	2 đến 8
	4. Hội tụ	Lặp lại bước 2 & 3 cho đến khi không có quốc gia nào thay đổi cụm (cột Difference = 0).	9
II. HIERARCHICAL CLUSTERING	**5. Dữ liệu HC**	Chuyển 6 Centroid cuối cùng (từ Step 4) thành 6 điểm dữ liệu mới để bắt đầu HC.	hc-1
	6. Tính ma trận HC	Tính khoảng cách Euclid giữa 6 Centroid này.	hc-1
	7. Gộp cụm	Lặp lại 5 bước gộp ($Step - 1$ đến $Step - 5$) bằng cách tìm khoảng cách nhỏ nhất (MIN) và tính **Centroid mới có trọng số** sau mỗi lần gộp.	hc-1 đến hc-5
	8. Vẽ Dendrogram	Sử dụng tọa độ X, Y được tính toán từ các bước gộp để tạo Biểu đồ Scatter Plot với đường nối.	hc-6

END