Hướng dẫn tải bài tập

- Trước khi làm bài tập chương, ta truy cập vào đường link Github sau để tải các bài tập trong chương đó: https://github.com/hhohho/Learn-Data-Mining-through-Excel-2.

- Sau khi truy cập vào đường link ta sẽ thấy có 14 folder đại diện cho từng chương và bài tập của chương đó, bây giờ bấm vào folder có tên "chapter8", trong folder sẽ chứa 11 file excel (5 file bài tập, 5 file đáp án của bài tập đó và 1 file tham khảo). Sau đó ta bấm vào từng file và tải "Download raw file" ở dưới icon "History".

Hiểu biết

1. Lý thuyết

1.1. Khái niệm

- **Phân cụm (Clustering)**: Là một phương pháp khai thác dữ liệu không giám sát (Unsupervised method). Nó phân loại các đối tượng (điểm dữ liệu) thành các nhóm (cụm) khác nhau dựa trên sự tương đồng về các đặc điểm.

- **Phân cụm K-Means**: Là một loại phân cụm phân vùng (Partitioning Clustering). Trong đó, K đại diện cho số lượng cụm mong muốn mà người dùng tự chọn. Với mục tiêu là phân chia N điểm dữ liệu thành K cụm sao cho các điểm dữ liệu trong cùng một cụm là tương đồng nhất.

- **Centroid (Trọng tâm)**: Là điểm đại diện cho tâm của một cụm. Vị trí của Centroid được tính bằng giá trị trung bình của tất cả các biến độc lập của các điểm trong cụm.

- **Khoảng cách Euclid (Euclidean Distance)**: Công thức được sử dụng phổ biến nhất để đo lường khoảng cách giữa một điểm dữ liệu và Centroid.

- **Các thuật ngữ đồng nghĩa**: Điểm dữ liệu (Data point), Bản ghi (Record), Đối tượng (Subject) đều có cùng ý nghĩa (một hàng dữ liệu). Nhóm (Group), Cụm (Cluster), Lớp (Class) đều có cùng ý nghĩa.

1.2. Thuật toán K-Means

Thuật toán K-Means hoạt động theo quy trình lặp lại (Iterative process) với các bước như sau:

2125800015

a. **Khởi tạo Centroid**: Chọn *K* điểm bất kỳ làm các Centroid ban đầu của *K* cụm.

b. **Tính khoảng cách**: Tính toán khoảng cách (thường là Khoảng cách Euclid) từ mọi điểm dữ liệu đến mọi Centroid hiện có.

c. **Gán cụm**: Gán mỗi điểm dữ liệu vào cụm có Centroid gần nhất (Khoảng cách nhỏ nhất).

d. **Tính toán Centroid mới**: Tính toán lại Centroid của mỗi cụm bằng cách lấy trung bình cộng (mean) của tất cả các điểm dữ liệu hiện đã được gán vào cụm đó.

e. **Lặp lại**: Lặp lại Bước 2, 3 và 4 cho đến khi Centroid của các cụm không còn thay đổi đáng kể (mô hình đạt hội tụ).

2. Thực hành

2.1. File Chapter3-1a

- Ở trong file này chứa 1 Sheet mang tên là "1", và dữ liệu về 50 quốc gia.

- Bước 1: Chọn từ G1:K1 và chọn "Merge and Center" . Đặt tên cho ô hợp nhất đó là "Mean", nhập "Cluster" cho ô G2 và nhập lần lượt C1-C4 cho H2:K2. Sau đó nhập từ G3:K6 theo bảng dưới đây.

Murder	2,3	5,6	11	15
Assault	15	53	100	200
UrbanPop	9,9	20	50	80
Rape	10	10	25	40

C1, C2, C3, và C4 đại diện cho cụm 1, cụm 2, cụm 3, và cụm 4, tương ứng. Các số trong các ô H3:K6 được chọn sau khi xem nhanh phạm vi dữ liệu của từng thuộc tính. Chúng ta cũng có thể chọn ngẫu nhiên một số số cho chúng. Trong ví dụ này, hãy giữ nguyên các số này. Các số trong các ô H3:H6, I3:I6, J3:J6, và K3:K6 đại diện cho các trung tâm của C1, C2, C3, và C4, tương ứng.

- Bước 2: Chọn M1:P1 rồi nhấn "Merge and Center", nhập vô ô đó là "Distances", nhập lần lượt C1-C4 và Cluster vào M2:Q2 lưu trữ các khoảng cách Euclidean từ mỗi điểm dữ liệu đến bốn tâm trung tâm trong các cột M, N, O và P. (Hình kết quả bên dưới)

G	H	I	J	K	L	M	N	O	P	Q
	Mean					Distances				
Cluster	C1	C2	C3	C4		C1	C2	C3	C4	Cluster
Murder	2.3	5.6	11	15						
Assault	15	53	100	200						
UrbanPop	9.9	20	50	80						
Rape	10	10	25	40						

Ô M3 lưu trữ khoảng cách từ Country L1 (12, 193, 51, 21) đến trung tâm C1 (2.3, 15, 9.9, 10). Có công thức **=SQRT(SUMXMY2($B3:$E3;H$3:H$6))**, ta autofill nó tới P3 rồi chọn M3:P3 autofill xuống M52:P52. Như vậy, khoảng cách từ mỗi điểm dữ liệu đến tất cả các tâm cụ thể đã được tính toán. (Hình kết quả bên dưới)

	J	K	L	M	N	O	P	Q
1				Distances				
2	C3	C4		C1	C2	C3	C4	Cluster
3	11	15		183.2711	143.9547	93.09672	35.49648	
4	100	200		211.5767	173.0825	123.6851	46.95743	
5	50	80		220.8871	181.7503	128.1015	30.34798	
6	25	40		167.1332	127.7919	77.47258	44.79955	
7				234.6365	195.7625	140.4742	36.41428	
8				171.4611	133.3505	76.57676	31.82766	
9				68.20777	58.21821	72.76675	169.0089	
10				192.6886	153.4684	100.7621	29.15476	
11				253.2969	214.0251	160.8913	60.17475	
12				129.5017	90.53927	36.29049	71.66589	

- Bước 3: Ở ô Q3 ta nhập **=@INDEX($M$2:$P$2;1;MATCH(MIN(M3:P3);M3:P3;0))** rồi autofill tới Q52. Tiếp theo ta cần bắt đầu vòng thứ hai của quá trình phân cụm bằng cách tạo một copy của Sheet "1" và đặt tên lại thành "2", bây giờ ở Sheet 2 ta nhập vào cho ô H3 là **=IFERROR(AVERAGEIFS(INDIRECT($F$1&"!"&ADDRESS(3;$F3;1)):INDIRECT($F$1&"!"&ADDRESS(52;$F3;1));INDIRECT($F$1&"!$Q$3"):INDIRECT($F$1&"!$Q$52");H$2);0)** rồi autofill tới K6. Trước đó thì ta nên nhập vào **=Sheet(A1)-1** cho ô F1, và nhập số 2-5 cho F3:F6. Ở cột R ta nhập 1,2 và autofill xuống R52. Nhập "Old cluster" cho S2 và "difference" cho T2. Ở S3, ta nhập vào **=@INDIRECT($F$1&"!Q"&R3)** và ở T3 ta nhập vào **=IF(Q3=S3;0;1)** và autofill chúng tới dòng 52. Công thức trên xác định rằng đối với một điểm dữ liệu cho trước, nếu cụm cuối cùng nó thuộc về khác với cụm hiện tại, thì trả về 1; còn nếu không, trả về 0. Mục tiêu của chúng ta là đạt được trạng thái ổn định khi cột S chỉ có số 0, tức là tất cả các điểm dữ liệu vẫn giữ nguyên cụm như trong lần lặp trước.

- Bước 4: Ta gộp G10:H10, đặt tên là "convergence", ô I10 ta viết công thức **=SUM(T3:T52)**. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1						1			Mean						Distances			1		
2	Country	Murder	Assault	UrbanPop	Rape		Cluster	C1	C2	C3	C4		C1	C2	C3	C4	Cluster	2	Old cluster	difference
3	L1	12	193	51	21	2	Murder	2	2,82	6,692307692	9,789473684		189,3638347	147,6882609	86,06637043	27,03322056	C4	3	C4	0
4	L2	9	222	39	42	3	Assault	4,175	45,9	108,2307692	215,3684211		220,5397059	179,3882449	118,804125	31,25792974	C4	4	C4	0
5	L3	6	226	72	30	4	UrbanPop	52,125	55,5	64,84615385	65,10526316		223,5690316	181,7076289	118,4377349	13,77279023	C4	5	C4	0
6	L4	8	177	50	17	5	Rape	10,875	12,7	19,69230769	26,15789474		173,050605	131,3879081	70,41714255	42,27734572	C4	6	C4	0
7	L5	7	235	86	39								235,0398091	193,3862001	129,9646288	31,53870243	C4	7	C4	0
8	L6	5	170	78	37								169,8792568	128,4612876	65,50482163	48,63186375	C4	8	C4	0
9	L7	0	35	75	7								38,63239411	23,22719096	75,31087445	181,9162771	C2	9	C2	0
10	L8	4	198	70	15		convergence		4				194,7014686	152,8114603	90,07964917	21,99175116	C4	10	C4	0
11	L9	13	259	74	30								256,7120213	214,8412958	151,5294999	44,80960028	C4	11	C4	0
12	L10	15	136	52	24								133,1131544	91,68588986	31,99574676	80,64056223	C3	12	C3	0

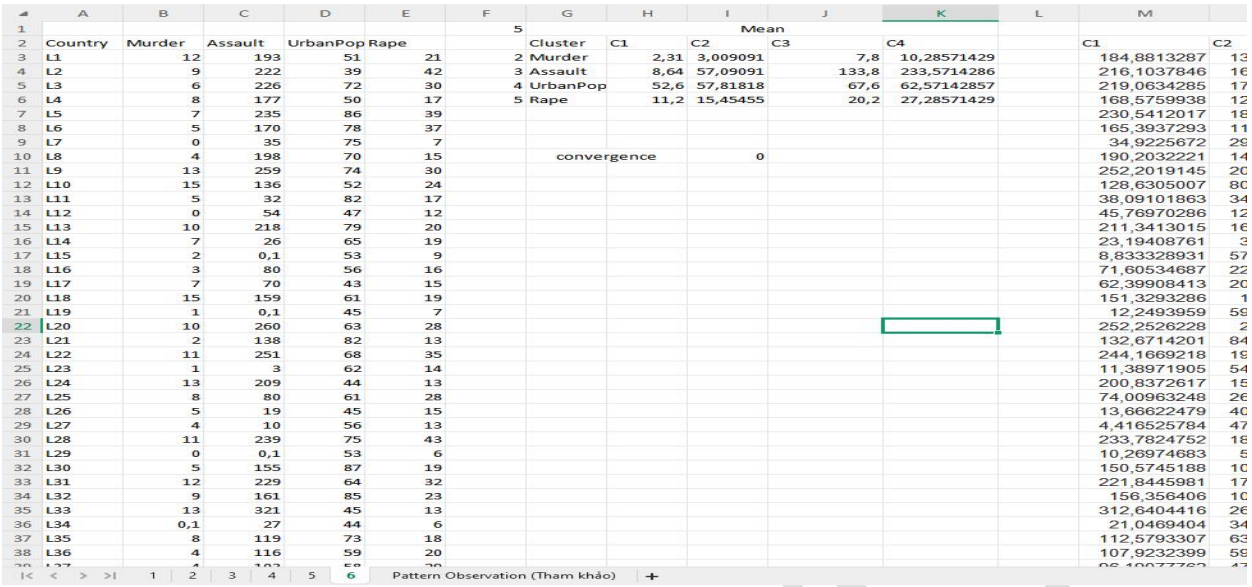
- Bước 5: Vì có bốn điểm dữ liệu đã chuyển nhóm trong vòng lặp thứ hai, chúng ta cần tiếp tục quá trình phân cụm. Tạo một bản sao của bảng tính số 2 và đặt tên bảng tính mới là 3. Đảm bảo rằng bảng tính 3 nằm ngay bên phải bảng tính 2. Ta có thể thấy rằng Sheet 3 đã tự động thay đổi cho chúng ta, (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1						2			Mean						Distances			1		
2	Country	Murder	Assault	UrbanPop	Rape		Cluster	C1	C2	C3	C4		C1	C2	C3	C4	Cluster	2	Old cluster	difference
3	L1	12	193	51	21	2	Murder	2	2,654545	7,666666667	9,8125		189,3638347	146,2439047	73,54448389	35,70768912	C4	3	C4	0
4	L2	9	222	39	42	3	Assault	4,175	47,36364	121,3333333	226,0625		220,5397059	177,9459255	106,8496971	28,26285659	C4	4	C4	0
5	L3	6	226	72	30	4	UrbanPop	52,125	57,09091	66,86666667	62,75		223,5690316	180,0256235	105,3270673	10,37612946	C4	5	C4	0
6	L4	8	177	50	17	5	Rape	10,875	13,72727	19,53333333	27,25		173,050605	129,981354	58,22191264	51,74977355	C4	6	C4	0
7	L5	7	235	86	39								235,0398091	191,5743569	116,8999192	27,68418434	C4	7	C4	0
8	L6	5	170	78	37								169,8792568	126,5858948	52,95839038	59,10828252	C3	8	C4	1
9	L7	0	35	75	7								38,63239411	22,93246283	87,95145125	192,7726357	C2	9	C2	0
10	L8	4	198	70	15		convergence		4				194,7014686	151,1998306	76,95187529	31,9986572	C4	10	C4	0
11	L9	13	259	74	30								256,7120213	213,1946567	138,3503709	35,0594364	C4	11	C4	0

- Bước 6: Ta cứ tiếp tục copy Sheet trước và đổi tên lại theo số thứ tự cho tới Sheet số 6 là được (lưu ý nên đặt theo đúng thứ tự từ bé đến lớn). Khi copy thì ta có thể thấy Sheet 5 phần "convergence" đã biến thành 0. (Hình kết quả bên dưới)

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1						4			Mean						Distances			1		
2	Country	Murder	Assault	UrbanPop	Rape		Cluster	C1	C2	C3	C4		C1	C2	C3	C4	Cluster	2	Old cluster	difference
3	L1	12	193	51	21	2	Murder	2,31	3,009091	7,8	10,28571429		184,8813287	136,4894029	61,63180997	42,68943376	C4	3	C4	0
4	L2	9	222	39	42	3	Assault	8,64	57,09091	133,8	233,5714286		216,1037846	168,1953756	95,25691576	30,12761971	C4	4	C4	0
5	L3	6	226	72	30	4	UrbanPop	52,6	57,81818	67,6	62,57142857		219,0634285	170,1526395	92,84115467	13,11332085	C4	5	C4	0
6	L4	8	177	50	17	5	Rape	11,2	15,45455	20,2	27,28571429		168,5759938	120,2772283	46,75767317	58,90150894	C3	6	C3	0
7	L5	7	235	86	39								230,5412017	181,7035368	104,5661513	26,43783621	C4	7	C4	0
8	L6	5	170	78	37								165,3937293	116,7216301	41,3361827	66,34510886	C3	8	C3	0
9	L7	0	35	75	7								34,9225672	29,38974494	100,2560721	200,2558058	C2	9	C2	0
10	L8	4	198	70	15		convergence		0				190,2032221	141,4388812	64,56686457	38,87105843	C4	10	C4	0
11	L9	13	259	74	30								252,2019145	203,3236847	125,8534068	28,14176938	C4	11	C4	0

Một khi sự hội tụ đã đạt đến 0, bất kể chúng ta tiếp tục bao nhiêu lần lặp nữa, dữ liệu sẽ không thay đổi nữa. Tuy nhiên, cần xác nhận điều đó bằng cách tạo một bảng tính thứ 6 để lặp lại quá trình trước đó. (Hình kết quả bên dưới)



	A	B	C	D	E	F	G	H	I	J	K	L	M	
1						5			Mean					
2	Country	Murder	Assault	UrbanPop	Rape		Cluster	C1	C2	C3	C4		C1	C2
3	L1	12	193	51	21	2	Murder	2,31	3,009091	7,8	10,28571429		184,8813287	13
4	L2	9	222	39	42	3	Assault	8,64	57,09091	133,8	233,5714286		216,1037846	16
5	L3	6	226	72	30	4	UrbanPop	52,6	57,81818	67,6	62,57142857		219,0634285	17
6	L4	8	177	50	17	5	Rape	11,2	15,45455	20,2	27,28571429		168,5759938	12
7	L5	7	235	86	39								230,5412017	18
8	L6	5	170	78	37								165,3937293	11
9	L7	0	35	75	7								34,9225672	29
10	L8	4	198	70	15		convergence		0				190,2032221	14
11	L9	13	259	74	30								252,2019145	20
12	L10	15	136	52	24								128,6305007	80
13	L11	5	32	82	17								38,09101863	34
14	L12	0	54	47	12								45,76970286	12
15	L13	10	218	79	20								211,3413015	16
16	L14	7	26	65	19								23,19408761	3
17	L15	2	0,1	53	9								8,833328931	57
18	L16	3	80	56	16								71,60534687	22
19	L17	7	70	43	15								62,39908413	20
20	L18	15	159	61	19								151,3293286	1
21	L19	1	0,1	45	7								12,2493959	59
22	L20	10	260	63	28								252,2526228	2
23	L21	2	138	82	13								132,6714201	84
24	L22	11	251	68	35								244,1669218	19
25	L23	1	3	62	14								11,38971905	54
26	L24	13	209	44	13								200,8372617	15
27	L25	8	80	61	28								74,00963248	26
28	L26	5	19	45	15								13,66622479	40
29	L27	4	10	56	13								4,416525784	47
30	L28	11	239	75	43								233,7824752	18
31	L29	0	0,1	53	6								10,26974683	5
32	L30	5	155	87	19								150,5745188	10
33	L31	12	229	64	32								221,8445981	17
34	L32	9	161	85	23								156,356406	10
35	L33	13	321	45	13								312,6404416	26
36	L34	0,1	27	44	6								21,0469404	34
37	L35	8	119	73	18								112,5793307	63
38	L36	4	116	59	20								107,9232399	58

1 2 3 4 5 6 Pattern Observation (Tham khảo) +

- Như vậy, tất cả các điểm dữ liệu đã được phân cụm thành công. Sheet "Pattern Observation" chứa quan sát của tác giả về các mẫu hình, bạn có thể tham khảo nếu muốn hiểu sâu hơn.

2.2. File Chapter3-HW

- Ở trong file này sẽ chứa 15 Sheet có tên từ 1-15, Sheet 1 là khởi tạo centroid ban đầu. Từ Sheet 2 trở đi ta chỉ cần copy Sheet trước đó, Excel sẽ tự động tính centroid mới bằng AVERAGEIFS, tính lại khoảng cách Euclid bằng SQRT(SUMXMY2...), gán cụm mới, rồi so sánh với cụm cũ qua cột Difference. Ta theo dõi sự thay đổi như sau:

- Sheet 1 → Sheet 2: có tới 48 bệnh nhân đổi cụm (rất nhiều!)
- Sheet 3: còn 29
- Sheet 4: còn 17
- Sheet 5: còn 9
- Sheet 6: còn 4
- Sheet 7: còn 2
- Sheet 8: còn 1
- Sheet 9: 0 → hội tụ hoàn toàn

- Từ Sheet 9 đến Sheet 15 đều cho kết quả giống nhau → chứng minh đã thật sự ổn định. Kết quả cuối cùng:

- C1: 83 bệnh nhân
- C2: 41 bệnh nhân
- C3: 19 bệnh nhân
- C4: 12 bệnh nhân

- Cụm lớn nhất gấp gần 7 lần cụm nhỏ nhất, cho thấy dữ liệu có sự phân bố không đều, có một nhóm bệnh nhân chính rất đông và ba nhóm nhỏ hơn, đặc trưng hơn.

2.3. File Chapter3-HW-NameManager

- Đây là một file do tác giả đã viết sẵn, tôi để ở đây chỉ để các bạn tham khảo. Ở trong file này ta sẽ dùng NameManager, một tính năng tích hợp sẵn của Excel, để làm cho các công thức trở nên đơn giản hơn. Bạn có thể tham khảo file để hiểu thêm về nó hoặc muốn hiểu chuyên sâu hơn thì lên mạng.

2.4. File Chapter3-HW-Cell-Function

- Đây là một file do tác giả đã viết sẵn, tôi để ở đây chỉ để các bạn tham khảo. Các file trước ta chỉ sử dụng hàm Sheet để tự động hóa quá trình phân cụm K-Means. Một yêu cầu quan trọng của việc sử dụng hàm Sheet là phải sắp xếp tất cả các bảng tính theo thứ tự. Nếu không muốn sắp xếp tất cả các bảng tính theo thứ tự, chúng ta có thể sử dụng hàm Cell thay vì Sheet. Ở trong file này sẽ trình bày một giải pháp như vậy, bạn cứ thoải mái khám phá và chỉnh sửa nếu bạn muốn.

312358015

END